

# 基于OCV模型优化的磷酸铁锂电池SOC估计

陈贵升, 许杨松, 沈颖刚, 肖仁鑫

(昆明理工大学 云南省内燃机重点实验室, 云南 昆明 650500)

**摘要:** 锂离子电池荷电状态(SOC)与开路电压(OCV)的关系曲线(OCV曲线)是影响其SOC估计精度的核心因素。针对小电流OCV(LO)测试耗时短但数据精度较低的问题,提出一种OCV模型及其优化方法。该方法基于LO测试的OCV数据,采用道格拉斯-普克算法和分段线性函数建立OCV模型。并将OCV曲线上的4个OCV点作为变量,建立了其他OCV点的随动模型,使曲线能够运用粒子群优化算法进行优化。基于优化后的OCV曲线,动态工况下的端电压估计绝对平均误差降低83.5%,采用自适应扩展卡尔曼滤波的SOC估计误差小于0.3%。该方法能够基于耗时短的LO测试获取准确OCV曲线,降低锂离子电池研究与应用的测试成本。

**关键词:** 磷酸铁锂电池; SOC估计; 小电流OCV测试; OCV模型

中图分类号: TM 912 文献标识码: A 文章编号: 1002-087X(2024)07-1281-08

DOI: 10.3969/j.issn.1002-087X.2024.07.016

## SOC estimation of LiFePO<sub>4</sub> battery based on OCV model optimization

CHEN Guisheng, XU Yangsong, SHEN Yinggang, XIAO Renxin

(Yunnan Key Laboratory of Internal Combustion Engine, Kunming University of Science and Technology,  
Kunming Yunnan 650500, China)

**Abstract:** The relationship curve between state-of-charge(SOC) and open-circuit voltage (OCV) of lithium-ion batteries is the core factor affecting SOC estimation accuracy. An OCV model and its optimization method are proposed to address the issue of short test times but low accuracy of the data in the low-current OCV (LO) test. Based on OCV data from the LO test, the method creates an OCV model using the Douglas-Peucker algorithm and piecewise linear functions. Since four OCV points on the OCV curve are utilized as variables and a follow-up model is created for other OCV points, the curve could be optimized using particle swarm optimization. Based on the optimized OCV curve, the absolute average error of terminal voltage estimation under dynamic conditions is reduced by 83.5%, and the SOC estimation error using adaptive extended Kalman filtering is less than 0.3%. Accurate OCV curves based on the short-time LO test can be obtained by this method, reducing the testing cost in the research and application of lithium-ion batteries.

**Key words:** LiFePO<sub>4</sub> battery; SOC estimation; low-current OCV test; OCV model

近年来,为有效应对全球能源危机和环境问题,电动汽车得以迅猛发展。锂离子电池因其能量密度高和循环寿命长等特点,成为电动汽车最主要的车

载电源<sup>[1]</sup>。其中,磷酸铁锂电池因较好的安全性而备受关注<sup>[2]</sup>。锂离子电池的荷电状态(state of charge, SOC)反映电池的剩余容量<sup>[3]</sup>,是电池管理系统中一

收稿日期: 2024-01-09

基金项目: 国家自然科学基金(51567012)

作者介绍: 陈贵升(1979—),男,重庆市人,博士,主要研究方向为车辆/航空动力系统高效利用技术开发。

通信作者: 肖仁鑫

个关键指标。准确的SOC估计可以避免过充或过放造成的电池损坏,从而延长其使用寿命<sup>[4]</sup>。由于锂离子电池的SOC不可直接测量得到<sup>[5]</sup>,为了实现精确的SOC估计,国内外已经研究了大量SOC估计方法,包括电化学模型<sup>[6]</sup>、黑箱模型<sup>[7]</sup>和等效电路模型<sup>[8]</sup>等。其中,电化学模型使用了大量的非线性方程,求解难度大,求解时间长;黑箱模型需要大量的样本数据进行长时间的训练,其精度受训练数据和策略的影响较大;而等效电路模型采用电路元件来表达电池的 electrochemical 特性,因其较少的参数和较高的精度,广泛应用于锂离子电池的SOC估计<sup>[9]</sup>。由于锂离子电池是一个高度非线性的系统,因此基于等效电路模型进行SOC估计需要通过非线性算法来实现,如扩展卡尔曼滤波<sup>[10]</sup>、无迹卡尔曼滤波<sup>[11]</sup>和自适应扩展卡尔曼滤波(adaptive extended Kalman filter, AEKF)<sup>[12]</sup>等。其中,AEKF算法由于能够自适应地调节过程噪声和测量噪声的协方差,对噪声具有较强的鲁棒性<sup>[13]</sup>,能够更好地实现锂离子电池的SOC估计。在基于等效电路模型的SOC估计方法中,锂离子电池开路电压(open-circuit voltage, OCV)与SOC之间的关系曲线(OCV曲线)是影响SOC估计精度的核心因素。尤其磷酸铁锂电池的OCV曲线斜率较小,其SOC对OCV的变化更为敏感。

精确的磷酸铁锂电池OCV曲线通常利用静置法OCV测试或小电流OCV(low-current OCV, LO)测试获得。静置法OCV测试中,电池以一定放电倍率放电至选定的SOC,在充分静置后测量得到当前的OCV值。基于所得到的OCV测试点,通过函数拟合建立OCV曲线。为确保OCV的准确性,每个OCV测试点需要电池充分静置1~2 h,静置时间根据电池的类型和充放电倍率确定<sup>[13-14]</sup>。而LO测试通常将充满电的电池以小于1/20 C倍率的恒定电流放电,以获取连续的OCV数据。两种方法相比,静置法OCV测试获取的OCV测试点更为准确,但OCV曲线精度依赖测试点数量,非测试点区域精度取决于拟合函数,且需要耗费大量的时间进行测试;LO测试能够在较短时间内获取连续的OCV数据,但不够准确。

为解决OCV测试存在的缺点,已有研究将两种测试相结合,提高OCV曲线精度。来鑫等<sup>[15]</sup>将LO测试获取的连续OCV数据向静置法获得OCV点平移,对OCV曲线进行优化以提升高、低SOC区域的曲线精度。林加顺等<sup>[16]</sup>运用分段拟合和差分进化方法,将两种测试的OCV数据结合,获取优化OCV曲线,

并在磷酸铁锂电池上进行了验证。上述研究实质是通过LO测试获取OCV的变化趋势,通过优化算法解决静置法OCV测试无法准确获取非测试区OCV的问题,最终提高OCV曲线精度。当前的研究将两种OCV测试结合以获取准确的OCV曲线,但都需要耗费大量时间进行更多的OCV测试,忽略了LO测试耗时短的优势。

为更好地发挥锂离子电池LO测试耗时短的优势,降低研究与应用过程中的测试成本,本文提出一种OCV模型及其优化方法,并在磷酸铁锂电池上进行了验证。该方法基于LO测试得到的OCV数据,采用道格拉斯-普克(Douglas-Peucker, DP)算法和分段线性函数建立OCV模型,所获得的OCV曲线与测量数据差异较小。将OCV曲线上的4个OCV点作为变量,建立了其他OCV点的随动模型,使曲线能够运用粒子群优化(particle swarm optimization, PSO)算法进行优化。本文采用静置法OCV测试构建的OCV曲线作为参考,通过动态工况下的端电压估计误差对比,优化后的OCV曲线全局精度大幅提升,并采用AEKF算法进行SOC估计,进一步对模型精度进行验证。

## 1 锂离子电池模型

建立锂离子电池模型时,需同时考虑模型精度和复杂性。其中,Thevenin模型具有较好的精度,能够有效估计锂离子电池的端电压,且模型复杂度较低<sup>[17]</sup>。本文采用Thevenin模型来描述电池的动态特性。Thevenin等效电路模型如图1所示。




图1 锂离子电池 Thevenin 模型

根据电路原理,Thevenin模型数学方程<sup>[18]</sup>为:

$$\begin{cases} \dot{U}_p = -\frac{U_p}{C_p R_p} + \frac{I_L}{C_p} \\ U_t = U_{oc} - U_p - I_L R_0 \end{cases} \quad (1)$$

式中: $R_p$ 为极化内阻; $C_p$ 为极化电容; $U_p$ 为 $R_p$ 的端电压; $R_0$ 为内阻; $U_t$ 为端电压; $U_{oc}$ 为开路电压; $I_L$ 为负载电流。

Thevenin模型的离散形式为:

$$\begin{cases} U_{p,k} = U_{p,k-1} e^{\frac{\Delta T}{C_p R_p}} + I_{L,k-1} R_p (1 - e^{\frac{\Delta T}{C_p R_p}}) \\ U_{t,k} = U_{oc,k} - U_{p,k} - I_{L,k} R_0 \end{cases} \quad (2)$$

式中:  $\Delta T$  为采样周期, 下标  $k$  和  $k-1$  为采样时刻。

## 2 OCV模型与优化方法

### 2.1 实验数据

本文采用的磷酸铁锂电池实验数据来自马里兰大学高级生命周期工程中心<sup>[19]</sup>。测试电池基本信息如表1所示。

表1 锂离子电池基本信息

类型	额定电压/V	额定容量/Ah	截止电压/V	最大电流/A	使用温度/°C
LiFePO <sub>4</sub>	3.3	1.1	2.0/3.6	30	0~50

### 2.2 LO测试与OCV模型

在LO测试中, 先以恒压恒流将电池充满, 然后以  $1/20 C$  倍率放电, 直至电池电压降低至截止电压 (2.0 V), 期间以 5 s 为间隔测量电压。如式(3)所示, SOC以安时积分法计算得到, 则基于LO测试可以获得SOC与OCV的关系数据。采用DP算法进行OCV测量数据简化, 得到少数OCV数据点, 以分段线性函数建立OCV模型, 最终得到OCV曲线。

$$SOC = C_0 - \frac{\eta \int_0^t Idt}{C_n} \quad (3)$$

式中:  $I$  为电流;  $t$  为时间;  $C_n$  为电池容量;  $C_0$  为初始SOC;  $\eta$  为充放电效率。

DP算法是最常用的曲线简化方法之一, 连接曲线端点获得直线, 将曲线上每一数据点到直线的距离 $d$ [如式(4)所示]与预设的阈值 $\varepsilon$ 相对比。当最大距离 $d$ 小于阈值 $\varepsilon$ 时, 删除两端点之间的数据点; 当最大距离 $d$ 大于阈值 $\varepsilon$ 时, 从最大距离的数据点处将曲线划分为两段, 并重复上述步骤。通过DP算法将曲线简化为通过较少数据点表达的近似曲线。

$$d = \left| \frac{\frac{y_2 - y_1}{x_2 - x_1}(x_i - x_1) - y_i + y_1}{\sqrt{\left(\frac{y_2 - y_1}{x_2 - x_1}\right)^2 + 1}} \right| \quad (4)$$

式中:  $x_1$ 、 $y_1$ 、 $x_2$  和  $y_2$  为曲线两端点坐标,  $x_i$  和  $y_i$  为两端点之间第  $i$  个数据点的坐标。

25 °C下LO测试的OCV数据及基于DP算法简化数据点建立的OCV曲线如图2所示。其中, OCV曲线采用式(5)所示分段线性函数建立。OCV曲线与测量数据的误差如图3所示, 最大误差为43.17 mV, 出现




图2 OCV测量值和OCV曲线




图3 OCV曲线误差

在接近0% SOC处, 绝对平均误差为0.903 mV。结果表明, 基于DP算法和分段线性函数建立的OCV模型与测量值误差较小, 具有较高的精度。

$$V = V_i + \frac{(V_{i+1} - V_i)(S - S_i)}{S_{i+1} - S_i}, \quad S_i < S < S_{i+1} \quad (5)$$

式中:  $V_i$  和  $V_{i+1}$  为两个相邻数据点的OCV;  $V$  为  $V_i$  和  $V_{i+1}$  之间的插值OCV;  $S$ 、 $S_i$  和  $S_{i+1}$  分别为  $V$ 、 $V_i$  和  $V_{i+1}$  对应的SOC。

### 2.3 OCV模型优化方法

为提高基于LO测试获取的OCV曲线精度, 采用PSO算法进行优化。选取图2中OCV曲线的2个端点和2个转折点作为4个优化变量, 并建立随动模型, 使其他OCV点能够在保持OCV变化趋势的情况下, 随4个变量OCV点的变化而变化。其中, 随动模型如式(6)所示。

$$\begin{cases} y_m(i) = \frac{Y_m(2) \times [y_{m-1}(i) - Y_{m-1}(1)] + Y_m(1) \times [Y_{m-1}(2) - y_{m-1}(i)]}{Y_{m-1}(2) - Y_{m-1}(1)} \\ x_m(i) = x_{m-1}(i) \end{cases} \quad (6)$$



式中:  $Y_{m-1}(1)$ 和 $Y_{m-1}(2)$ 为两个相邻变量  $OCV$ 点变动前的  $OCV$ 值,  $Y_m(1)$ 和 $Y_m(2)$ 为变动后的  $OCV$ 值;  $y_{m-1}(i)$ 为相邻变量  $OCV$ 点之间第  $i$ 个  $OCV$ 点随动前的  $OCV$ 值, 而  $y_m(i)$ 代表  $y_{m-1}(i)$ 随变量  $OCV$ 移动后的  $OCV$ 值。

PSO算法是一种高效的随机搜索算法, 将每个潜在解看作是D维问题空间中的一个粒子, 通过粒子群在空间中飞行迭代, 搜索最优解。在包含  $n$ 个粒子的粒子群中, 第  $i$ 个粒子的位置与速度更新如式(7)所示:

$$\begin{cases} v_i = av_i + c_1r_1(P_{best,i} - x_i) + c_2r_2(G_{best} - x_i) \\ x_i = x_i + v_i \\ X_{min} \leq x_i \leq X_{max} \end{cases} \quad (7)$$

式中:  $x_i$ 和 $v_i$ 为第  $i$ 个粒子的位置和速度;  $a$ 为惯性系数;  $c_1$ 和 $c_2$ 为学习因子;  $r_1$ 和 $r_2$ 为0和1之间均匀分布的随机数;  $P_{best,i}$ 为个体极值, 是单个粒子搜索到的最优解;  $G_{best}$ 为群体极值, 是粒子群搜索到的最优解;  $X_{min}$ 和 $X_{max}$ 为搜索空间位置边界。

采用 PSO 算法以 4 个变量  $OCV$ 点和 Thevenin 模型参数作为优化变量, 以动态工况下端电压  $RMSE$  最小为优化目标, 同时实现  $OCV$ 曲线的优化和模型的参数辨识。优化与辨识模型如式(8)所示:

$$\begin{cases} \theta = [OCV_1, OCV_2, OCV_3, OCV_4, R_0, R_p, C_p] \\ RMSE = \sqrt{\frac{1}{N} \sum_{k=1}^N [M_k - E_k(\theta)]^2} \\ \arg \min \{RMSE\} \end{cases} \quad (8)$$

式中:  $\theta$ 为待辨识参数向量;  $OCV_1$ 、 $OCV_2$ 、 $OCV_3$ 和 $OCV_4$ 代表4个变量  $OCV$ 点的  $OCV$ 值;  $N$ 为样本数;  $M$ 为测量值;  $E(\theta)$ 为基于变量  $\theta$ 得到的估计值。

2.4 优化结果验证

由于静置法  $OCV$ 测试在电池充分静置后测量当前  $OCV$ , 获得的  $OCV$ 更为准确<sup>[3-5]</sup>。基于静置法获取的离散  $OCV$ 数据能够构建较高精度的  $OCV$ 曲

线<sup>[15-16]</sup>。为验证所提出的优化方法, 将基于静置法  $OCV$ 测试获取的  $OCV$ 曲线(静置  $OCV$ 曲线)作为参考曲线进行对比验证。

2.4.1 室温(25℃)下的对比验证

在图4所示的室温(25℃)美国联邦城市运行工况(federal urban driving schedule, FUDS)下, 根据2.3节所述优化方法对  $OCV$ 曲线进行优化, 并辨识了模型参数, 如表2所示。




图4 室温(25℃)FUDS动态工况电压曲线

表2 优化与辨识结果

OCV点优化				参数辨识	
OCV	SOC/%	优化前 OCV/V	优化后 OCV/V	参数	值
OCV <sub>1</sub>	0.00	1.999 7	2.000 0	$R_0/\Omega$	0.164
OCV <sub>2</sub>	9.88	3.177 6	3.244 1	$R_p/\Omega$	0.159
OCV <sub>3</sub>	95.13	3.336 4	3.398 5	$C_p/F$	2 613.68
OCV <sub>4</sub>	100.00	3.497 4	3.482 3	—	—

室温(25℃)下静置  $OCV$ 测试的  $OCV$ 数据如表3所示, 通过式(5)构建静置  $OCV$ 曲线。  $OCV$ 曲线、优化  $OCV$ 曲线和静置  $OCV$ 曲线如图5所示。  $OCV$ 曲线和优化  $OCV$ 曲线的变化趋势一致, 但在10%~90%SOC区域的差值达到60 mV以上。优化  $OCV$ 曲线与静置  $OCV$ 曲线相比, 在高SOC和低SOC区域存在明显差异。基于3种  $OCV$ 曲线在FUDS工况下进行端电压估计, 如图6所示。

表3 室温(25℃)下静置OCV测试的OCV数据

参数	参数值												
SOC/%	0	5	10	20	30	40	50	60	70	80	90	95	100
OCV/V	2.655	3.132	3.265	3.294	3.326	3.350	3.355	3.365	3.369	3.391	3.398	3.401	3.485

如图6所示, 在FUDS工况下, 基于静置  $OCV$ 曲线和优化  $OCV$ 曲线的端电压估计误差更小。端电压估计的最大误差、绝对平均误差和  $RMSE$  如表4所示。基于优化  $OCV$ 曲线的端电压估计最大误差、绝对平均误差和  $RMSE$  最小, 分别为166.1、11.4和14.7 mV, 且与  $OCV$ 曲线相比, 绝对平均误差和  $RMSE$  分

表4 室温(25℃)下端电压估计误差 mV

OCV曲线	最大误差	绝对平均误差	RMSE
OCV曲线	180.3	69.2	70.0
静置OCV曲线	465.3	16.1	19.6
优化OCV曲线	166.1	11.4	14.7

别降低了83.5%和79%。可以看出优化后的  $OCV$ 曲线全局精度大幅提升, 且优于静置  $OCV$ 曲线。

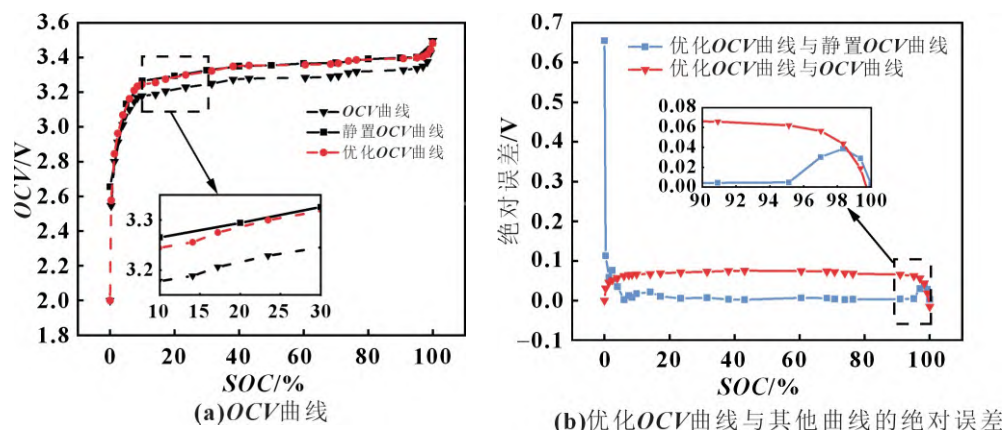


图5 25 °C下的OCV曲线、优化OCV曲线和静置OCV曲线

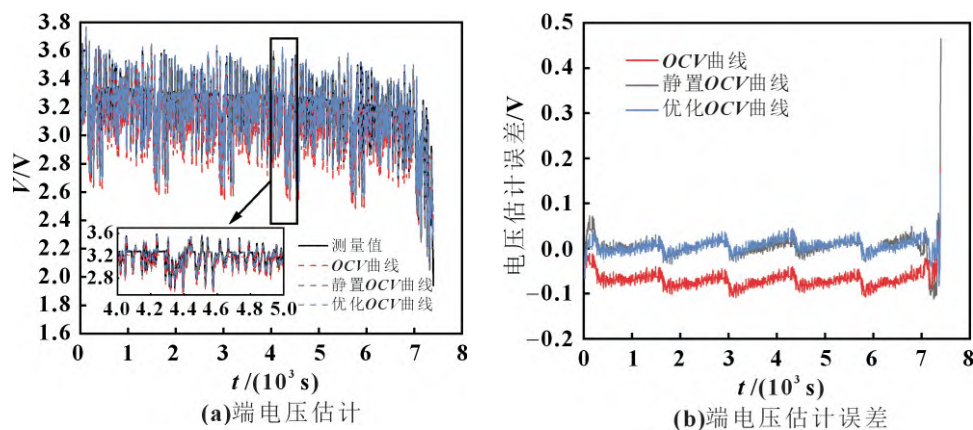


图6 FUDS工况下的端电压估计及其误差

#### 2.4.2 不同温度下的验证

由于不同温度下的OCV变化趋势较为一致,分别在0与50 °C的FUDS工况下,基于室温(25 °C)下的OCV曲线采用2.3节所述优化方法获取0和50 °C的优化OCV曲线和模型参数,如表5所示。

为更好地进行验证,同样将静置OCV曲线作为参考曲线进行对比。0和50 °C下的静置OCV曲线和

优化OCV曲线如图7所示,可以看出不同温度下2种OCV曲线呈现出相同的趋势,但在高SOC和低SOC区域同样存在显著差异。基于2种OCV曲线在FUDS工况下的端电压估计如图8所示,端电压估计误差如表6所示。在0和50 °C下,基于优化OCV曲线的端电压估计最大误差、绝对平均误差和RMSE均更小。结果表明,基于室温LO测试的OCV数据,采

表5 0和50 °C下的优化与辨识结果

变量OCV点优化				参数辨识		
变量OCV	SOC/%	OCV(0 °C)/V	OCV(45 °C)/V	参数	0 °C	50 °C
OCV <sub>1</sub>	0.00	2.020 3	2.053 7	$R_0/\Omega$	0.208 3	0.155 1
OCV <sub>2</sub>	9.88	3.139 5	3.211 3	$R_p/\Omega$	0.116 7	0.063 6
OCV <sub>3</sub>	95.13	3.350 3	3.376 0	$C_p/\text{F}$	3 409.4	1 976.9
OCV <sub>4</sub>	100.00	3.470 8	3.545 0	—	—	—

表6 0和50 °C下的端电压估计误差

$\theta/^\circ\text{C}$	OCV曲线	最大误差/mV	绝对平均误差/mV	RMSE/mV
0	静置OCV曲线	2 021.1	20.4	25.1
	优化OCV曲线	151.0	20.2	24.4
50	静置OCV曲线	426.5	11.5	14.9
	优化OCV曲线	58.2	6.7	9.5

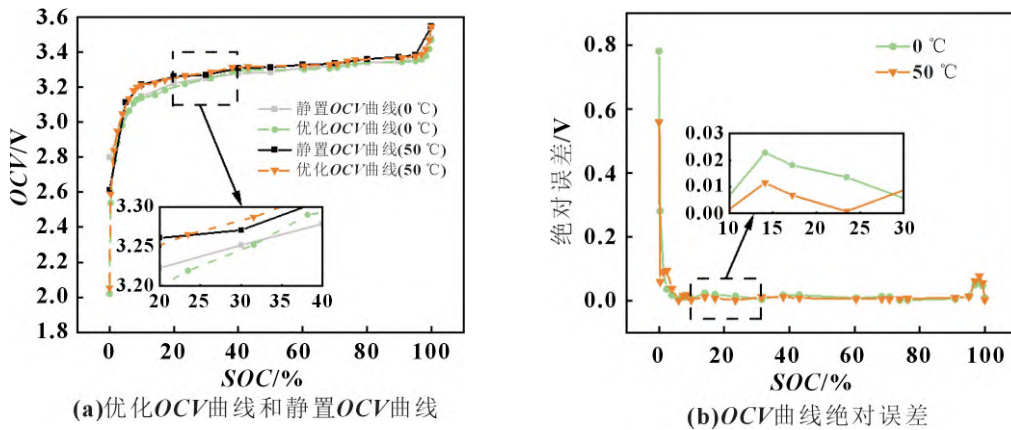


图7 0和50℃下的优化OCV曲线和静置OCV曲线

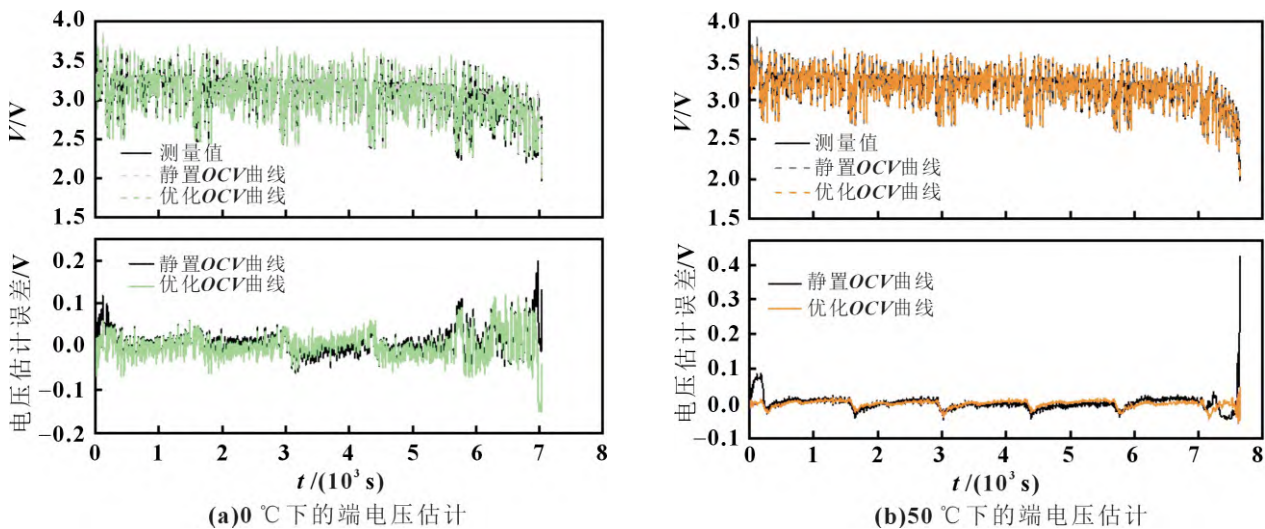


图8 0和50℃下的端电压估计

用所提出方法能够优化构建其他温度下较高精度的OCV曲线。

### 3 基于AEKF的SOC估计

在不同温度下基于静置OCV曲线和优化OCV曲线,采用AEKF算法实现磷酸铁锂电池的SOC,以进一步验证OCV模型优化结果。

#### 3.1 AEKF算法

本文采用AEKF算法进行SOC估计。非线性离散系统的状态空间模型可以表示为:

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_{k-1} + \mathbf{w}_k \quad (9)$$

$$\mathbf{y}_k = \mathbf{C}_k \mathbf{x}_k + \mathbf{D}_k \mathbf{u}_k + \mathbf{v}_k \quad (10)$$

式中: $\mathbf{x}_k$ 、 $\mathbf{u}_k$ 和 $\mathbf{y}_k$ 分别为系统 $k$ 时刻的状态变量、输入和输出; $\mathbf{w}_k$ 和 $\mathbf{v}_k$ 分别为过程噪声和测量噪声; $\mathbf{A}_k$ 为采样间隔内的传递矩阵; $\mathbf{B}_k$ 为输入矩阵; $\mathbf{C}_k$ 为输出矩阵; $\mathbf{D}_k$ 为前馈矩阵。

AEKF算法按以下步骤进行迭代:

(1)状态预测:

$$\mathbf{x}_k^- = \mathbf{A}_k \mathbf{x}_{k-1}^+ + \mathbf{B}_k \mathbf{u}_k + \mathbf{w}_k \quad (11)$$

式中: $\mathbf{x}_k^-$ 为 $k$ 时刻的先验估计; $\mathbf{x}_{k-1}^+$ 为 $k-1$ 时刻的后验估计。

(2)误差协方差预测

$$\mathbf{P}_k^- = \mathbf{A}_k \mathbf{P}_{k-1} \mathbf{A}_k^T + \mathbf{Q}_k \quad (12)$$

(3)卡尔曼增益计算

$$\mathbf{K}_k = \frac{\mathbf{P}_k^- \mathbf{C}_k^T}{\mathbf{C}_k \mathbf{P}_k^- \mathbf{C}_k^T + \mathbf{R}_{k-1}} \quad (13)$$

(4)状态更新

$$\mathbf{x}_k^+ = \mathbf{x}_k^- + \mathbf{K}_k (\mathbf{y}_k - \mathbf{C}_k \mathbf{x}_k^- - \mathbf{D}_k \mathbf{u}_k) \quad (14)$$

(5)协方差更新

$$\mathbf{P}_k^+ = \mathbf{P}_k^- - \mathbf{K}_k \mathbf{C}_k \mathbf{P}_k^- \quad (15)$$

(6)过程噪声与测量噪声的协方差更新

$$\mathbf{Q}_{k+1} = (1 - d_k) \mathbf{Q}_k + d_k [\mathbf{K}_k (\mathbf{e} \mathbf{e}^T) \mathbf{K}_k^T + \mathbf{P}_k^- - \mathbf{A}_{k-1} \mathbf{P}_{k-1}^+ \mathbf{A}_{k-1}^T] \quad (16)$$

$$\mathbf{R}_{k+1} = (1 - d_k) \mathbf{R}_k + d_k (\mathbf{e} \mathbf{e}^T - \mathbf{C}_k \mathbf{P}_k^- \mathbf{C}_k^T) \quad (17)$$

$$d_k = \frac{1 - b}{1 - b^k} \quad (18)$$

式中: $\mathbf{Q}$ 为过程噪声的方差; $d$ 为自适应因子; $d_k$ 为 $k$



时刻的自适应因子值; $P$ 为估计误差协方差; $R$ 为测量噪声的方差; $e$ 为预测值和测量值之间的误差; $b$ 为 $[0\ 1]$ 范围内的遗忘因子。

估计SOC时,以SOC和式(2)中的 $U_p$ 作为状态变量,电流 $I$ 和端电压 $U_t$ 分别作为输入和输出。则根据式(2)和式(3)可以得到式(19):

$$\begin{cases} A_k = \begin{bmatrix} 1 & 0 \\ 0 & e^{-\frac{\Delta T}{R_p C_p}} \end{bmatrix} \\ B_k = \begin{bmatrix} -\eta \frac{\Delta T}{C_n} \\ R_p (1 - e^{-\frac{\Delta T}{R_p C_p}}) \end{bmatrix} \\ C_k = \begin{bmatrix} \frac{\partial U_{OCV,k}}{\partial SOC_k} & -1 \end{bmatrix} \\ D_k = [-R_0] \end{cases} \quad (19)$$

### 3.2 基于AEKF算法的SOC估计

在0、25和50℃的FUDS动态工况下,基于Thevenin模型,采用AEKF算法进行磷酸铁锂电池SOC估计,并以静置OCV曲线作为参考,进一步验证所提出的OCV模型优化方法。不同温度下基于静置OCV曲线和优化OCV曲线的SOC估计及其误差分

别如图9(a)和(b)所示,SOC估计的最大误差、绝对平均误差和RMSE如表7所示。可以看出,基于2种OCV曲线的估计SOC都能够很好地跟踪参考SOC,而优化OCV曲线具有更好的精度优势。在0、25和50℃下,基于静置OCV曲线的SOC估计最大误差分别为0.881%、0.476%和0.852%,而基于优化OCV曲线的SOC估计最大误差分别为0.807%、0.404%和0.606%。最大误差均出现在低SOC区域,这是由于低SOC区域内锂离子电池等效阻抗增加,对于Thevenin等效电路模型则表现为模型参数( $R_0$ 、 $R_p$ 和 $C_p$ )的较大变化<sup>[20]</sup>,导致了辨识的模型参数精度降低。同时,实际的SOC与OCV关系在低SOC区域的非线性趋势更为显著,使OCV曲线精度降低,SOC估计的误差进一步凸显。在不同温度下基于优化OCV曲线的SOC绝对平均误差均小于0.3%,RMSE均小于0.35%,较静置OCV曲线误差更小。SOC估计结果表明,OCV模型优化方法能够基于室温LO测试的OCV数据获取不同温度下高精度的OCV曲线,降低锂离子电池研究与应用的测试成本,且适用于对OCV曲线敏感性较高的磷酸铁锂电池。

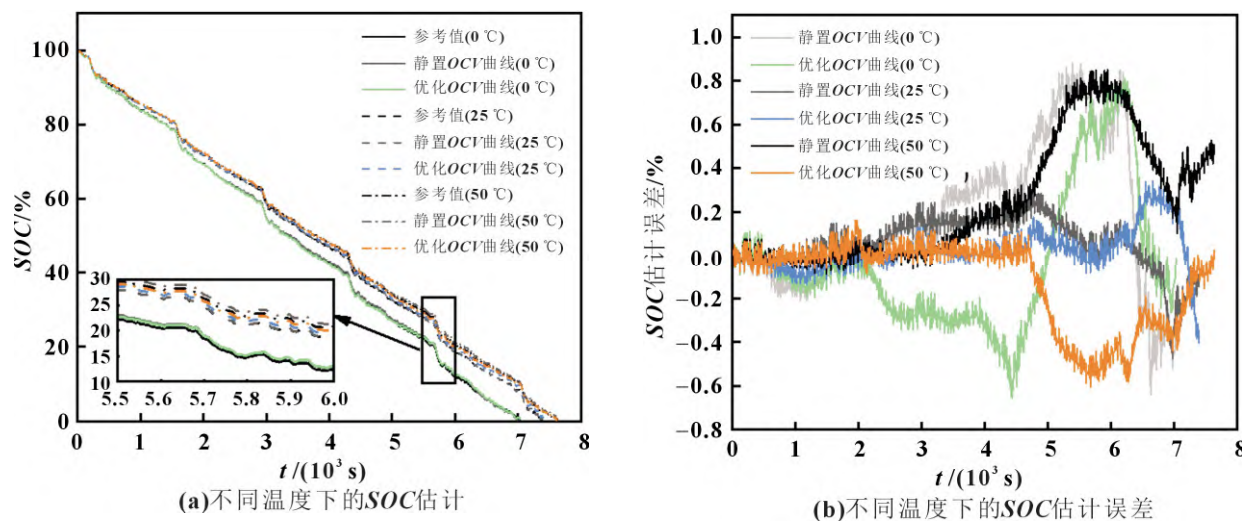


图9 不同温度下的SOC估计

表7 不同温度下的SOC估计误差

$\theta/^\circ\text{C}$	OCV 曲线	最大误差/%	绝对平均误差/%	RMSE/%
0	静置 OCV 曲线	0.881	0.279	0.370
	优化 OCV 曲线	0.807	0.251	0.320
25	静置 OCV 曲线	0.476	0.104	0.130
	优化 OCV 曲线	0.404	0.064	0.097
50	静置 OCV 曲线	0.852	0.246	0.360
	优化 OCV 曲线	0.606	0.145	0.230

## 4 结论

针对LO测试快速获取的磷酸铁锂电池OCV曲线误差较大的问题,本文提出一种OCV模型的构建与优化方法,提高OCV曲线精度。该方法能够通过室温下的LO测试快速获取不同温度下磷酸铁锂电池的高精度OCV曲线,降低锂离子电池研究与应用的测试成本,具有一定的应用价值。

(1)基于DP算法和分段线性函数建立OCV模型,所获取的OCV曲线与测量值的绝对平均误差为仅为0.903 mV,具有较高的精度。

(2)选取OCV曲线2个端点和2个转折点作为变量,建立了其他OCV点的随动模型,使OCV曲线能够运用PSO算法进行优化。优化OCV曲线全局精度大幅提升,相比OCV曲线,在FUDS工况下的端电压绝对平均误差和RMSE分别降低了83.5%和79%,且精度优于静置OCV曲线。

(3)在0、25和50℃,基于Thevenin模型和优化OCV曲线,采用AEKF算法的SOC估计最大误差分别为0.807%、0.404%和0.606%,不同温度下的SOC估计绝对平均误差小于0.3%,RMSE小于0.35%,与静置OCV曲线相比具有一定精度优势。SOC估计对比结果进一步验证优化OCV曲线具有较高精度。

## 参考文献:

- 王义军,左雪. 锂离子电池荷电状态估算方法及其应用场景综述[J]. 电力系统自动化, 2022, 46(14): 193-207.
- 余杰,廖思阳,徐箭,等. 考虑环境温度的磷酸铁锂电池SOC实时修正及频率控制方法[J]. 电工技术学报, 2023, 38(17): 4564-4573.
- XUAN D, SHI Z, CHEN J, et al. Real-time estimation of state-of-charge in lithium-ion batteries using improved central difference transform method[J]. Journal of Cleaner Production, 2020, 252: 119787.
- 刘耿峰,张向文. 动力电池管理系统设计及SOC实时在线估计方法[J]. 电源技术, 2022, 46(3): 329-334.
- 宋胜,李云伍,赵颖,等. 锂离子电池片段数据的荷电状态估计研究[J]. 电源技术, 2022, 46(7): 734-738.
- NIU X, GARG A, GOYAL A, et al. A coupled electrochemical-mechanical performance evaluation for safety design of lithium-ion batteries in electric vehicles: an integrated cell and system level approach[J]. Journal of Cleaner Production, 2019, 222: 633-645.
- 谢奕展,程夕明. 锂离子电池状态估计机器学习方法综述[J]. 汽车工程, 2021, 43(11): 1720-1729.
- XIAO R, HU Y, ZHANG W, et al. A novel approach to estimate the state of charge for lithium-ion battery under different temperatures incorporating open circuit voltage online identification[J]. Journal of Energy Storage, 2023, 67: 107509.
- 封居强,孙亮东,蔡峰,等. 基于双无迹变换的锂离子电池SOC估计研究[J]. 电源技术, 2022, 46(11): 1270-1274.
- CHEN C, XIONG R, YANG R, et al. State-of-charge estimation of Lithium-ion battery using an improved neural network model and extended Kalman filter[J]. Journal of Cleaner Production, 2019, 234: 1153-1164.
- 廖友萍,李睿,吕航,等. 基于EKF的钛酸锂电池SOC估计[J]. 电源技术, 2023, 47(5): 639-643.
- XIAO R, YANG Y, JIA X, et al. Collaborative estimations of state of energy and maximum available energy of lithium-ion batteries with optimized time windows considering instantaneous energy efficiencies[J]. Energy, 2023, 274: 127305.
- WU W, WU W, QIU X, et al. Low-temperature reversible capacity loss and aging mechanism in lithium-ion batteries for different discharge profiles[J]. International Journal of Energy Research, 2019, 43(1): 243-253.
- OUYANG D, WENG J, CHEN M, et al. Impact of high-temperature environment on the optimal cycle rate of lithium-ion battery[J]. Journal of Energy Storage, 2020, 28: 101242.
- 来鑫,李云飞,郑岳久,等. 基于SOC-OCV优化曲线与EKF的锂离子电池荷电状态全局估计[J]. 汽车工程, 2021, 43(1): 19-26.
- 林佳顺,周娟,吴乃豪,等. 一种高精度磷酸铁锂电池OCV-SOC曲线获取方法[EB/OL]. [2023-05-17]. <https://kns.cnki.net/kcms/detail/12.1420.TM.20230517.104.5.002.html>.
- ZHU Q, XU M, LIU W, et al. A state of charge estimation method for lithium-ion batteries based on fractional order adaptive extended Kalman filter[J]. Energy, 2019, 187: 115880.
- HE Z, LI Y, SUN Y, et al. State-of-charge estimation of lithium ion batteries based on adaptive iterative extended Kalman filter[J]. Journal of Energy Storage, 2021, 39: 102593.
- XING Y, HE W, PECHT M, et al. State of charge estimation of lithium-ion batteries using the open-circuit voltage at various ambient temperatures[J]. Applied Energy, 2014, 113: 106-115.
- ZHENG X, ZHANG Z. State of charge estimation at different temperatures based on dynamic thermal model for lithium-ion batteries[J]. Journal of Energy Storage, 2022, 48: 104011.