

# 基于多开路电压曲线结合 EKF 的 锂电池 SOC 融合估计

韦颖

(安徽三联学院 工学部, 安徽合肥 230601)

**摘要:** 准确估计电池的荷电状态 (state of charge, SOC) 对电动汽车具有重要意义。针对单一的锂电池开路电压曲线对基于模型 SOC 估计方法的局限性, 提出了一种应用多开路电压曲线结合扩展卡尔曼滤波的锂电池 SOC 融合估计方法。利用 SOC 与对应开路电压之间的离散数据, 通过多项式拟合和含有对数函数的复合函数拟合方式, 获得了两种开路电压曲线。分别基于这两种开路电压曲线并结合扩展卡尔曼滤波算法, 获得了各自的 SOC 估计结果。利用加权求和对获得的 SOC 进行融合, 得到最终的 SOC 估计结果。在动态应力测试工况和美国联邦城市驾驶工况下, 验证了所提方法的有效性。两种工况下, SOC 融合估计的平均绝对误差和均方根误差均出现了明显下降。

**关键词:** SOC 估计; 锂电池; 融合; 多开路电压曲线; EKF

**中图分类号:** TM912

**文献标志码:** A

**文章编号:** 1009-0312 (2024) 05-0076-07

DOI:10.16002/j.cnki.10090312.2024.05.018

传统燃油汽车的尾气排放对环境造成污染, 而新能源电动汽车的普及有助于“双碳”目标的实现。锂电池是电动汽车的主要动力源, 电池的荷电状态 (SOC) 能够反映剩余电量的多少, 对电池 SOC 进行有效监测显得至关重要<sup>[1]</sup>。一方面, 当得知电池电量不足时, 提醒驾驶员要及时充电, 避免电池因过度放电导致加速老化甚至损坏; 另一方面, 提供准确的 SOC 信息可以消除驾驶员对电池续航能力的焦虑。

锂电池的 SOC 不能直接测量得到, 只能通过测量电池的其他参数, 如电流、电压、温度等, 再利用适当方法估计得到。目前, 学者最关注的一类 SOC 估计方法是基于模型的 SOC 估计方法。这类方法主要依据电池的等效电路模型结合卡尔曼滤波算法完成对 SOC 的估计。例如, 文献 [2] 建立了 Thevenin (戴维宁) 等效电路模型, 利用扩展卡尔曼滤波算法实现了对特种机器人锂离子电池的 SOC 估计; 文献 [3] 以 (Partnership for a New Generation of Vehicles, PNGV) (新一代汽车合作计划) 模型作为锂电池等效电路模型, 结合无迹卡尔曼滤波算法完成了 SOC 的准确估计;

文献 [4] 采用二阶 RC 等效电路模型, 提出了一种加权多新息自适应扩展卡尔曼滤波算法, 实现了对锂电池 SOC 和容量的联合估计; 文献 [5] 提出了一种核极限学习机与容积卡尔曼滤波相融合的 SOC 估计方法, 并且利用递归最小二乘法实现了 Thevenin 等效电路模型中参数的在线更新, 有效减小了 SOC 估计误差。近年来, 分数阶电路模型及分数阶卡尔曼滤波算法也逐渐应用到锂电池的 SOC 估计<sup>[6-11]</sup>, 一定程度上改善了电池建模及 SOC 估计的精度。

确定以 SOC 为自变量的电池开路电压曲线 (函数), 是基于模型方法估计 SOC 的前提。然而, 现有的方法要么选择多项式拟合方式获得开路电压曲线, 要么选择复合函数拟合方式获得开路电压曲线, 并没有考虑不同的开路电压曲线获取方式对 SOC 估计的影响。实际上, 单一的锂电池开路电压曲线并不一定适用于所有的驾驶工况, 最佳的方案应该是让 SOC 估计方法能够根据实际驾驶工况自主选择开路电压曲线。为此, 本文提出基于多开路电压曲线结合扩展卡尔曼滤波算法 (Extended Kalman Filter, EKF) 的锂电池 SOC 融

收稿日期: 2024-03-15

基金项目: 安徽省高校自然科学基金项目重点项目 (2022AH051982, 2022AH051991); 安徽省高校学科 (专业) 带头人培育项目 (DTR2023062)。

作者简介: 韦颖 (1978—), 女, 安徽临泉人, 教授, 硕士, 主要从事动力电池管理系统研究, Email: weiyang8ths@sohu.com。

合估计方法, 将上述两种开路电压曲线综合考虑, 根据权重分配原则, 最终获得融合后的 SOC 估计结果, 该方法有效提高了 SOC 的估计精度。

## 1 锂电池建模及 EKF 算法

### 1.1 锂电池建模

选择含有两个 RC 网络的电路模型作为锂电池的等效电路模型, 如图 1 所示。两个 RC 网络, 一个用于模拟锂电池的电化学极化现象, 另一个用于模拟电池内部浓度差极化现象。

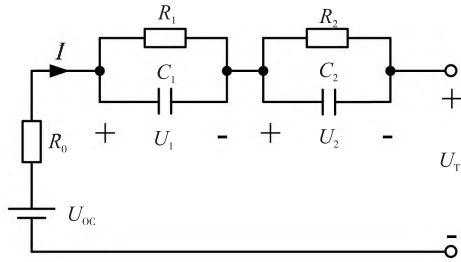


图 1 锂电池的二阶 RC 等效电路模型

根据图 1 所示的电路模型, 以 SOC、 $U_1$ 、 $U_2$  为待估计的状态变量, 建立锂电池等效电路模型的状态方程和测量方程, 表示为

$$\begin{cases} \begin{pmatrix} SOC_{k+1} \\ U_{1,k+1} \\ U_{2,k+1} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & e^{-\frac{T_s}{R_1 C_1}} & 0 \\ 0 & 0 & e^{-\frac{T_s}{R_2 C_2}} \end{pmatrix} \begin{pmatrix} SOC_k \\ U_{1,k} \\ U_{2,k} \end{pmatrix} + \begin{pmatrix} -T_s/C_N \\ R_1(1 - e^{-\frac{T_s}{R_1 C_1}}) \\ R_2(1 - e^{-\frac{T_s}{R_2 C_2}}) \end{pmatrix} I_k \\ U_{T,k} = U_{OC,k} - R_0 I_k - U_{1,k} - U_{2,k}, \end{cases} \quad (1)$$

式 (1) 中,  $U_1$  ( $U_2$ ) 为内部 RC 网络的端电压,  $U_T$  为电池的端电压,  $U_{OC}$  为电池的开路电压,  $R_0$  为电池内阻,  $I$  为电池的工作电流,  $C_N$  为电池的额定容量,  $T_s$  为电压电流的采样周期。各参数中的下标  $k$  表示第  $k$  个采样周期。

定义状态向量  $x_k = [SOC_k, U_{1,k}, U_{2,k}]^T$ , 输入  $U_k = I_k$ , 输出  $y_k = U_{T,k}$ , 则式 (1) 可变换为

$$\begin{cases} x_{k+1} = A_k x_k + B_k u_k = f(x_k, u_k) \\ y_k = C_k x_k + D_k u_k = g(x_k, u_k) \end{cases} \quad (2)$$

式 (2) 中,  $A_k = \text{diag}[1, e^{-\frac{T_s}{R_1 C_1}}, e^{-\frac{T_s}{R_2 C_2}}]$ ,

$$B_k = [-T_s/C_N, R_1(1 - e^{-\frac{T_s}{R_1 C_1}}), R_2(1 - e^{-\frac{T_s}{R_2 C_2}})]^T,$$

$$C_k = \left[ \left. \frac{dU_{OC}(SOC)}{dSOC} \right|_{SOC=SOC_k}, -1, -1 \right],$$

$$D_k = -R_0.$$

### 1.2 EKF 算法的 SOC 估计

首先, 建立 SOC 估计的 EKF 算法的状态方程 (3) 和测量方程 (4)

$$x_{k+1} = f(x_k, u_k) + w_k, \quad (3)$$

$$y_k = g(x_k, u_k) + v_k, \quad (4)$$

式 (3)、式 (4) 中,  $w_k$  和  $v_k$  分别是状态噪声和测量噪声, 并认为  $w_k$  和  $v_k$  是均值为零、方差分别为  $Q_k$  和  $R_k$  的白噪声。

然后, 初始化状态向量  $x_0$ 、误差协方差矩阵  $P_0$ 、状态噪声方差  $Q_0$  和测量噪声方差  $R_0$ 。

接下来, EKF 算法按照以下五个步骤不断迭代, 每迭代一次就获得一个时刻的 SOC 估计值, 直至迭代结束。

步骤 1, 预测状态:

$$\hat{x}_{k+1}^- = f(\hat{x}_k^+, u_k), \quad (5)$$

步骤 2, 预测误差协方差:

$$P_{x,k+1}^- = A_k P_{x,k}^+ A_k^T + Q_k, \quad (6)$$

步骤 3, 计算 Kalman 增益:

$$K_k = P_{x,k+1}^- C_k^T (C_k P_{x,k+1}^- C_k^T + R_k)^{-1}, \quad (7)$$

步骤 4, 更新状态向量:

$$\hat{x}_{k+1}^+ = \hat{x}_{k+1}^- + K_k (y_k - g(\hat{x}_{k+1}^-, u_k)), \quad (8)$$

步骤 5, 更新误差协方差:

$$P_{x,k+1}^+ = (I - K_k C_k) P_{x,k+1}^-, \quad (9)$$

式 (9) 中,  $I$  是单位矩阵。

## 2 SOC 融合估计方法

利用两个不同开路电压曲线结合 EKF 算法实现 SOC 融合估计的操作示意图见图 2。在电池建模与参数辨识的基础上, 利用开路电压曲线 1 结合 EKF 算法估计得到电池的 SOC, 标记为 SOC1, 利用开路电压曲线 2 结合 EKF 算法估计得到电池的 SOC, 标记为 SOC2; 之后对两路 SOC 进行融合, 最终得到电池 SOC 的估计结果。

利用加权求和的方式对 SOC1 和 SOC2 进行融合, 融合后的 SOC 可用式 (10) 表示:

$$SOC_k = SOC1_k \times W_{SOC1,k} + SOC2_k \times W_{SOC2,k}, \quad (10)$$

式 (10) 中,  $W_{SOC1,k}$  和  $W_{SOC2,k}$  分别为第  $k$  时刻 SOC1 和 SOC2 的权重系数。权重系数的确定对融合结果尤为重要, 考虑到电池端电压的预测误差 (即实测端电压与 SOC 估计算法预测的端电压之

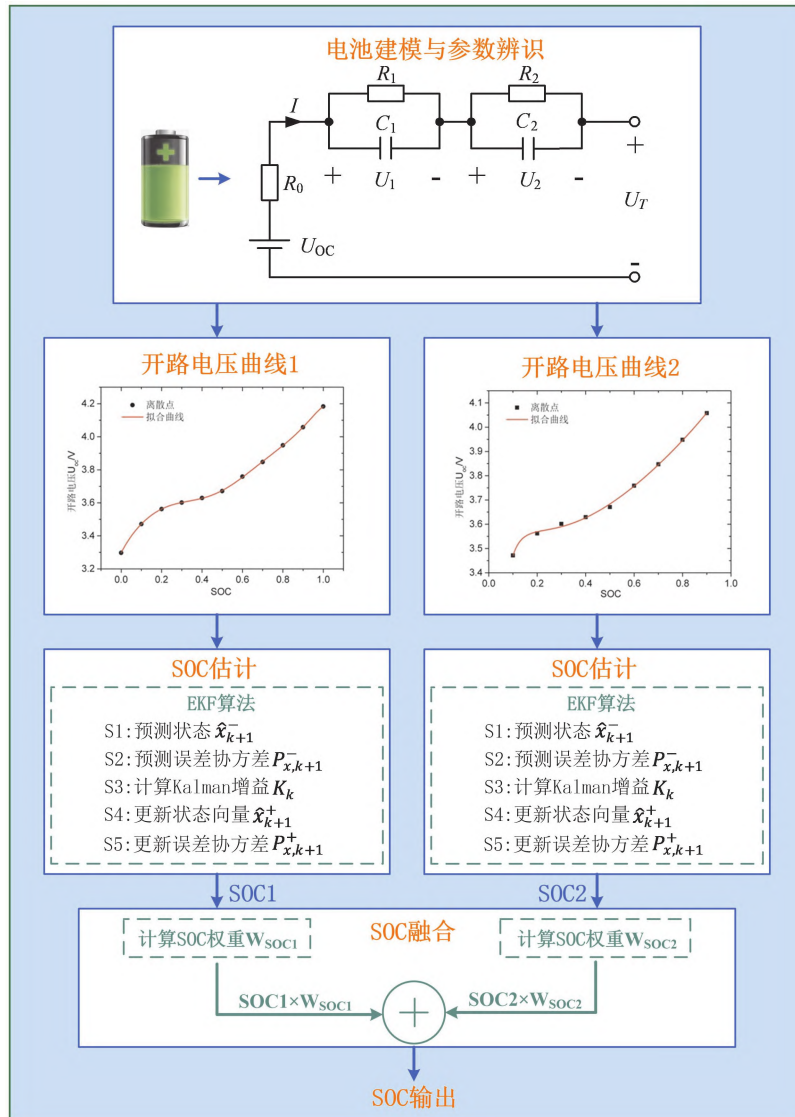


图2 SOC 融合估计操作示意图

间的差值)是衡量基于模型方法 SOC 估计结果准确性的重要参考,即 SOC 估计越准确,电池端电压的预测误差就越小。也就是说,在 SOC 融合时,电池端电压预测误差越小,其 SOC 的权重系数就应该越大,同时应满足所有权重系数的和为 1。基于这一准则,通过式 (11) 来计算 SOC 的权重系数:

$$\begin{cases} W_{SOC1, k} = \frac{\sum_{j=k-M+1}^k |\Delta v_{2, j}|}{\sum_{i=k-M+1}^k |\Delta v_{1, i}| + \sum_{j=k-M+1}^k |\Delta v_{2, j}|}, \\ W_{SOC2, k} = \frac{\sum_{i=k-M+1}^k |\Delta v_{1, i}|}{\sum_{i=k-M+1}^k |\Delta v_{1, i}| + \sum_{j=k-M+1}^k |\Delta v_{2, j}|}, \end{cases} \quad (11)$$

式 (11) 中,  $\Delta v_{1, i}$  为基于开路电压曲线 1 获得的

第  $i$  时刻电池端电压预测误差,  $\Delta v_{2, j}$  为基于开路电压曲线 2 获得的第  $j$  时刻电池端电压预测误差,  $M$  为误差截取窗口宽度,  $M$  取值越大,计算负担越重。

### 3 结果与讨论

#### 3.1 实验数据

文献 [12] 给出的开源数据链接网站提供了多种型号锂电池的实验数据,本文以型号为 INR18650-20R 的锂电池作为实验对象,其额定电压为 3.6 V、额定容量为 2 Ah、电池工作温度为 25℃。利用链接网站上提供的混合功率脉冲特性 (Hybrid Pulse Power Characteristic, HPPC) 工况数据来获取电池开路电压曲线以及完成电池模型的参数辨识,利用动态应力测试 (Dynamic

Stress Test, DST) 和美国联邦城市驾驶 (Federal Urban Driving Schedule, FUDS) 两种工况数据来验证所提方法的有效性和准确性, 所有实验数据的采样周期  $T_s$  均为 1 s。

3.2 开路电压曲线的获取

利用 HPPC 工况数据可以获得 11 组 SOC 与开路电压相对应的离散点数据, SOC 的变化步进为 0.1, 见图 3 (a) 中的实心点。根据式 (12) 和式 (13) 分别对这些离散数据点进行曲线拟合, 得到的开路电压曲线见图 3 (a) 和 (b) 中的红线。

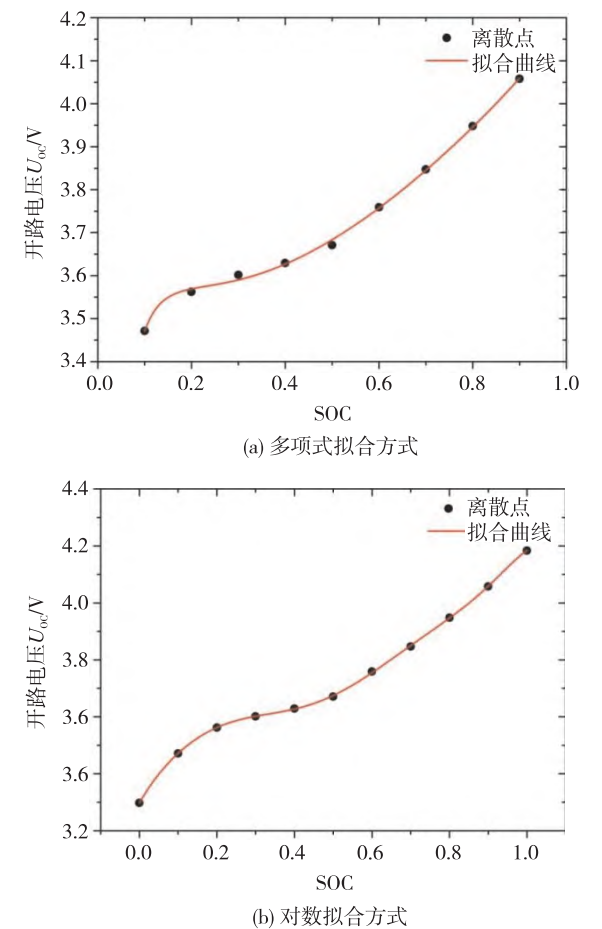


图3 两种拟合方式下的开路电压与 SOC 关系曲线

$$U_{oc}(SOC) = \sum_{i=0}^8 a_i (SOC)^i, \quad (12)$$

$$U_{oc}(SOC) = b_0 + b_1 SOC + b_2 (SOC)^{-1} + b_3 \ln(SOC) + b_4 \ln(1 - SOC), \quad (13)$$

式 (12) 和式 (13) 中,  $U_{oc}$  表示电池的开路电压,  $a_i (i=0, \cdots, 8)$  和  $b_j (j=0, \cdots, 4)$  是拟合系数。式 (12) 表示八阶多项式拟合方式, 简称为多项式方式; 式 (13) 表示含有对数函数的复合

函数拟合方式, 简称为对数方式。两种拟合方式得到的拟合系数见表 1。

表 1 开路电压曲线的拟合系数

多项式拟合系数	数值	对数拟合系数	数值
$a_0$	3.298	$b_0$	2.424
$a_1$	2.378	$b_1$	1.793
$a_2$	-8.841	$b_2$	-0.089
$a_3$	35.66	$b_3$	-0.763
$a_4$	-147.1	$b_4$	0.017
$a_5$	380.8	-	-
$a_6$	-523.5	-	-
$a_7$	357.7	-	-
$a_8$	-96.06	-	-

3.3 模型参数的辨识

基于 HPPC 工况数据, 采用自适应遗传算法 (Adaptive Genetic Algorithm, AGA) 来辨识二阶 RC 等效电路模型中的 5 个参数:  $R_0$ 、 $R_1$ 、 $R_2$ 、 $C_1$  和  $C_2$ 。AGA 是一种基于生物进化的优化算法, 其操作流程见图 4。图 4 中的种群由若干个表示问题解的生物个体组成, 每个生物个体又由待辨识的模型参数  $R_0$ 、 $R_1$ 、 $R_2$ 、 $C_1$  和  $C_2$  这五个基因组成。通过个体的不断进化, 最终获得最优个体 (即模型参数), 使得模型输出电压与电池的实测端电压之间的误差达到期望。

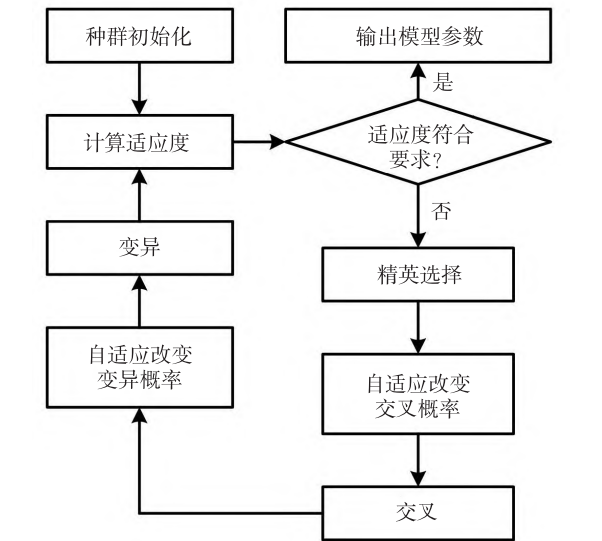


图4 AGA 算法操作流程图

AGA 算法辨识得到的锂电池二阶 RC 等效电路模型参数见表 2。图 5 给出了等效电路模型输出电压与实测端电压波形的对比, 两者较吻合。为了定量描述模型参数的准确性, 计算了模型输出电压与实测端电压两者之间的平均绝对误差 (Mean Absolute Error, MAE) 和均方根误差



(Root-Mean Square Error, RMSE), 计算结果见表 2。MAE 和 RMSE 分别只有 4.8 mV 和 6.2 mV, 说明辨识的模型参数是准确的。

表 2 AGA 算法辨识的电池模型参数及电压误差

$R_0/\text{m}\Omega$	$R_1/\text{m}\Omega$	$R_2/\text{m}\Omega$	$C_1/\text{F}$	$C_2/\text{F}$	MAE/mV	RMSE/mV
77.3	28.2	283.3	14 275	19 760	4.8	6.2





图 5 模型输出电压与实测端电压的对比

### 3.4 SOC 融合估计结果


按照图 2 所示的 SOC 融合估计操作流程, 利用多项式拟合获得的开路电压曲线和对数拟合获得的开路电压曲线, 结合 EKF 算法分别进行了 DST 工况和 FUDS 工况下的锂电池 SOC 估计。图 6 (a) 和 (b) 的上半部分给出了这两种工况下利用不同开路电压曲线获得的电池端电压预测结果, 可以看出两种工况下两种方式预测的端电压均与实测值接近。图 6 (a) 和 (b) 的下半部分所示是这两种工况下两种方式预测电压的误差对比, 它们的 MAE 和 RMSE 见表 3。无论是在 DST 工况还是 FUDS 工况下, 尽管多项式方式和对数方式的预测电压误差 MAE 和 RMSE 数值均非常接近, 但从误差曲线来看, 仍然存在一些差别, 这些差别将赋予融合算法不同的 SOC 融合权重。

表 3 DST 和 FUDS 工况下 SOC 估计结果和端电压预测误差

工况	方法	SOC 误差/%		端电压误差/mV	
		MAE	RMSE	MAE	RMSE
DST	多项式	1.72	1.90	4.9	7.0
	对数	1.82	2.55	4.9	6.9
	融合	1.20	1.46	-	-
FUDS	多项式	1.69	1.84	5.4	7.1
	对数	1.49	2.02	5.4	6.9
	融合	0.93	1.09	-	-



(a) DST工况



(b) FUDS工况

图 6 DST 和 FUDS 工况下电池端电压预测结果

利用图 6 (a) 和 (b) 下半部分所示的电压误差曲线, 根据式 (11) 计算得到两种工况下的 SOC 融合权重分别见图 7 (a) 和 (b)。从图 7 (a) 和 (b) 中可以看出, 两种工况下两种方式的 SOC 融合权重均以数值 0.5 为轴互补对称, 即满足权重之和为 1。对于 DST 工况, 在 4 000 ~ 6 000 s 时间段内, 多项式方式被赋予了更高的 SOC 融合权重, 说明此时间段对应的 SOC 与电池开路电压之间的关系曲线, 采用多项式拟合方式比采用对数方式更加精确。而对于 FUDS 工况, 似乎两种方式的 SOC 融合权重分布比较均匀。通过计算发现, 在整个 FUDS 工况内, 多项式方式和对数方式的 SOC 融合权重平均值分别为 0.502 5 和 0.497 5, 尽管它们非常接近, 但融合操作仍然可能会改善 SOC 的估计效果。

图 8 (a) 和 (b) 给出了基于多项式拟合获得的开路电压曲线和基于对数拟合获得的开路电压曲线, 结合 EKF 算法估计得到的 DST 工况和 FUDS 工况下的电池 SOC。利用各自的 SOC 估计结果和图 7 (a)、(b) 所示的 SOC 融合权重, 根据式 (10) 计算得到融合后的 SOC 结果及误差曲线见图 8 (a) 和 (b) 中的橙色线条, 融合估计的 SOC 误差 MAE 和 RMSE 见表 3。可以看出, 融合后的 SOC 曲线更加接近真实 SOC。在 DST 工况

下, SOC 误差 MAE 值分别从多项式方式的 1.72% 和对数方式的 1.82% 下降到 1.20%, RMSE 值分别从多项式方式的 1.90% 和对数方式的 2.55% 下降到 1.46%。同样, 在 FUDS 工况下, 融合估计的 SOC 误差 MAE 和 RMSE 也都出现了明显的下降。这些实验结果表明, 所提的 SOC 融合估计方法有效降低了 SOC 估计误差, 提高了 SOC 估计的准确性。

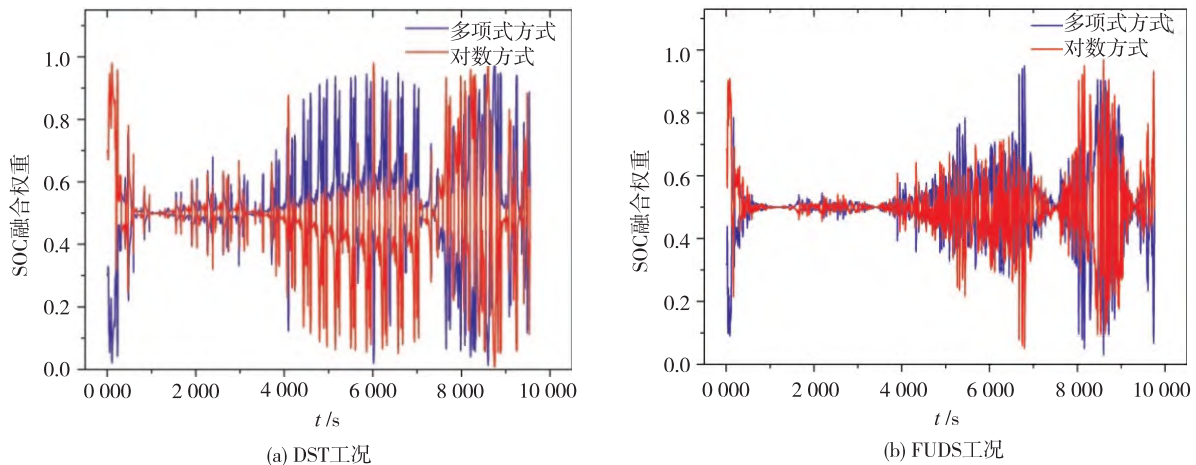


图 7 DST 和 FUDS 工况下 SOC 融合权重

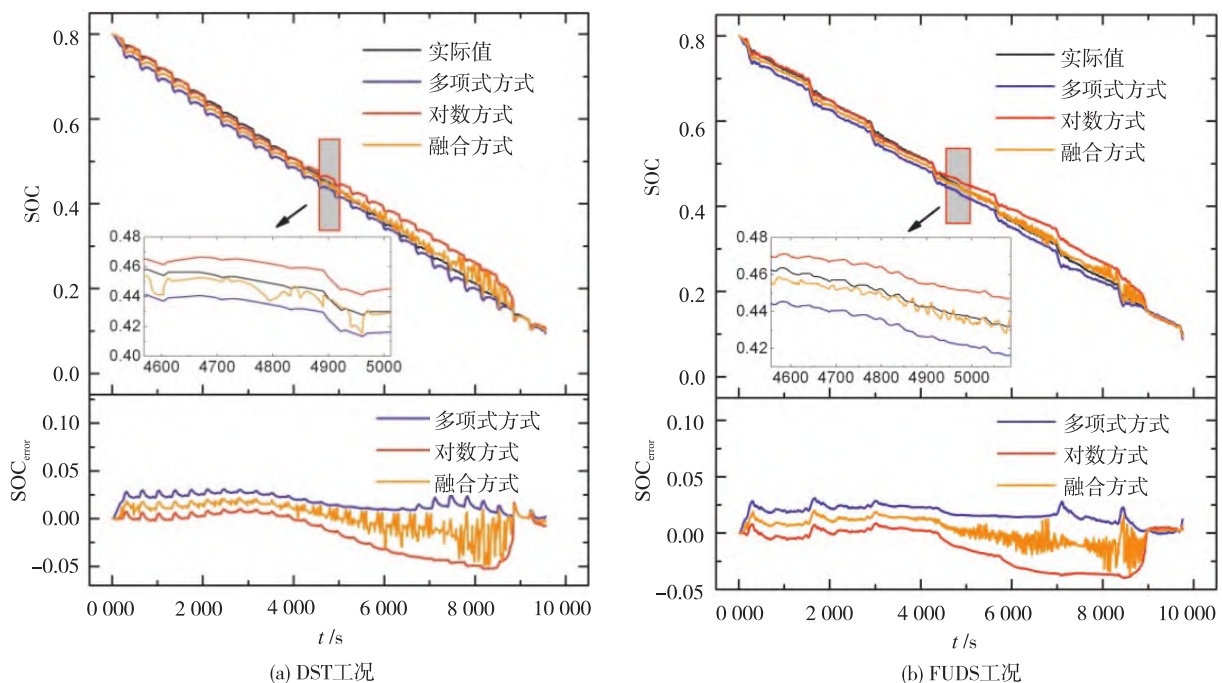


图 8 DST 和 FUDS 工况下 SOC 估计及融合结果

## 4 结语

以 SOC 为自变量的电池开路电压曲线 (函

数) 的选择, 对基于模型的 SOC 估计方法来说至关重要, 任何一种开路电压曲线对所有驾驶工况的锂电池 SOC 估计的适用能力都是有限的。利用多种开路电压曲线进行 SOC 融合估计, 可以有效

提高 SOC 的估计精度。本文仅使用了常规的 EKF 算法对 SOC 进行估计,旨在阐述 SOC 融合估计的思想以及证明其有效性。可以通过利用更加复杂

的卡尔曼滤波算法,结合模型参数在线辨识等手段来进一步提高 SOC 融合估计的精度。

### 参考文献

- [1] SELVARAJ V, VAIRAVASUNDARAM I. A comprehensive review of state of charge estimation in lithium-ion batteries used in electric vehicles [J]. J Energy Storage, 2023, 72(11): 108777.
- [2] 熊然,王顺利,于春梅,等. 基于 Thevenin 模型和改进扩展卡尔曼的特种机器人锂离子电池 SOC 估算方法[J]. 储能科学与技术, 2021, 10(2): 695-704.
- [3] ZHOU H, WANG S, YU C, et al. Research on SOC estimation for lithium ion batteries based on improved PNGV equivalence model and AF-UKF algorithm[J]. Int J Electrochem SC, 2022, 17(8): 220836.
- [4] 顾乃朋,王亚平,杨驹丰,等. 基于 WMIAEKF 的锂离子电池 SOC 与容量联合估算[J]. 电源技术, 2024, 48(1): 134-142.
- [5] 刘世林,李德俊,姚伟,等. 基于核极限学习机与容积卡尔曼滤波融合的锂电池荷电状态估计[J]. 湖南大学学报(自然科学版), 2023, 50(10): 51-59.
- [6] 赵靖英,胡劲,张雪辉,等. 基于锂电池模型和分数阶理论的 SOC-SOH 联合估计[J]. 电工技术学报, 2023, 38(17): 4551-4563.
- [7] 张梦龙,凌六一,官兵,等. IAGA 辨识分数阶模型与 FOAEKF 算法的锂电池 SOC 估计[J]. 电源技术, 2022, 46(6): 638-642.
- [8] XU Y, HU B, WU T, et al. Joint estimation of state of charge and state of health of lithium-ion battery based on fractional order model [J]. J Power Electron, 2022, 22(2): 318-330.
- [9] ZHU Q, XU M, LIU W, et al. A state of charge estimation method for lithium-ion batteries based on fractional order adaptive extended kalman filter [J]. Energy, 2019, 187(11): 115880.
- [10] CHAI H, GAO Z, JIAO Z, et al. State of charge estimation for lithium-ion batteries based on an adaptive fractional-order cubature kalman filter with initial value compensation [J]. J Energy Storage, 2023, 68(9): 107544.
- [11] WU J, FANG C, JIN Z, et al. A multi-scale fractional-order dual unscented kalman filter based parameter and state of charge joint estimation method of lithium-ion battery [J]. J Energy Storage, 2022, 50(6): 104666.
- [12] ZHENG F, XING Y, JIANG J, et al. Influence of different open circuit voltage tests on state of charge online estimation for lithium-ion batteries [J]. Appl Energy, 2016, 183(10): 513-525.

## SOC Fusion Estimation for Lithium Batteries Based on Multiple Open Circuit Voltage Curves Combined With EKF

WEI Ying

(Faculty of Engineering, Anhui Sanlian University, Hefei 230601, China)

**Abstract** Accurately estimating the state of charge (SOC) of batteries is of great importance for electric vehicles. To address the limitations of model-based SOC estimation methods using a single open circuit voltage curve, this paper proposes a lithium battery SOC fusion estimation method, which combines multiple open circuit voltage curves with extended Kalman filter. By using discrete data between SOC and corresponding open circuit voltage, two types of open circuit voltage curves are obtained through polynomial fitting and composite function fitting with logarithmic function. Based on these two types of open circuit voltage curves and combined with extended Kalman filter, their respective SOC estimation results are obtained. The SOC estimation results are finally achieved by using weighted summation to fuse respective SOC. The effectiveness of the proposed method is verified under the Dynamic Stress Test and Federal Urban Driving Schedule. Under these tests, both the average absolute error and root-mean square error of SOC fusion estimation have a significant decrease.

**Key words** SOC estimation; lithium batteries; fusion; multiple open circuit voltage curves; EKF