

AI 辅助先进电池设计与应用专刊



基于机器学习方法的锂电池剩余寿命预测研究进展

朱振威¹, 苗嘉伟², 祝夏雨¹, 王晓旭², 邱景义¹, 张 浩¹

(¹军事科学院防化研究院, 北京 100083; ²北京深势科技有限公司, 北京 100080)

摘 要: 随着技术的不断进步和成本的逐步降低, 锂电池在电动汽车、储能系统、便携式电子设备等多个领域实现了广泛应用, 有效促进了清洁能源的普及和能源结构的优化。掌握锂电池衰变和剩余使用寿命(RUL)对于确保设备稳定运行、提高能源利用效率以及保障用户安全至关重要。通过优化电池设计和使用策略, 可以延长锂电池的使用寿命, 降低更换成本, 进一步推动锂电池的规模化应用。锂电池的性能衰变是一个涉及多尺度化学、电化学反应的复杂过程, 涉及其内部从材料、界面到多孔电极、器件等诸多因素影响。各种机器学习(ML)的方法正是建模处理复杂数据、寻找规律、反馈应用的重要手段。本文针对锂电池 RUL 建模研究的科学问题, 综述了 ML 算法在预测电池 RUL 领域的最新进展, 重点介绍数据驱动的电池管理、预测建模以及利用 ML 方法来提高电池性能和寿命方面的突破。最后, 对当前领域内面临的关键问题进行了归纳总结, 以期提供一个基于 ML 算法的电池 RUL 预测技术的全面视角, 并展望其未来的发展趋势。

关键词: 电池管理系统; 电池剩余寿命; 寿命预测; 机器学习算法; 寿命延长

doi: 10.19799/j.cnki.2095-4239.2024.0713

中图分类号: TM 911

文献标志码: A

文章编号: 2095-4239 (2024) 09-3134-16

Research progress in lithium-ion battery remaining useful life prediction based on machine learning

ZHU Zhenwei¹, MIAO Jiawei², ZHU Xiayu¹, WANG Xiaoxu², QIU Jingyi¹, ZHANG Hao¹

(¹Chemical Defense Insititute, Beijing 100083, China; ²DP Technology, Beijing 100080, China)

Abstract: The performance degradation of lithium-ion batteries encompasses detailed processes at multiple scales, ranging from materials, interfaces, and porous electrodes to devices and involving complex chemical and electrochemical reactions. In recent years, informatics has emerged as a vibrant new field for the study of the degradation of lithium-ion batteries, and it intersects data science with battery materials science. These developments promise to accelerate the resolution of complex issues such as battery state modeling, performance management, and lifetime prediction. Various machine learning (ML) methods serve as crucial tools for modeling complex data, discovering patterns, and informing applications. This study focuses on modeling the remaining useful life (RUL) of lithium-ion batteries by reviewing the latest advancements for predicting the RUL of lithium-ion batteries based on ML. It presents breakthroughs by ML methods for data-driven battery management, predictive modeling, and enhanced battery performance and lifespan. Despite numerous

收稿日期: 2024-07-31; 修改稿日期: 2024-08-29。

基金项目: 国家自然科学基金 (22075320)。

第一作者: 朱振威 (1993—), 女, 博士, 助理研究员, 研究方向为化学电源, E-mail: zhenweizhu1@outlook.com; 通信作者: 张浩, 研究员, 研究方向为化学电源, E-mail: dr.h.zhang@hotmail.com。

引用本文: 朱振威, 苗嘉伟, 祝夏雨, 等. 基于机器学习方法的锂电池剩余寿命预测研究进展[J]. 储能科学与技术, 2024, 13(9): 3134-3149.

Citation: ZHU Zhenwei, MIAO Jiawei, ZHU Xiayu, et al. Research progress in lithium-ion battery remaining useful life prediction based on machine learning[J]. Energy Storage Science and Technology, 2024, 13(9): 3134-3149.

achievements in this field, several key challenges hinder its further development. Finally, this study summarizes the primary problem within the field at present, with the intent to provide a comprehensive perspective on ML-based battery RUL prediction and an outlook for future trends and directions.

Keywords: battery management system; remaining useful life; life prediction; machine learning algorithms; lifespan extension

随着规模储能、电动汽车用锂电池的循环寿命达到上千次、服役时间达到5年甚至8年以上,对锂电池的剩余寿命进行精准预测评估成为影响锂电池应用的重要科研方向。然而,锂电池性能衰变是涉及其内部从材料、界面到多孔电极、器件多尺度复杂化学、电化学反应的复杂过程。采用信息学的方法研究锂电池性能衰变、将数据科学与电池物质科学交叉是一个近年来蓬勃发展的新兴领域,有望推进电池状态建模、性能管理和寿命预测等复杂问题的加速解决。各种机器学习(machine learning, ML)的方法是建模处理复杂数据、寻找规律、反馈应用的重要手段。通过深度融合传统电池科学与前沿信息学技术,期望攻克电池管理系统(battery management system, BMS)中的一系列核心难题,诸如精准估算电池的充电状态(state of charge, SOC)、健康状态(state of health, SOH)、优化热管理策略及有效预测电池老化进程。BMS作为保障锂离子电池安全高效运行的关键系统,通过实时采集并分析电池的充电/放电循环、电压、电流、温度变化及潜在故障状态等多维度信息,为电池状态预测提供关键输入数据。理想的BMS系统应当能够不仅精准预测电池的SOH、SOC及剩余使用寿命(remaining useful life, RUL),还应具备高效的故障检测与诊断能力,从而全面提升电池系统的整体性能、可靠性及安全性。

文献中关于BMS参数预测(涵盖SOC、SOH、RUL及故障检测)的技术主要分为两大类:基于物理模型的方法和基于ML的方法。前者依托电池的电化学动力学原理构建模型,并基于这些模型做出假设以估算参数;而后者则主要利用BMS的输入输出数据集来训练多种模型,从而预测电池在特定输入条件下的状态。鉴于不同实验室测试条件的差异性,BMS预测任务所依赖的输入输出数据间自然存在差异,数据收集框架承担记录这些差异并基于电池或电池组模型生成额外数据的重任。至于电

池故障信息的获取,则更多依赖于实验测试的直接结果^[1]。对比而言,基于物理模型的方法因需深入探究电池系统的基本物理和化学特性,其开发过程相对漫长且复杂,可能难以面面俱到且耗时较多。数据驱动的方法通过ML算法从海量数据中学习规律,这一过程在开发效率上往往更具优势。然而,为数据驱动方法搜集高质量的数据集同样是一项充满挑战且可能耗时的任务。因此,在方法选择上仍然需综合考虑资源条件、精度要求及具体应用场景等多种因素,以做出最适宜的决策。值得注意的是,近期将电化学模型与数据驱动方法相结合,构建了一种混合模型,通过提供更为全面的电池动态性能,为设计更安全、更高效的电池系统开辟了新的路径^[2]。

近期的研究重点聚焦于利用数据驱动策略来优化BMS,寻找与电池容量衰减相关性更高的特征变量、探索性能更优的数模融合模型。通过收集电池组内各类传感器在电池服役全周期内的详尽数据,构建复杂的预测模型,以精准刻画电池在不同工况条件下的行为特性。其中,基于人工神经网络(artificial neural networks, ANN)的锂离子电池状态预测方法尤为表现出色。ANN最初构想为模拟人脑信息处理机制的计算机系统组件,现已发展成为一种强大的算法框架,其独特的从数据中学习并推广知识至新情境的能力,使得ANN在模式识别、优化及预测等多个领域均展现出广泛应用价值。在BMS领域,神经网络(neural networks, NN)的引入为解决传统技术难题开辟了新路径。以SOC的精确测量为例,传统的SOC估算方法,如安时积分法,常因测量误差、电池老化及温度变化等因素的干扰而使结果误差较大^[3-4]。相比之下,NN通过深度学习与电池各项指标间的复杂非线性关联,即便面对含噪声或不确定性的数据,也能有效提升BMS在参数估算上的可靠性与准确性,为电池管理策略的优化提供了坚实的数据支撑^[5]。

锂离子电池是目前最广泛使用的储能设备,对其RUL的准确预测对于确保其可靠运行和预防事故至关重要。本文综述了ML算法在RUL预测中的发展趋势,并探讨了未来的改进方向。此外,探讨了利用RUL预测结果延长锂离子电池寿命的可能性。首先介绍用于RUL预测的最常用的ML算法。然后,介绍了RUL预测的一般流程,及RUL预测中最常用的四种信号预处理技术。本文给出了常见ML算法准确性和特性方面的比较,并进一步展望了可能的改进方向,包括早期预测、局部再生建模、物理信息融合、广义迁移学习和硬件。最后,总结了延长电池寿命的方法,并展望了将RUL作为延长电池寿命指标的可行性。未来,可以根据在线RUL准确预测结果多次优化充电曲线,从而延长电池寿命。本文旨在为电池RUL预测和寿命延长策略的ML算法未来改进提供启示。

1 老化轨迹预测建模和仿真

准确预测锂离子电池RUL对其可靠运行和事故预防至关重要。通常,当电池的容量达到其初始值的80%时,视为处于寿命结束(end of life, EOL)^[6]。如果电池的使用超出了EOL标准,可能会导致用电系统性能不佳,有时甚至会引起灾难性事件。BMS可以参考RUL预测结果来控制电池的运行,帮助用户及时维护或更换电池^[7]。由于容量恶化和复杂的内部特性,RUL预测对于评估电动汽车退役电池同样很重要^[8]。基于电池早期循环数据的RUL预测可以减少老化测试的成本和时间,加速电池设计、生产和优化。

在讨论RUL预测方法之前,有必要明确RUL预测问题的定义。RUL预测主要分为两类:一类是预测电池达到EOL时的循环次数,另一类是预测剩余所有循环的剩余容量——即容量老化轨迹。这两类问题在输入输出和模型选择上往往有所不同。本文主要聚焦于第二类问题,即预测剩余所有循环的剩余容量或者SOH。这种方法不仅能提供电池何时达到EOL的信息,还能描绘出电池整个生命周期的容量衰减过程,为电池管理系统提供更全面、更细致的信息。

容量老化轨迹预测是一个更具挑战性的任务,因为它需要模型能够捕捉电池容量衰减的长期趋势和短期波动。这种预测通常需要处理长序列时间序

列数据,考虑多种影响因素,如充放电条件、环境温度、使用模式等。

1.1 RUL预测常用的机器学习算法

RUL预测的实现途径通常有基于物理的方法和数据驱动的方法,以及逐渐受到关注的将二者结合的数模混合方法。基于物理的方法包括电化学模型^[9]、等效电路模型^[10]和经验退化模型^[11]。物理模型基本都限定具体的电池材料、使用环境、充放电条件,参数一般都基于电极的物理性质,导致模型难以跟踪电池的动态变化,加之电池衰变因素复杂,也难以建立完善的衰变模型,为了实现较为可靠的预测数据,最终都要依赖大量的电化学模型和等效电路模型。而数据驱动的方法则较少依赖物理规律,更多是学习电池使用过程和实时的电性能数据。电池RUL预测的难点是如何根据有限的准确预测锂离子电池数百乃至数千周循环后的衰变特性。ML作为非线性建模方面表现出色的数据驱动方法,为锂离子电池RUL预测提供了不同于物理模型方法的有力的工具。如图1所示,在众多ML算法中,循环神经网络(recurrent neural networks, RNN),包括基本RNN、回声状态网络(echo status network, ESN)、长短期记忆网络(long short-term memory, LSTM)和门控循环单元(gated recirculation unit, GRU),已成为电池RUL预测的主流算法。此外,人工神经网络(ANN)中的经典前馈神经网络(feed forward neural networks, FFNN),作为非RNN和卷积神经网络(CNN)的补充,也发挥着重要作用。近年来,基于注意力机制的Transformer架构也逐渐成为RUL预测领域的热门选择,其优秀的长序列建模能力和并行计算效率使其在处理电池长期性能退化数据方面表现出色。

1.2 RUL预测的一般流程

基于ML的RUL预测的一般结构包括三个步骤,如图2所示,第一步,从电池老化测试中收集数据,并提取有效特征。电池老化特性可以通过充放电电压和电流、充放电时间、温度、内阻、循环圈数等常见的直接特征,以及等电压差时间间隔(time interval of an equal charging voltage difference, TIECVD)、增量容量分析(incremental capacity analysis, ICA)、差分电压分析(differential voltage analysis, DVA)和差分热伏安法

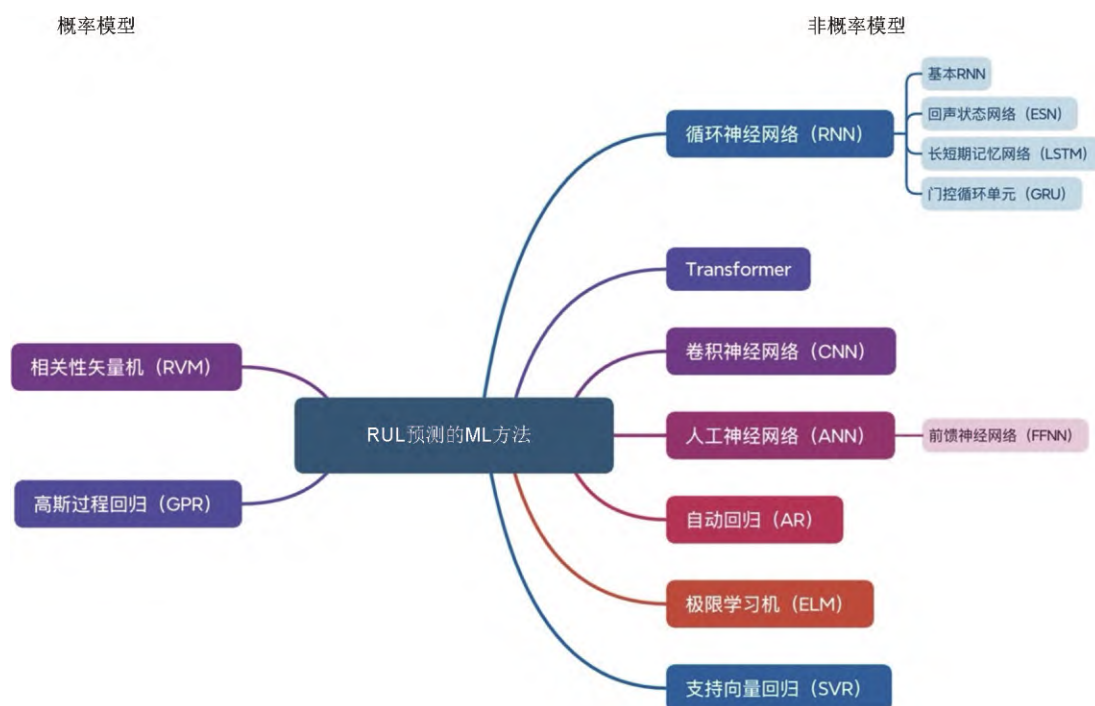


图1 RUL预测常用的机器学习算法

Fig. 1 The generally used ML algorithms for RUL prediction

(differential thermal voltammetry, DTV)的时序变化等间接特征反映^[12]。近年来,从电化学阻抗谱(electrochemical impedance spectroscopy, EIS)数据中提取特征作为ML算法的输入也逐渐成为主流。常见的EIS特征提取方法有三种:全面分析所有频率点的EIS数据、从EIS推导出的等效电路模型中提取参数以及聚焦于特定频率下的阻抗值^[13]。利用像ANN这样的ML方法从EIS中提取特征已被证明是一种高效且准确的手段^[14]。鉴于EIS对温度、SOC和弛豫效应的敏感性,这些参数在RUL预测中尤为重要^[15]。例如, Faraji-Niri等^[16]通过GPR模型和EIS测试,深入量化了温度和SOC对电池SOH估计精度的影响,强调了它们在模型构建中的不可或缺性。第二步,通过ML算法发现提取的特征与电池RUL之间的潜在关系。一种常见的策略是先利用模型估算SOH,再基于SOH的估计值进一步预测RUL,直至SOH降至预设的阈值以下。值得注意的是,尽管SOH估计与RUL预测在算法层面多有共通,但两者的输入变量存在显著差异。SOH预测倾向于直接利用与SOH紧密相关的特征,而RUL预测则更多依赖于电池的历史SOH记录或容量数据。例如, Severson等^[17]成功利用早期循环的放电电压曲线预测了124个快充磷

酸铁锂/石墨电池的循环寿命。第三步,模型评估阶段通过对比预测结果与实际测试数据,量化模型的性能表现。常用的评估指标包括绝对误差(absolute error, AE)、平均绝对百分比误差(mean absolute percentage error, MAPE)、均方误差(mean square error, MSE)、均方根误差(root mean square error, RMSE)、均绝对误差(mean absolute error, MAE)以及最大绝对误差(max absolute error, MaxAE)。详细评估标准确立途径则包括精确性、召回率、置信区间、及时性和稳定性。精确性衡量了模型预测为正类的样本中实际为正类的比例。在RUL预测中,可以设定一个阈值,将预测结果分为“即将失效”和“正常”两类,然后计算精确性。精确性高意味着模型在预测电池即将失效时,有较高的把握。召回率衡量了实际为正类的样本中被模型预测为正类的比例。在RUL预测中,召回率高意味着模型能够识别出大部分即将失效的电池。精确性和召回率之间往往存在权衡关系,需要根据具体应用场景进行调整。对于RUL预测来说,除了给出具体的预测值外,还需要提供预测的置信区间。置信区间表示了预测结果的不确定性范围,有助于决策者更好地了解预测结果的可靠性。及时性衡量了模型在预测RUL时是否

能够提前足够的时间给出预警。对于需要预防性维护的系统来说,及时性至关重要。稳定性评估了模型在不同数据集或不同时间点上预测结果的一致

性。稳定性好的模型能够更可靠地应用于实际场景中。这些指标共同构成了评估模型准确性和可靠性的重要依据。

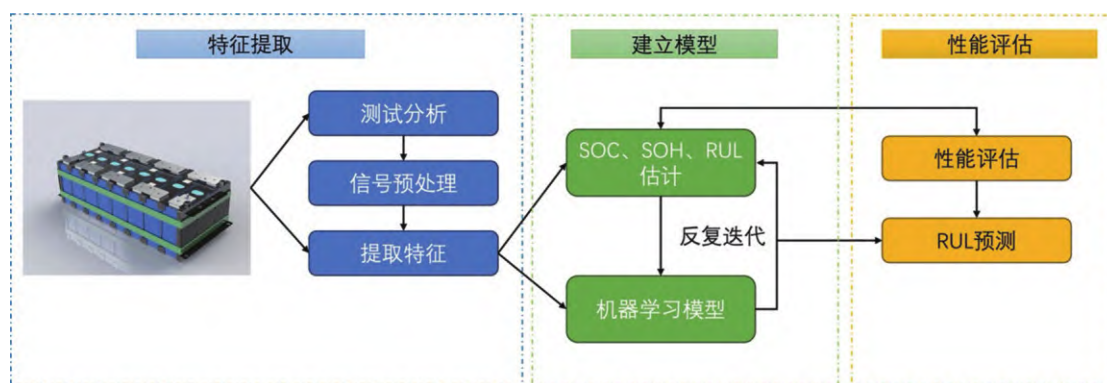


图2 基于ML的RUL预测的一般流程

Fig. 2 Process of RUL prediction based on ML

1.3 RUL预测中的信号预处理技术

对于电池的RUL预测,大多数研究主要关注电池的衰退曲线的趋势分析。相较于直接处理包含噪声的真实测试数据,从经过降噪处理的容量或SOH平滑曲线中提取RUL信息更为高效。信号预处理技术便是为了将特征曲线中的噪声和波动剔除。在RUL预测过程中,所选取的特征值往往与电池容量或SOH存在线性关联^[14],强化这种线性相关性成为提高预测速度和准确性的重要途径。当前,多种信号预处理技术被广泛应用于RUL预测,常见的有经验模态分解(empirical modal decomposition, EMD)、变分模态分解(variational modal decomposition, VMD)、Box-Cox变换(Box-Cox transform, BCT)以及小波分解技术(wavelet decomposition technique, WDT)等^[14]。VMD在NASA 5#电池的RUL预测,通过去噪处理,将预测准确率从78%提升至93%^[18]。Wang等^[19]利用WDT提出了一种直接基于分解后的端电压数据进行预测,进一步拓宽了WDT在RUL预测中的应用范围。作为小波变换的深化应用,小波包分解(wavelet packet decomposition, WPD)不仅能够处理低频带信号,还能对高频带信号进行细致分解,有效消除了充放电循环数据中的噪声干扰^[20]。该算法的主要思想是基于离散小波变换,在分解信号的每个电平中。Chen等^[21]则将WPD与信息熵理论相结合,提出了小波包能量熵(wavelet packet energy entropy, WPEE)理论,这一方法进

一步提升了RUL预测的准确性。

1.4 机器学习方法

机器学习算法大致可划分为非概率方法与概率方法两大类。支持向量回归(support vector regression, SVR)与自回归(autoregression, AR)等概率模型是在2012年首次被引入到电池RUL预测的研究中。非概率方法中,循环神经网络(RNN)与前馈神经网络(FFNN)自2013年起被广泛应用于电池RUL的预测,并迅速成为该领域的主流技术。

1.4.1 非概率方法

循环神经网络(RNN)算法其基本结构包含一个输入层,隐藏层和输出层[图3(a)],重量矩阵连接输入层和隐藏层,这种结构确保RNN可以使用过去和现在的信息预测未来。充放电循环中收集的电池老化数据为时间序列数据,非常适合作为RNN算法的输入来预测电池RUL。Kwon等^[22]使用RNN学习内部电阻实现电池RUL预测。Ansari等^[23]提高了RNN算法的输入数据维度,用每个周期的电压、电流和温度组成的数据集来预测RUL。RNN虽然能够准确获取时间依赖关系,但在处理长序列时容易出现梯度消失问题。处理某些复杂的序列数据时,随着隐藏层或单元数量的增加超过了模型容量,同样会加剧梯度消失的问题。

RNN算法还有很多变体,其中,回声状态网络(ESN)由于其结构简单[图3(b)],是一种快速高效的类型。长短期记忆网络(LSTM)使用独特的信息控制机制[图3(c)],解决RNN中消失梯度的问题。

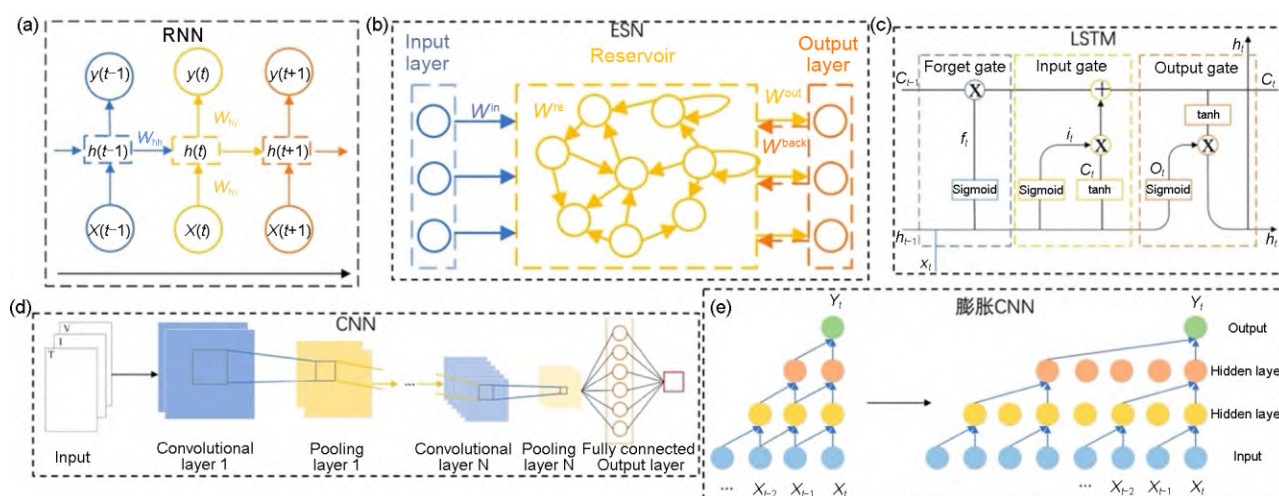


图3 (a) RNN的基本结构, x 是输入层, h 是隐藏层, y 是输出层, W 是权重矩阵。(b) ESN的基本结构, W 是权重矩阵。(c) LSTM的基本结构, x 、 h 、 C 是输入、输出和单元存储, Sigmoid是激活函数。(d) CNN的基本结构。(e) 常规卷积到膨胀卷积, x 是输入, y 是输出^[14]

Fig. 3 (a) The basic structure of RNN, where x represents the input layer, h represents the hidden layer, y represents the output layer, and W represents the weight matrix. (b) The basic structure of ESN, where W represents the weight matrix. (c) The basic structure of LSTM, where x , h , C represent the input, output, and cell state respectively, and Sigmoid refers to the activation function. (d) The basic structure of CNN. (e) Transition from regular convolution to dilated convolution, where x is the input and y is the output

门控循环单元(GRU)是LSTM的变体,它将LSTM的遗忘门和输入门集成到更新门中,并引入了额外的重置门来控制信息流。为预测锂离子电池RUL构建的RNN模型,以及变体LSTM、GRU,基于相同数据集进行预测时,LSTM效果最佳^[24]。LSTM通常与CNN结合,从数据中提取空间和时间信息。

Zhang等^[25]提出LSTM是为了捕捉长期电池老化趋势,却发现LSTM可以实现RUL早期预测,只需要整个电池衰变数据的20%~25%就可以实现RUL准确预测。Tong等^[26]也得出了类似的结论。在LSTM的输入功能中,一对一结构被多对一结构所取代^[27]。多对一结构是指同时使用多个输入向量,如电流、电压和温度。事实证明,即使在存在电池容量再生的情况下,多对一结构也可以提高RUL预测的准确性^[28]。Zhang等^[29]提出了一个结合LSTM和广泛学习系统(broad learning system, BLS)的模型,增加参数输入节点数,获取更多信息。通过采用自适应滑动窗口,LSTM可以同时学习局部波动和长期依赖性^[30]。通过结合多个模型的预测结果,集成学习可以减少耽搁模型的偏差和方差。Liu等^[31]使用贝叶斯模型集成LSTM模型,获得更高的预测准确性。Wang等^[32]提出了多层堆叠

LSTM的集成模型来预测RUL。Pan等^[33]提出了基于转移学习(TL-LSTM)的LSTM,以预测锂离子电池容量和不同工作条件下的RUL。

电池RUL预测中GRU的研究主要集中在基本应用、深度信息提取和传输学习上。GRU比LSTM具有更简单的结构,训练速度更快,同时能够缓解数据爆炸和梯度消失的问题。Song等^[34]利用GRU建立了电池RUL预测方法,其中隐藏层的数量为4个,NASA B0006电池上RUL预测的最大误差仅11个循环周期。Wei等^[35]使用GRU与Monte Carlo Dropout预测RUL,其中MC主要用于生成RUL预测点的概率分布和95%置信区间,以及隐藏层权重衰变避免过度拟合。Tang等^[36]利用双向门控循环单元(BiGRU)可以同时捕获过去和未来两个方向的电池容量信息,因此增加了特征信息的多样性。迁移学习可以减少在线应用程序的训练数据和训练时间,迁移学习和GRU的结合,以预测具有相似衰变趋势电池的RUL^[37]。

Transformer是一种深度神经网络架构,其核心完全基于注意力机制,这一特性使得它不仅能够高效处理并建模序列数据中的长期依赖关系,还具备并行处理数据的能力,这在处理大规模数据集时尤为重要。通过动态聚焦输入序列,Transformer

能够以较少的训练数据更有效地学习数据的内在特征^[38]。此外, Transformer模型的架构设计支持对输入序列的并行化处理显著加速了训练过程, 提高了模型的训练效率。基于Transformer的电池RUL预测模型, 在预测准确性和计算效率方面均超越了LSTM和GRU模型。拓宽了Transformer在预测性维护领域的应用前景^[39]。

支持向量回归(SVR)可以绘制输入和输出数据之间的非线性关系, 也适用于RUL预测^[40], 关键是将复杂的非线性问题转换为简单的线性问题。Zhao等^[41]利用SVR与特征矢量选择(feature vector selection, FVS)集成模型来预测RUL。RUL预测中关于SVR的研究主要集中在超参数优化和模型融合上。SVR在与粒子系统^[42]和卡尔曼滤波器^[43]结合作为测量方程, 可以实现前瞻性的预测。此外, SVR可以作为增强工具提高BiLSTM-AM模型的预测精度^[44]。SVR还与其他方法融合, 如基于加权原理的多层感知器(multi-layer perceptrons, MLP), 这些融合策略进一步拓宽了其应用范围。展望未来, SVR可能朝着更加精细化和定制化的方向发展, 例如, 利用包含训练数据特定区域的不同超参数的多个SVR组合, 采用混合内核功能的SVR可能成为一种趋势。此外, 针对车辆中央控制器中的具体应用环境, 特别是考虑到多变的负载条件, 对SVR算法的实现进行更深入的研究和优化^[45], 也将是未来值得探索的重要方向。

自动回归(AR)是一个时间序列模型, 擅长预测序列中即将发生的值, 尤其在捕捉时间序列长期趋势方面有显著优势。例如, Vilsen等^[46]使用AR来追踪电池内部电阻的长期变化模式。确定AR模型的阶数(即模型中的延迟项数量)对于预测精度至关重要。常见的确定方法包括Box-Jenkins方法、Akaike信息标准(Akaike information standards, AIC)和贝叶斯信息标准(Bayesian information standards, BIC)。为了进一步提升模型适应性, Long等^[47]引入了粒子群优化(particle swarm optimization, PSO)算法来搜索AR模型的最优阶数, 并通过计算均方根误差(RMSE)来评估不同阶数的效果, 并能根据新数据的引入自适应地调整模型阶数, 保证预测性能的稳定与提升。AR模型的研究焦点正逐渐转向电池非线性老化现象的建模以及不同算法的有效组

合策略, 这些探索旨在进一步提升模型在复杂时间序列数据上的预测能力和鲁棒性。

锂离子电池的老化过程是非线性的, 随着循环圈数增加, 其性能衰变速率通常会逐渐加快。为了提高AR模型在处理这种非线性老化现象上的能力, 引入了与老化周期及时效变化紧密相关的非线性加速老化因子。这一因子被设计为预测步骤的函数, 从而构建出非线性老化自回归(ND-AR)模型^[48]。Guo等^[49]进一步对ND-AR模型中的老化因子进行优化, 提出了基于非线性尺度老化参数的AR(NSDP-AR)模型。模型中, 降解因子与电池当前生命周期长度的百分比直接相关, 并通过扩展卡尔曼滤波技术精确求解相关参数, 以提升模型的准确性和适应性。此外, AR模型还常与不同的粒子滤波(particle filter, PF)方法相结合, 利用AR模型的预测输出作为PF中的观测或测量数据, 旨在优化PF的长期及迭代预测性能。这一思路不仅催生了ND-AR模型的应用, 还促成了迭代非线性降解自回归(IND-AR)模型的诞生^[50]。同时, 研究者们还探索了将AR模型与正则化粒子滤波(regularized particle filter, RPF)以及基于变形双指数经验降解模型的PF等高级算法相结合的可能性, 以进一步提升预测精度^[51]。在电池RUL预测中, PF通过模拟电池状态的概率分布来估计电池的剩余寿命。将双指数模型与PF结合, 可以利用PF的强非线性处理能力来更新双指数模型的参数, 从而更准确地预测电池的RUL。然而, 该方法面临模型复杂性、粒子贫化及数据依赖等挑战。为克服这些难题, 未来研究将聚焦于模型优化(如多因素耦合与混合模型)、算法改进(如自适应PF与多源数据融合)以及实验验证与评估(包括多样化数据集与量化评估指标), 以进一步提升电池RUL预测的准确性和可靠性。此外, Lin等^[52]将衰变轨迹视为多变点线性模型, 而非固定形态, 并借助带有协变量的AR模型来捕捉各段之间的斜率变化, 为锂离子电池的老化预测提供了新思路。

卷积神经网络(convolutional neural networks, CNN)架构, 典型的包含由卷积层、汇集层和完全连接层[图3(d)], 基本逻辑是通过过滤器卷积操作从输入数据中提取空间信息, 并利用池化层简化特征维度, 最终通过全连接层进行回归预测。CNN的核心优势在于其高效的空間信息提取与降维能力^[53]。在电池RUL预测领域, Hsu等^[54]利用双CNN

模型缩减数据维度, 结合人工特征提取, 通过深度神经网络 (deep neural networks, DNN) 实现了 6.46% 的 MAPE 电池 RUL 预测精度。Xiong 等^[55]则采用半监督学习方法, 直接将 EIS 数据输入 CNN 进行特征提取, 无需容量标签即可估算容量。目前, CNN 的研究热点聚焦于超参数优化、与 LSTM 的结合、膨胀 CNN 的应用以及迁移学习。超参数优化通过贝叶斯优化等方法提升模型性能。与 LSTM 结合, CNN-LSTM 模型能同时捕捉空间与时间信息, 显著提高 RUL 预测精度^[56]。Ren 等^[57]进一步引入自动编码器, 通过增加数据维度优化 CNN-LSTM 模型。Zhang 等^[58]则利用 CNN-LSTM 结合卷积循环生成对抗网络 (generate adversarial networks, GAN), 生成更贴近实际的时间序列数据, 减少预测误差。Yang 等^[59]则将 CNN 与双向 LSTM (Bi-LSTM) 结合, 提升学习效果与泛化能力。膨胀 CNN 通过增加层数实现接收域数量的指数级增长[图 3(e)], 有效提升模型捕捉长时间依赖的能力。Hong 等^[60]基于此提出五层膨胀 CNN 框架, 显著提升 RUL 预测表现。Zhou 等^[61]提出时间卷积网络 (temporal convolutional networks, TCN) 利用因果卷积与膨胀卷积技术, 提高局部容量再生现象的捕捉能力, 增强预测准确性。迁移学习为解决小数据集问题提供了有效途径。Shen 等^[62]通过预训练深度卷积神经网络 (deep convolutional neural networks, DCNN) 模型, 并将其参数迁移至目标域, 结合集成学习方法, 构建 DCNN-ETL 模型, 显著提升了 RUL 预测的准确性和鲁棒性。未来, 如何在有限数据集条件下实现快速稳定的 RUL 预测, 仍将是研究的重要方向。

极限学习机 (ELM) 作为一种前馈神经网络 (FFNN), 特色在于其仅含一层隐藏层, 位于输入与输出层之间。ELM 的隐藏层参数 (权重与偏差) 随机生成且无需训练, 仅输出权重需通过学习调整, 常用广义 Moore-Penrose 逆求解, 因此具备参数少、学习快的优势, 适合在线及快速 RUL 预测。在电池 RUL 预测领域, ELM 展现出出色的潜力。例如, 通过集成框架应对数据缺失时的 RUL 预测^[63], 利用两相维纳过程结合 ELM 捕捉锂电池老化特征^[64], 并引入粒子滤波^[65]、优化算法 (如 PSO^[66]、GAAA、HGWO^[18]) 优化初始参数以提升预测精度。然而, ELM 的浅层结构限制其在高维数据特征提取

能力, 难以应对大规模电池数据集。对此, BL-ELM 通过扩展隐藏层节点数而非增加层数, 显著增强了 ELM 处理大数据的能力。为缩短 RUL 预测时间, OS-ELM 被提出, 其利用新数据在线更新模型参数而非重新训练。Tang 等^[67]进一步开发了 OS-PELM, 通过引入卷积和池化操作优化连接结构, 提升训练效率。Fan 等^[18]提出的 FOS-ELM 是在 OS-ELM 基础上增加了遗忘机制, 自动剔除过时数据, 保持模型时效性。Zhang 等^[68]则基于深度学习方法, 提出了 CTC-ELM, 其设计灵感来源于 RNN 的时间变化处理, 但保持了 ELM 的快速学习优势。CTC-ELM 通过级联子网络, 每个子网络输入结合了前一输出与原始时间序列数据, 非常适用于小数据集场景。尽管 ELM 具有诸多优势, 其浅层结构仍是处理复杂数据集的瓶颈^[69]。

非概率方法的优点主要体现在计算复杂度低, 计算效率高, 能够快速给出预测结果, 适用于实时性要求较高的场景。相对于概率方法, 非概率方法对数据的需求通常较低, 能够在数据量有限的情况下进行预测。非概率方法的预测结果通常以具体的数值形式呈现, 便于直接理解和解释。非概率方法的缺点主要体现在, 非概率方法无法直接量化预测结果的不确定性, 这可能导致在某些应用场景下决策的风险增加。由于非概率方法通常基于较简单的数学模型或规则进行预测, 其泛化能力有限, 难以适应复杂的电池老化过程和多种影响因素。在面临高度非线性和不确定性的电池老化过程时, 非概率方法的预测精度有限。

1.4.2 概率方法

相关性矢量机 (RVM) 是一种基于贝叶斯框架的稀疏概率模型, 其结构类似于支持向量回归 (SVR), 但不受 Mercer 定理约束, 具有更高的灵活性。RVM 能利用不确定性表达优势, 集成多个内核函数, 且通过减少超参数和稀疏相关向量的数量来优化计算效率^[70]。在锂离子电池的剩余使用寿命 (RUL) 预测中, RVM 将特定周期内的容量衰变数据视为相关向量, 有效实现了数据降维^[71]。

在 RUL 预测模型中, RVM 常用于构建特征与电池容量之间的关系, 特征选择广泛, 如电流电压样本熵^[72]、充电过程中的电流变化率^[73]、充电时间、环境温度, 以及放电/充电电压差持续时间等。为提高预测精度, RVM 常与卡尔曼滤波器 (Kalman

filter, KF) 或无迹卡尔曼滤波器 (unscented Kalman filter, UKF) 集成使用, 如预测 UKF 残差演变^[74]或生成新的误差序列以校正预测结果^[75]。此外, RVM 还擅长融合不同预测方法的输出, 特别是当这些方法缺乏概率分布或预测起点不同时, RVM 通过提供输出的后验概率分布来增强整体预测的稳定性和准确性^[76]。RVM 的内核参数选择常依赖于经验, 但优化策略如人工鱼群算法 (artificial fish swarm algorithm, AFSA)^[77]和粒子群优化 (particle swarm optimization, PSO)^[78]等, 被用来寻找高斯内核函数的最佳参数, 以提升预测准确性。多重内核学习通过结合多个内核的优势, 并利用 PSO^[79]或网格搜索^[80]等方法优化其权重和参数, 进一步增强了 RVM 的性能。针对 RVM 在长期预测表现不佳的问题, 增量学习策略通过引入新在线数据样本并更新相关性向量和系数矩阵, 显著提高了多步预测精度^[81]。结合卡尔曼滤波器或 deep belief network 等方法, 进一步优化了长期预测的稳定性^[82]。此外, RVM 与灰色模型 (gray model, GM) 的交替使用, 考虑了容量再生的特性, 为 RUL 长期预测提供了新的思路^[83]。未来, 将 RVM 生成的相关向量与其他先进算法融合, 有望成为提升长期预测性能的重要途径。同时, RVM 的硬件实现研究也值得关注, 这将进一步推动其实际应用^[84]。

高斯过程回归 (Gaussian process regression, GPR) 作为一种非参数化且基于概率的建模方法, 其核心在于处理遵循高斯分布的随机变量集合。在 RUL 预测中, GPR 常通过提取如增量容量分析 (incremental capacity analysis, ICA) 曲线的峰值、面积、斜率等几何特征^[85-87], 以及电压依赖性^[88]和 EIS 频谱特征^[89]等, 作为输入数据来预测 RUL。研究人员致力于增强 GPR 的内核功能, 如结合电化学或物理定律 (如 Arrhenius 定律) 来优化协方差函数, 或修改基本平方指数函数以剔除无关输入, 从而显著提高预测精度^[90]。此外, 结合不同内核函数 (如平方指数与周期协方差函数) 的混合 GPR 模型, 也被证明能更全面地描述电池的老化模式, 包括再生现象^[91]。模型组合是另一项重要策略, 通过集成多个基于不同输入和内核函数的 GPR 模型结果, 来构建最终预测模型。例如, 利用 VMD 分解的剩余序列、时间指数等作为输入, 再结合滞后矢量等, 以捕捉全局趋势与局部波动^[92]。Li 等^[93]使用多

个指数和线性模型作为 GP 模型的趋势函数, 以反映锂离子电池在不同降解阶段的容量衰减。GPR 在 RUL 预测中的发展聚焦于内核功能的增强与模型组合的创新, 旨在实现更精确、更全面的电池健康状态评估。

概率方法的优点主要体现在, 能够量化预测结果的不确定性, 这对于需要高度可靠性的应用场景尤为重要。通过提供预测结果的概率分布, 用户可以更全面地了解电池 RUL 的可能范围。概率模型能够处理复杂的非线性关系和数据不确定性, 因此在面对复杂的电池老化过程和多种影响因素时表现出色。在基于概率的预测结果上, 可以进一步进行风险评估和决策分析, 为电池维护和管理提供更科学的依据。概率方法的不足主要体现在, 通常需要大量的计算资源来估计概率分布和进行模型训练, 因此计算复杂度高, 这在资源受限的环境下可能是一个挑战。为了获得准确的概率预测, 通常需要大量的高质量数据来训练模型。数据不足或质量不高可能导致预测结果的不准确。概率模型的结果往往以概率分布的形式呈现, 这可能导致对预测结果的直接解释较为困难。

2 RUL 预测方法的比较

从准确性和算法特征双重维度评估 ML 算法, 包括在线更新能力、不确定性量化、泛化能力及便捷性, 表 1 汇总了相关结果, 各算法均展现出高准确度。RVM 与 GPR 擅长不确定性量化且精度高, 但泛化较弱; RNN 与 CNN 在性能与信息提取上表现优秀; SVR 与 ELM 以其在线更新和预测迅速见长; AR 以其简单性、可接受的准确度和易实现性脱颖而出。然而, 每种算法在电池剩余使用寿命 (RUL) 预测中均存在局限。SVM 在处理长期依赖预测时易过拟合、不收敛, 尤其面对全寿命数据匮乏时^[96]; 其无法捕捉电池容量再生现象, 跨电池预测误差波动大^[95]。GPR 同样无法捕捉容量再生, 预测曲线可能与真实数据大相径庭, 如呈现直线形态, 导致 RMSE 偏高^[70]。RVM 适用的范围有限, 较短训练数据下预测 RUL 易失准。事实上, SVM、RVM 和 GPR 的内核函数设置对结果影响都很大, 如果设置不当, 预测结果必然偏离真实数据。AR 则缺乏长期记忆能力。ELM 预测误差较大^[41]; CNN 单独使用时预测偏差显著^[36]; LSTM 虽能预测老化

趋势，但速度较慢^[96]，且易受短期波动影响^[98]降低预测精度；因结构简化且依赖大量数据，GRU 预测误差高于 LSTM，数据不足时预测曲线趋于平直，无法实现 RUL 预测。

表1 不同ML方法在RUL预测方面的表现
Table 1 Performance of different ML methods in RUL prediction

年份	机器学习方法	参考文献	预测性能	电池类型	精度	备注
2021	RNN	[94]	容量	LCO/石墨(NASA 5#)	0.0030 RMSE	较好的泛化性能
2021	ESN	[95]	容量	LCO/石墨(NASA 5#)	3周	预测精度高，稳定
2021	LSTM	[27]	SOH	CALCE CS2-34#	0.0017 RMSE(1周)	不同电池不同工况下误差小，精度高
2021	GRU	[96]	容量	LCO/石墨(NASA 5#)	0.0156 RMSE	效率和精度都较高
2022	SVR-PSO	[97]	电压对时间的积分	LCO/石墨(NASA 5#)	0.0133 RMSE	高精度在线预测
2022	CNN	[54]	自定义	LFP/石墨(MIT)	6.46%MAPE	只需要一圈循环数据即可以实现预测
2022	CTC-ELM	[68]	容量	LCO/石墨(NASA, Oxford)	0.000036MES(NASA), 0.000001MES(Oxford)	高精度预测
2021	RVM	[76]	容量	LCO/graphite (NASA 5#)	0.0105 RMSE	具有长预测能力，预测稳定性高
2021	GPR	[87]	峰位置、峰高、峰面积	CALCE CS2-35#	5周	高精度，适配不同电池，预测实际变化曲线表现良好

物理模型和算法组合的数模混合模型不仅能反映电池的衰变的物理机制，还能从数据中获取电池 RUL 的实时信息和变化规律，在电池 RUL 预测中表现出更优越的性能，是当前和未来研究的重要方向。比如，建立双指数模型来描述锂电池退化，引入自适应卡尔曼滤波算法更新过程噪声和观测噪声的协方差，并使用遗传算法优化 SVR 的关键参数，最终实现 RUL 多步预测。结合自适应卡尔曼滤波、完全经验模态分解和 RVM，提出一种基于误差修正思想的锂离子 RUL 预测方法^[11]。此类融合方法需要仔细平衡模型的参数设置和数据的质量，过度依赖先验假设或数据也会造成模型性能下降。正如第 1 部分举的大部分例子完成一个可靠的训练，并不是仅仅靠单一的算法或模型，更多是通过加权或其他方式组合两种或多种数据驱动方法。数模融合以及多种算法组合可以有效弥补单一机器学习算法的不足，充分利用不同算法的优点，从而获得更好的性能。

3 电池延寿

RUL 预测不仅在于电池寿命评估，更核心目的在于辅助电池寿命延长。当前，主要的电池延寿策

略有：优化充放电控制、热管理、均衡及维护、故障的有效识别及必要管控、安全风险及时预警及抑制等。优化充放电控制通过精细管理电池的充放电过程，减少不必要的损耗，是延长电池寿命的基础。2023 年瑞典皇家理工学院 Strandberg 团队^[99]发现使用基于脉冲电流的充电协议时，锂离子电池的健康状况得到了明显改善。柏林洪堡大学 Philipp Adelhel 教授团队^[100]发现，通过优化循环条件，锂离子电池有望使用长达数十年。脉冲充电，其不仅促进锂离子在石墨中均匀分布，从而减少了石墨颗粒中的机械应力和裂纹，还能抑制 NCM523 阴极结构的退化。这将使电池可进行的充电周期数从恒定电流的大约 500 增加到 1000 以上。斯坦福大学崔毅团队^[101]最近发现了一种简单且低成本电池延寿策略，只需让电池耗尽电量并静置几小时，不仅能恢复电池容量，还能提升整体性能。

热管理策略通过维持电池工作在适宜的温度范围内，防止过热导致的性能下降和寿命缩短。均衡及维护策略确保电池组内各单体电池性能一致，防止因单体电池差异导致的整体性能衰退。故障的有效识别及必要管控能够及时发现并解决潜在问题，避免故障扩大影响电池寿命。而安全风险及时预警

及抑制策略则是通过实时监控和预警机制,降低电池使用过程中的安全风险。这些策略相辅相成,共同作用于电池系统,以实现更长的使用寿命、更高的安全性和更优的性能表现。在实际应用中,需要根据具体需求和场景灵活选择和组合这些策略,以达到最佳的延寿效果。Wu等^[102]通过电池/超级电容器混合系统,有效降低了城市行车中的电池容量衰减。

然而,多数研究尚未将RUL预测直接用于指导电池寿命延长实践。从用户视角出发,充电配置优化是延长电池寿命最为切实可行的方法,在不牺牲充电效能的情况下减少充电过程中的不可逆容量损失。研究表明,低频正脉冲电流(positive pulse current, PPC)充电相较于恒流(constant current, CC)充电能显著延长电池寿命^[103]。而由电池健康状态(SOH)决定的动态充电策略,如四阶段恒流(four-stage constant current, 4SCC)充电和多步快速充电协议,亦展现出延长寿命的潜力^[104]。此外,通过电化学模型优化传统恒流恒压(CC-CV)充电策略,同样能有效提升电池使用寿命^[105-106]。目前大多数方法在模型中都已经考虑了SOH。

RUL预测作为评估电池寿命延长效果的指标,结合贝叶斯优化等方法,能以较低成本筛选出最佳充电配置^[107]。进一步地,基于实时RUL预测动态调整充电策略,针对不同用户放电模式定制优化方案,是延长电池寿命的另一种思路。通过构建反映充电过程不可逆损失的电化学模型,优化算法可生成定制化充电曲线,并依据RUL预测结果持续迭代优化,直至达到预设的RUL上限,从而实现电池寿命的最大化延长。电池寿命预测为电池寿命延长提供了重要的数据支持。通过对电池寿命的准确预测,可以及时发现电池性能下降的趋势和潜在的安全隐患,从而有针对性地采取延寿措施。同时,电池寿命延长的实践也为电池寿命预测提供了宝贵的反馈和验证机会,有助于不断完善预测模型和方法。通过不断优化预测方法和延寿技术,可以进一步提升电池的使用效率和安全性,为新能源产业的发展提供有力保障。

4 前景和挑战

近年来,基于ML算法的RUL预测研究取得了显著进展,研究的重点聚焦于算法参数优化、结构

改进、寻找与电池容量衰减相关性更高的特征变量及探索性能更优的融合模型。审视当前研究,为推动领域发展,以下六个方面亟待加强。

(1) 提高RUL预测精度:关键在于构建全面且高质量的数据基础,涵盖电池全寿命周期的充放电电流、电压、温度等传感器数据,并通过精细的数据清洗与预处理,去除噪声与异常值。随后,通过特征工程与选择,运用统计方法或机器学习算法提炼出对预测至关重要的特征。在此基础上,采用多种机器学习算法构建预测模型,并通过交叉验证优选最佳模型,进而进行细致的模型训练与参数调优。模型的验证则依赖于独立的验证集及多种评估指标,确保模型的泛化能力与预测精度。实际应用中,持续更新模型以应对电池寿命变化,实现高精度预测。未来,深度学习技术如Transformer-LSTM与GRU神经网络,融合方法如粒子滤波与神经网络的结合,以及自适应滤波与Autoformer等先进模型的联合应用,均展现出强大的潜力,为RUL预测精度的进一步提升提供了广阔的技术路径。

(2) 早期预测能力:早期预测旨在利用有限的初始循环数据精准预测RUL,提前实现故障检测并减少资源消耗。尽管早期预测面临有效老化信息稀缺的难点,LSTM^[25]与CNN^[54]等算法已初步展现出潜力。早期预测的先决条件是有效提取数据特征,提升途径包括采用ML自动特征提取技术,减少对手动特征选择的依赖,并探索如广泛学习等新型ML方法以增强早期预测能力。

(3) 容量再生建模:容量再生是电池老化过程中的普遍现象,影响RUL预测准确性。研究表明,放电深度(depth of discharge, DOD)及高温容易加重容量再生现象^[108]。ML算法需具备学习容量再生特性的能力,RUL预测的准确性将进一步得到提高,特别是基于SOH估计的预测。当前,信号分解结合ML预测是主流方法,但未来应探索在整个老化周期内动态调整ML策略,即根据不同容量再生间隔采用最合适的算法,确保信息捕捉的全面性和准确性。

(4) 融合物理原理:物理原理与ML算法的深度融合展现出诸多优势,包括提升预测准确性、增强长期预测的稳定性,以及拓宽算法的泛化能力。当前,已有研究成功将物理学原理融入神经网络模

型^[109-110], 这一领域未来依然有很大探索潜力, 几乎所有ML算法都有与物理原理相结合的可能性, 以进一步提升性能。例如, 在采用基于Arrhenius定律核函数的ML算法时, 通过调整内核函数, 将温度、DOD和再生容量等物理因素纳入协方差函数的多项式方程或周期协方差函数中, 可以实现对复杂物理过程更精准的建模。未来, 探索物理原理与ML算法更多样化的融合方式将成为重要研究的重要方向。

(5) 广义迁移学习: 这一概念涵盖了迁移学习与增量学习的精髓, 旨在面对数据分布相似的新情况时, 通过保持并微调原有RUL预测模型的大部分参数, 而非从头开始训练, 从而提高模型的应用效率。数据的相似性可通过相关系数等统计指标来量化。迁移学习允许根据目标数据对原始模型进行微调, 而增量学习则能够无缝地整合新数据与旧数据, 无需重建整个模型, 这对于提升ML算法的学习效率及支持未来在线应用的实现具有重要意义。

(6) 硬件层面: 尽管ML算法在RUL预测领域的研究取得了显著进展, 但相关的硬件尚显薄弱, 仅有少数研究^[84]探讨了相关的软件与硬件架构设计。然而, 电动汽车等实际应用场景对硬件的需求与实验室条件存在显著差异, 且行业对高计算需求的RUL预测算法的接受度高度依赖于硬件平台的成本效益与实用性。因此, 从硬件角度如何高效、经济地实现ML算法, 以满足实际应用的需求, 仍是一个亟待深入研究的课题。

通过这些方向的深化研究, ML在RUL预测中的应用将更加精准高效, 为电池管理及维护策略提供有力支持。

5 结 论

在过去十年中, 利用ML算法预测锂离子电池的RUL取得了巨大进展。本文总结了用于电池RUL预测的常见ML方法的发展趋势, 概述了延长电池寿命的方法, 并分析了基于RUL预测延长锂离子电池寿命的可能性。概述了RUL预测的可能改进方向, 包括早期预测、局部再生建模、物理信息融合、广义迁移学习和硬件实现, 最终用户可以基于在线RUL预测结果个性化优化充电配置文件, 从而延长电池寿命。本文期望帮助研究人员清楚了解不同ML算法在RUL预测中的研究发展方向, 并

在未来提出更多有用的算法, 也期望可以为使用RUL预测结果延长电池寿命提供一些启发。

参 考 文 献

- [1] SAMANTA A, CHOWDHURI S, WILLIAMSON S S. Machine learning-based data-driven fault detection/diagnosis of lithium-ion battery: A critical review[J]. *Electronics*, 2021, 10(11): 1309. DOI: 10.3390/electronics10111309.
- [2] ALKHEDHER M, AL TAHHAN A B, YOUSAF J, et al. Electrochemical and thermal modeling of lithium-ion batteries: A review of coupled approaches for improved thermal performance and safety lithium-ion batteries[J]. *Journal of Energy Storage*, 2024, 86: 111172. DOI: 10.1016/j.est.2024.111172.
- [3] CHANG W Y. The state of charge estimating methods for battery: A review[J]. *ISRN Applied Mathematics*, 2013, 2013: 953792. DOI: 10.1155/2013/953792.
- [4] NDECHE K C, EZEONU S O. Implementation of coulomb counting method for estimating the state of charge of lithium-ion battery[J]. *Physical Science International Journal*, 2021: 1-8. DOI: 10.9734/psij/2021/v25i330244.
- [5] HOW D N T, HANNAN M A, HOSSAIN LIPU M S, et al. State of charge estimation for lithium-ion batteries using model-based and data-driven methods: A review[J]. *IEEE Access*, 2019, 7: 136116-136136. DOI: 10.1109/ACCESS.2019.2942213.
- [6] LI Y, LIU K L, FOLEY A M, et al. Data-driven health estimation and lifetime prediction of lithium-ion batteries: A review[J]. *Renewable and Sustainable Energy Reviews*, 2019, 113: 109254. DOI: 10.1016/j.rser.2019.109254.
- [7] MENG H X, LI Y F. A review on prognostics and health management (PHM) methods of lithium-ion batteries[J]. *Renewable and Sustainable Energy Reviews*, 2019, 116: 109405. DOI: 10.1016/j.rser.2019.109405.
- [8] ZHANG Q S, YANG L, GUO W C, et al. A deep learning method for lithium-ion battery remaining useful life prediction based on sparse segment data via cloud computing system[J]. *Energy*, 2022, 241: 122716. DOI: 10.1016/j.energy.2021.122716.
- [9] HASHEMZADEH P, DÉSILETS M, LACROIX M, et al. Investigation of the P2D and of the modified single-particle models for predicting the nonlinear behavior of Li-ion batteries[J]. *Journal of Energy Storage*, 2022, 52: 104909. DOI: 10.1016/j.est.2022.104909.
- [10] LIN X Y, TANG Y L, REN J, et al. State of charge estimation with the adaptive unscented Kalman filter based on an accurate equivalent circuit model[J]. *Journal of Energy Storage*, 2021, 41: 102840. DOI: 10.1016/j.est.2021.102840.
- [11] ZHANG Y, TU L, XUE Z W, et al. Weight optimized unscented Kalman filter for degradation trend prediction of lithium-ion battery with error compensation strategy[J]. *Energy*, 2022, 251: 123890. DOI: 10.1016/j.energy.2022.123890.
- [12] LI Y Y, STROE D I, CHENG Y H, et al. On the feature selection for battery state of health estimation based on charging-

- discharging profiles[J]. *Journal of Energy Storage*, 2021, 33: 102122. DOI: 10.1016/j.est.2020.102122.
- [13] JIANG B, ZHU J G, WANG X Y, et al. A comparative study of different features extracted from electrochemical impedance spectroscopy in state of health estimation for lithium-ion batteries [J]. *Applied Energy*, 2022, 322: 119502. DOI: 10.1016/j.apenergy.2022.119502.
- [14] LI X J, YU D, SØREN BYG V, et al. The development of machine learning-based remaining useful life prediction for lithium-ion batteries[J]. *Journal of Energy Chemistry*, 2023, 82: 103-121. DOI: 10.1016/j.jechem.2023.03.026.
- [15] GASPER P, SCHIEK A, SMITH K, et al. Predicting battery capacity from impedance at varying temperature and state of charge using machine learning[J]. *Cell Reports Physical Science*, 2022, 3(12): 101184. DOI: 10.1016/j.xcrp.2022.101184.
- [16] FARAJI-NIRI M, RASHID M, SANSOM J, et al. Accelerated state of health estimation of second life lithium-ion batteries via electrochemical impedance spectroscopy tests and machine learning techniques[J]. *Journal of Energy Storage*, 2023, 58: 106295. DOI: 10.1016/j.est.2022.106295.
- [17] SEVERSON K A, ATTIA P M, JIN N, et al. Data-driven prediction of battery cycle life before capacity degradation[J]. *Nature Energy*, 2019, 4: 383-391. DOI: 10.1038/s41560-019-0356-8.
- [18] FAN J M, FAN J P, LIU F, et al. A novel machine learning method based approach for Li-ion battery prognostic and health management[J]. *IEEE Access*, 2019, 7: 160043-160061. DOI: 10.1109/ACCESS.2019.2947843.
- [19] WANG Y J, PAN R, YANG D, et al. Remaining useful life prediction of lithium-ion battery based on discrete wavelet transform[J]. *Energy Procedia*, 2017, 105: 2053-2058. DOI: 10.1016/j.egypro.2017.03.582.
- [20] HAN X J, WANG Z R, WEI Z X. A novel approach for health management online-monitoring of lithium-ion batteries based on model-data fusion[J]. *Applied Energy*, 2021, 302: 117511. DOI: 10.1016/j.apenergy.2021.117511.
- [21] CHEN L, DING Y H, LIU B H, et al. Remaining useful life prediction of lithium-ion battery using a novel particle filter framework with grey neural network[J]. *Energy*, 2022, 244: 122581. DOI: 10.1016/j.energy.2021.122581.
- [22] KWON S J, HAN D, CHOI J H, et al. Remaining-useful-life prediction via multiple linear regression and recurrent neural network reflecting degradation information of 20 Ah $\text{LiNi}_x\text{Mn}_y\text{Co}_{1-x-y}\text{O}_2$ pouch cell[J]. *Journal of Electroanalytical Chemistry*, 2020, 858: 113729. DOI: 10.1016/j.jelechem.2019.113729.
- [23] ANSARI S, AYOB A, HOSSAIN LIPU M S, et al. Remaining useful life prediction for lithium-ion battery storage system: A comprehensive review of methods, key factors, issues and future outlook[J]. *Energy Reports*, 2022, 8: 12153-12185. DOI: 10.1016/j.egyr.2022.09.043.
- [24] CHEN J C, CHEN T L, LIU W J, et al. Combining empirical mode decomposition and deep recurrent neural networks for predictive maintenance of lithium-ion battery[J]. *Advanced Engineering Informatics*, 2021, 50: 101405. DOI: 10.1016/j.aei.2021.101405.
- [25] ZHANG Y Z, XIONG R, HE H W, et al. Long short-term memory recurrent neural network for remaining useful life prediction of lithium-ion batteries[J]. *IEEE Transactions on Vehicular Technology*, 2018, 67(7): 5695-5705. DOI: 10.1109/TVT.2018.2805189.
- [26] TONG Z M, MIAO J Z, TONG S G, et al. Early prediction of remaining useful life for Lithium-ion batteries based on a hybrid machine learning method[J]. *Journal of Cleaner Production*, 2021, 317: 128265. DOI: 10.1016/j.jclepro.2021.128265.
- [27] CHENG G, WANG X Z, HE Y R. Remaining useful life and state of health prediction for lithium batteries based on empirical mode decomposition and a long and short memory neural network[J]. *Energy*, 2021, 232: 121022. DOI: 10.1016/j.energy.2021.121022.
- [28] PARK K, CHOI Y, CHOI W J, et al. LSTM-based battery remaining useful life prediction with multi-channel charging profiles[J]. *IEEE Access*, 2020, 8: 20786-20798. DOI: 10.1109/ACCESS.2020.2968939.
- [29] ZHANG M, WU L F, PENG Z. The early prediction of lithium-ion battery remaining useful life using a novel long short-term memory network[C]// 2021 IEEE 16th Conference on Industrial Electronics and Applications (ICIEA). IEEE, 2021: 1364-1371 [2024-09-01]. DOI: 10.1109/ICIEA51954.2021.9516254.
- [30] WANG Z Q, LIU N, GUO Y M. Adaptive sliding window LSTM NN based RUL prediction for lithium-ion batteries integrating LTSA feature reconstruction[J]. *Neurocomputing*, 2021, 466: 178-189. DOI: 10.1016/j.neucom.2021.09.025.
- [31] LIU Y F, ZHAO G Q, PENG X Y. Deep learning prognostics for lithium-ion battery based on ensembled long short-term memory networks[J]. *IEEE Access*, 2019, 7: 155130-155142. DOI: 10.1109/ACCESS.2019.2937798.
- [32] WANG F K, HUANG C Y, MAMO T. Ensemble model based on stacked long short-term memory model for cycle life prediction of lithium-ion batteries[J]. *Applied Sciences*, 2020, 10(10): 3549. DOI: 10.3390/app10103549.
- [33] PAN D W, LI H F, WANG S J. Transfer learning-based hybrid remaining useful life prediction for lithium-ion batteries under different stresses[J]. *IEEE Transactions on Instrumentation and Measurement*, 2022, 71: 3501810. DOI: 10.1109/TIM.2022.3142757.
- [34] SONG Y C, LI L, PENG Y, et al. Lithium-ion battery remaining useful life prediction based on GRU-RNN[C]// 2018 12th International Conference on Reliability, Maintainability, and Safety (ICRMS). IEEE, 2018: 317-322[2024-09-01]. DOI: 10.1109/ICRMS.2018.00067.
- [35] WEI M, GU H R, YE M, et al. Remaining useful life prediction of lithium-ion batteries based on Monte Carlo Dropout and gated recurrent unit[J]. *Energy Reports*, 2021, 7: 2862-2871. DOI: 10.1016/j.egyr.2021.05.019.
- [36] TANG T, YUAN H M. A hybrid approach based on decomposition algorithm and neural network for remaining useful life prediction of lithium-ion battery[J]. *Reliability Engineering & System Safety*, 2022, 217: 108082. DOI: 10.1016/j.res.2021.108082.
- [37] CHE Y H, DENG Z W, LIN X K, et al. Predictive battery health

- management with transfer learning and online model correction [J]. *IEEE Transactions on Vehicular Technology*, 2021, 70(2): 1269-1277. DOI: 10.1109/TVT.2021.3055811.
- [38] VASWANI A, SHAZEER N M, PARMAR N, et al. Attention is All you Need[J/OL]. *Neural Information Processing Systems*, 2017 [2024-07-31]. <https://doi.org/10.48550/arXiv.1706.03762>
- [39] CHEN D Q, HONG W C, ZHOU X Z. Transformer network for remaining useful life prediction of lithium-ion batteries[J]. *IEEE Access*, 1975, 10: 19621-19628. DOI: 10.1109/ACCESS.2022.3151975.
- [40] YU J S, YANG J, WU Y, et al. Online state-of-health prediction of lithium-ion batteries with limited labeled data[J]. *International Journal of Energy Research*, 2020, 44(14): 11345-11360. DOI: 10.1002/er.5750.
- [41] ZHAO Q, QIN X L, ZHAO H B, et al. A novel prediction method based on the support vector regression for the remaining useful life of lithium-ion batteries[J]. *Microelectronics Reliability*, 2018, 85: 99-108. DOI: 10.1016/j.microrel.2018.04.007.
- [42] LI X, MA Y, ZHU J J. An online dual filters RUL prediction method of lithium-ion battery based on unscented particle filter and least squares support vector machine[J]. *Measurement*, 2021, 184: 109935. DOI: 10.1016/j.measurement.2021.109935.
- [43] DONG H C. Prediction of the remaining useful life of lithium-ion batteries based on Dempster-Shafer theory and the support vector regression-particle filter[J]. *IEEE Access*, 2021, 9: 165490-165503. DOI: 10.1109/ACCESS.2021.3136131.
- [44] WANG F K, AMOGNE Z E, TSENG C, et al. A hybrid method for online cycle life prediction of lithium-ion batteries[J]. *International Journal of Energy Research*, 2022, 46(7): 9080-9096. DOI: 10.1002/er.7785.
- [45] NUHIC A, TERZIMEHIC T, SOCZKA-GUTH T, et al. Health diagnosis and remaining useful life prognostics of lithium-ion batteries using data-driven methods[J]. *Journal of Power Sources*, 2013, 239: 680-688. DOI: 10.1016/j.jpowsour.2012.11.146.
- [46] VILSEN S B, SUI X, STROE D I. A time-varying log-linear model for predicting the resistance of lithium-ion batteries[C]// 2020 IEEE 9th International Power Electronics and Motion Control Conference (IPEMC2020-ECCE Asia). IEEE, 2020: 1659-1666. DOI: 10.1109/IPEMC-ECCEAsia48364.2020.9367839.
- [47] LONG B, XIAN W M, JIANG L, et al. An improved autoregressive model by particle swarm optimization for prognostics of lithium-ion batteries[J]. *Microelectronics Reliability*, 2013, 53(6): 821-831. DOI: 10.1016/j.microrel.2013.01.006.
- [48] LIU D T, LUO Y, LIU J, et al. Lithium-ion battery remaining useful life estimation based on fusion nonlinear degradation AR model and RPF algorithm[J]. *Neural Computing and Applications*, 2014, 25(3): 557-572. DOI: 10.1007/s00521-013-1520-x.
- [49] GUO L M, PANG J Y, LIU D T, et al. Data-driven framework for lithium-ion battery remaining useful life estimation based on improved nonlinear degradation factor[C]// 2013 IEEE 11th International Conference on Electronic Measurement & Instruments. IEEE, 2013, 2: 1014-1020[2024-09-01]. DOI: 10.1109/ICEMI.2013.6743205.
- [50] SONG Y C, LIU D T, YANG C, et al. Data-driven hybrid remaining useful life estimation approach for spacecraft lithium-ion battery [J]. *Microelectronics Reliability*, 2017, 75: 142-153. DOI: 10.1016/j.microrel.2017.06.045.
- [51] LIN J, WEI M H. Remaining useful life prediction of lithium-ion battery based on auto-regression and particle filter[J]. *International Journal of Intelligent Computing and Cybernetics*, 2021, 14(2): 218-237. DOI: 10.1108/ijicc-09-2020-0131.
- [52] LIN C P, CABRERA J, YANG F F, et al. Battery state of health modeling and remaining useful life prediction through time series model[J]. *Applied Energy*, 2020, 275: 115338. DOI: 10.1016/j.apenergy.2020.115338.
- [53] ZHOU B T, CHENG C, MA G J, et al. Remaining useful life prediction of lithium-ion battery based on attention mechanism with positional encoding[J]. *IOP Conference Series: Materials Science and Engineering*, 2020, 895(1): 012006. DOI: 10.1088/1757-899x/895/1/012006.
- [54] HSU C W, XIONG R, CHEN N Y, et al. Deep neural network battery life and voltage prediction by using data of one cycle only [J]. *Applied Energy*, 2022, 306: 118134. DOI: 10.1016/j.apenergy.2021.118134.
- [55] XIONG R, TIAN J P, SHEN W X, et al. Semi-supervised estimation of capacity degradation for lithium ion batteries with electrochemical impedance spectroscopy[J]. *Journal of Energy Chemistry*, 2023, 76: 404-413. DOI: 10.1016/j.jechem.2022.09.045.
- [56] KONG D P, WANG S H, PING P. State-of-health estimation and remaining useful life for lithium-ion battery based on deep learning with Bayesian hyperparameter optimization[J]. *International Journal of Energy Research*, 2022, 46(5): 6081-6098. DOI: 10.1002/er.7548.
- [57] REN L, DONG J B, WANG X K, et al. A data-driven auto-CNN-LSTM prediction model for lithium-ion battery remaining useful life [J]. *IEEE Transactions on Industrial Informatics*, 2021, 17(5): 3478-3487. DOI: 10.1109/TII.2020.3008223.
- [58] ZHANG X W, QIN Y, YUEN C, et al. Time-series regeneration with convolutional recurrent generative adversarial network for remaining useful life estimation[J]. *IEEE Transactions on Industrial Informatics*, 2021, 17(10): 6820-6831. DOI: 10.1109/TII.2020.3046036.
- [59] YANG H, WANG P L, AN Y B, et al. Remaining useful life prediction based on denoising technique and deep neural network for lithium-ion capacitors[J]. *eTransportation*, 2020, 5: 100078. DOI: 10.1016/j.etrans.2020.100078.
- [60] HONG J, LEE D, JEONG E R, et al. Towards the swift prediction of the remaining useful life of lithium-ion batteries with end-to-end deep learning[J]. *Applied Energy*, 2020, 278: 115646. DOI: 10.1016/j.apenergy.2020.115646.
- [61] ZHOU D H, LI Z Y, ZHU J L, et al. State of health monitoring and remaining useful life prediction of lithium-ion batteries based on temporal convolutional network[J]. *IEEE Access*, 2020, 8: 53307-

53320. DOI: 10.1109/ACCESS.2020.2981261.
- [62] SHEN S, SADOUGHI M, LI M, et al. Deep convolutional neural networks with ensemble learning and transfer learning for capacity estimation of lithium-ion batteries[J]. *Applied Energy*, 2020, 260: 114296. DOI: 10.1016/j.apenergy.2019.114296.
- [63] RAZAVI-FAR R, CHAKRABARTI S, SAIF M, et al. An integrated imputation-prediction scheme for prognostics of battery data with missing observations[J]. *Expert Systems with Applications*, 2019, 115: 709-723. DOI: 10.1016/j.eswa.2018.08.033.
- [64] CHEN X W, LIU Z, WANG J Y, et al. An adaptive prediction model for the remaining life of an Li-ion battery based on the fusion of the two-phase Wiener process and an extreme learning machine[J]. *Electronics*, 2021, 10(5): 540. DOI: 10.3390/electronics10050540.
- [65] SUN T F, XIA B Z, LIU Y F, et al. A novel hybrid prognostic approach for remaining useful life estimation of lithium-ion batteries[J]. *Energies*, 2019, 12(19): 3678. DOI: 10.3390/en12193678.
- [66] YANG J, PENG Z, WANG H M, et al. The remaining useful life estimation of lithium-ion battery based on improved extreme learning machine algorithm[J]. *International Journal of Electrochemical Science*, 2018, 13(5): 4991-5004. DOI: 10.20964/2018.05.84.
- [67] TANG T, YUAN H M. The capacity prediction of Li-ion batteries based on a new feature extraction technique and an improved extreme learning machine algorithm[J]. *Journal of Power Sources*, 2021, 514: 230572. DOI: 10.1016/j.jpowsour.2021.230572.
- [68] ZHANG M, KANG G Q, WU L F, et al. A method for capacity prediction of lithium-ion batteries under small sample conditions[J]. *Energy*, 2022, 238: 122094. DOI: 10.1016/j.energy.2021.122094.
- [69] MA Y Y, WU L F, GUAN Y, et al. The capacity estimation and cycle life prediction of lithium-ion batteries using a new broad extreme learning machine approach[J]. *Journal of Power Sources*, 2020, 476: 228581. DOI: 10.1016/j.jpowsour.2020.228581.
- [70] FENG H L, SONG D D. A health indicator extraction based on surface temperature for lithium-ion batteries remaining useful life prediction[J]. *Journal of Energy Storage*, 2021, 34: 102118. DOI: 10.1016/j.est.2020.102118.
- [71] ZHANG Y Z, XIONG R, HE H W, et al. Validation and verification of a hybrid method for remaining useful life prediction of lithium-ion batteries[J]. *Journal of Cleaner Production*, 2019, 212: 240-249. DOI: 10.1016/j.jclepro.2018.12.041.
- [72] JIA S, MA B, GUO W, et al. A sample entropy based prognostics method for lithium-ion batteries using relevance vector machine [J]. *Journal of Manufacturing Systems*, 2021, 61: 773-781. DOI: 10.1016/j.jmsy.2021.03.019.
- [73] WANG R R, FENG H L. Remaining useful life prediction of lithium-ion battery using a novel health indicator[J]. *Quality and Reliability Engineering International*, 2021, 37(3): 1232-1243. DOI: 10.1002/qre.2792.
- [74] ZHENG X J, FANG H J. An integrated unscented Kalman filter and relevance vector regression approach for lithium-ion battery remaining useful life and short-term capacity prediction[J]. *Reliability Engineering & System Safety*, 2015, 144: 74-82. DOI: 10.1016/j.res.2015.07.013.
- [75] CHANG Y, FANG H J, ZHANG Y. A new hybrid method for the prediction of the remaining useful life of a lithium-ion battery[J]. *Applied Energy*, 2017, 206: 1564-1578. DOI: 10.1016/j.apenergy.2017.09.106.
- [76] CHEN Z W, SHI N, JI Y F, et al. Lithium-ion batteries remaining useful life prediction based on BLS-RVM[J]. *Energy*, 2021, 234: 121269. DOI: 10.1016/j.energy.2021.121269.
- [77] CAI Y S, YANG L, DENG Z W, et al. Prediction of lithium-ion battery remaining useful life based on hybrid data-driven method with optimized parameter[C]// 2017 2nd International Conference on Power and Renewable Energy (ICPRE). IEEE, 2017: 1-6. DOI: 10.1109/ICPRE.2017.8390489.
- [78] ZHOU Y, GU H H, SU T, et al. Remaining useful life prediction with probability distribution for lithium-ion batteries based on edge and cloud collaborative computation[J]. *Journal of Energy Storage*, 2021, 44: 103342. DOI: 10.1016/j.est.2021.103342.
- [79] ZHANG C L, HE Y G, YUAN L F, et al. Capacity prognostics of lithium-ion batteries using EMD denoising and multiple kernel RVM[J]. *IEEE Access*, 2017, 5: 12061-12070. DOI: 10.1109/ACCESS.2017.2716353.
- [80] SUN X F, ZHONG K, HAN M. A hybrid prognostic strategy with unscented particle filter and optimized multiple kernel relevance vector machine for lithium-ion battery[J]. *Measurement*, 2021, 170: 108679. DOI: 10.1016/j.measurement.2020.108679.
- [81] LIU D T, ZHOU J B, PAN D W, et al. Lithium-ion battery remaining useful life estimation with an optimized relevance vector machine algorithm with incremental learning[J]. *Measurement*, 2015, 63: 143-151. DOI: 10.1016/j.measurement.2014.11.031.
- [82] SONG Y C, LIU D T, HOU Y D, et al. Satellite lithium-ion battery remaining useful life estimation with an iterative updated RVM fused with the KF algorithm[J]. *Chinese Journal of Aeronautics*, 2018, 31(1): 31-40. DOI: 10.1016/j.cja.2017.11.010.
- [83] ZHAO L, WANG Y P, CHENG J H. A hybrid method for remaining useful life estimation of lithium-ion battery with regeneration phenomena[J]. *Applied Sciences*, 2019, 9(9): 1890. DOI: 10.3390/app9091890.
- [84] WANG S J, LIU D T, ZHOU J B, et al. A run-time dynamic reconfigurable computing system for lithium-ion battery prognosis [J]. *Energies*, 2016, 9(8): 572. DOI: 10.3390/en9080572.
- [85] DONG G Z, XU Y, WEI Z B. A hierarchical approach for finite-time H_{∞} state-of-charge observer and probabilistic lifetime prediction of lithium-ion batteries[J]. *IEEE Transactions on Energy Conversion*, 2022, 37(1): 718-728. DOI: 10.1109/TEC.2021.3109896.
- [86] LI X Y, YUAN C G, WANG Z P. Multi-time-scale framework for prognostic health condition of lithium battery using modified Gaussian process regression and nonlinear regression[J].

- Journal of Power Sources, 2020, 467: 228358. DOI: 10.1016/j.jpowsour.2020.228358.
- [87] PAN W J, LUO X S, ZHU M T, et al. A health indicator extraction and optimization for capacity estimation of Li-ion battery using incremental capacity curves[J]. Journal of Energy Storage, 2021, 42: 103072. DOI: 10.1016/j.est.2021.103072.
- [88] KONG J Z, YANG F F, ZHANG X, et al. Voltage-temperature health feature extraction to improve prognostics and health management of lithium-ion batteries[J]. Energy, 2021, 223: 120114. DOI: 10.1016/j.energy.2021.120114.
- [89] ZHANG Y W, TANG Q C, ZHANG Y, et al. Identifying degradation patterns of lithium ion batteries from impedance spectroscopy using machine learning[J]. Nature Communications, 2020, 11: 1706. DOI: 10.1038/s41467-020-15235-7.
- [90] LIU K L, HU X S, WEI Z B, et al. Modified Gaussian process regression models for cyclic capacity prediction of lithium-ion batteries[J]. IEEE Transactions on Transportation Electrification, 2019, 5(4): 1225-1236. DOI: 10.1109/TTE.2019.2944802.
- [91] LIU J, CHEN Z Q. Remaining useful life prediction of lithium-ion batteries based on health indicator and Gaussian process regression model[J]. IEEE Access, 2019, 7: 39474-39484. DOI: 10.1109/ACCESS.2019.2905740.
- [92] ZHANG C L, ZHAO S S, HE Y G. An integrated method of the future capacity and RUL prediction for lithium-ion battery pack[J]. IEEE Transactions on Vehicular Technology, 2022, 71(3): 2601-2613. DOI: 10.1109/TVT.2021.3138959.
- [93] LI M, SADOUGHI M, SHEN S, et al. Remaining useful life prediction of lithium-ion batteries using multi-model Gaussian process[C]// 2019 IEEE International Conference on Prognostics and Health Management (ICPHM). IEEE, 2019[2024-09-01]. DOI: 10.1109/ICPHM.2019.8819384.
- [94] ANSARI S, AYOB A, HOSSAIN LIPU M S, et al. Data-driven remaining useful life prediction for lithium-ion batteries using multi-charging profile framework: A recurrent neural network approach[J]. Sustainability, 2021, 13(23): 13333. DOI: 10.3390/su132313333.
- [95] JI Y F, CHEN Z W, SHEN Y, et al. An RUL prediction approach for lithium-ion battery based on SADE-MESN[J]. Applied Soft Computing, 2021, 104: 107195. DOI: 10.1016/j.asoc.2021.107195.
- [96] ROUHI ARDESHIRI R, MA C B. Multivariate gated recurrent unit for battery remaining useful life prediction: A deep learning approach[J]. International Journal of Energy Research, 2021, 45 (11): 16633-16648. DOI: 10.1002/er.6910.
- [97] ZOU L, WEN B Y, WEI Y Y, et al. Online prediction of remaining useful life for Li-ion batteries based on discharge voltage data[J]. Energies, 2022, 15(6): 2237. DOI: 10.3390/en15062237.
- [98] PAN H P, CHEN C T, GU M M. A method for predicting the remaining useful life of lithium batteries considering capacity regeneration and random fluctuations[J]. Energies, 2022, 15(7): 2498. DOI: 10.3390/en15072498.
- [99] STRANDBERG J. Pulse charging of Li-ion batteries for enhanced life performance[D]. KTH Royal Institute of Technology, 2023.
- [100] GUO J, XU Y L, EXNER M, et al. Unravelling the mechanism of pulse current charging for enhancing the stability of commercial $\text{LiNi}_{0.5}\text{Mn}_{0.3}\text{Co}_{0.2}\text{O}_2/\text{graphite}$ lithium-ion batteries[J]. Advanced Energy Materials, 2024, 14(22): 2400190. DOI: 10.1002/aenm.202400190.
- [101] ZHANG W B, SAYAVONG P, XIAO X, et al. Recovery of isolated lithium through discharged state calendar ageing[J]. Nature, 2024, 626: 306-312. DOI: 10.1038/s41586-023-06992-8.
- [102] WU Y, HUANG Z W, LIAO H T, et al. Adaptive power allocation using artificial potential field with compensator for hybrid energy storage systems in electric vehicles[J]. Applied Energy, 2020, 257: 113983. DOI: 10.1016/j.apenergy.2019.113983.
- [103] HUANG X R, LIU W J, MENG J H, et al. Lifetime extension of lithium-ion batteries with low-frequency pulsed current charging [J]. IEEE Journal of Emerging and Selected Topics in Power Electronics, 2023, 11(1): 57-66. DOI: 10.1109/JESTPE.2021.3130424.
- [104] LEE C H, WU Z Y, HSU S H, et al. Cycle life study of Li-ion batteries with an aging-level-based charging method[J]. IEEE Transactions on Energy Conversion, 2020, 35(3): 1475-1484. DOI: 10.1109/TEC.2020.2984799.
- [105] MAIA L K K, DRÜNERT L, LA MANTIA F, et al. Expanding the lifetime of Li-ion batteries through optimization of charging profiles[J]. Journal of Cleaner Production, 2019, 225: 928-938. DOI: 10.1016/j.jclepro.2019.04.031.
- [106] LI Y Q, GUO J, PEDERSEN K, et al. Investigation of multi-step fast charging protocol and aging mechanism for commercial NMC/graphite lithium-ion batteries[J]. Journal of Energy Chemistry, 2023, 80: 237-246. DOI: 10.1016/j.jechem.2023.01.016.
- [107] ATTIA P M, GROVER A, JIN N, et al. Closed-loop optimization of fast-charging protocols for batteries with machine learning [J]. Nature, 2020, 578: 397-402. DOI: 10.1038/s41586-020-1994-5.
- [108] GUO J, LI Y Q, MENG J H, et al. Understanding the mechanism of capacity increase during early cycling of commercial NMC/graphite lithium-ion batteries[J]. Journal of Energy Chemistry, 2022, 74: 34-44. DOI: 10.1016/j.jechem.2022.07.005.
- [109] NASCIMENTO R G, CORBETTA M, KULKARNI C S, et al. Hybrid physics-informed neural networks for lithium-ion battery modeling and prognosis[J]. Journal of Power Sources, 2021, 513: 230526. DOI: 10.1016/j.jpowsour.2021.230526.
- [110] GUO W D, SUN Z C, VILSEN S B, et al. Review of "grey box" lifetime modeling for lithium-ion battery: Combining physics and data-driven methods[J]. Journal of Energy Storage, 2022, 56: 105992. DOI: 10.1016/j.est.2022.105992.