

电工技术学报
Transactions of China Electrotechnical Society
ISSN 1000-6753,CN 11-2188/TM

《电工技术学报》网络首发论文

题目: 基于集成型极限学习机的 PEMFC 寿命预测研究
作者: 杨淇, 陈景文, 华志广, 李祥隆, 赵冬冬, 兰天一, 窦满峰
DOI: 10.19595/j.cnki.1000-6753.tces.240123
收稿日期: 2024-01-18
网络首发日期: 2024-09-14
引用格式: 杨淇, 陈景文, 华志广, 李祥隆, 赵冬冬, 兰天一, 窦满峰. 基于集成型极限学习机的 PEMFC 寿命预测研究[J/OL]. 电工技术学报.
<https://doi.org/10.19595/j.cnki.1000-6753.tces.240123>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于集成型极限学习机的 PEMFC 寿命预测研究

杨 洪¹ 陈景文¹ 华志广² 李祥隆³ 赵冬冬² 兰天一¹ 窦满峰²

(1.陕西科技大学电气与控制工程学院 西安 710021

2.西北工业大学自动化学院 西安 710072

3.北京化工大学材料科学与工程学院 北京 100029)

摘要 基于数据驱动的寿命预测方法能精准预测质子交换膜燃料电池 (PEMFC) 的剩余使用寿命, 预测性能的提高是当前寿命预测领域的研究热点。针对 PEMFC 寿命预测过程中预测精度与鲁棒性的提升问题, 基于统计学原理的寿命预测方法, 提出一种集成极限学习机 (EELM) 结构, 对 PEMFC 的寿命进行长期预测。集成结构中包含了 50 次重复测试, 通过局部强化优化器算法对每次测试结果进行优化, 提升了寿命预测精度。在长期预测的结果中, 给出了 EELM 预测结果的平均值和 95% 置信区间, 提升了系统的鲁棒性。最后采用稳态电流、准动态电流条件和动态电流下的老化数据集验证了所提出方法的有效性与可行性。

关键词: 质子交换膜燃料电池 极限学习机 集成结构 局部强化优化器

中图分类号: TM911.42

0 引言

质子交换膜燃料电池 (Proton Exchange Membrane Fuel Cell, PEMFC) 是一种可以将氢气与氧气中的化学能直接转化成电能的装置, 电化学反应的产物是电、水和热^[1]。PEMFC 具有高效能、快速启停、环保等优点, 应用前景广泛, 但高成本和短寿命是限制 PEMFC 商业化应用的两大阻碍^[2]。预测 PEMFC 的剩余使用寿命 (Remaining Useful Life, RUL), 可以帮助用户提前采取维护措施, 延长 PEMFC 的使用寿命^[3]。

目前对于 PEMFC 剩余使用寿命的预测方法主要有三种: 模型驱动、数据驱动、混合驱动^[4]。模型驱动方法需要在明确 PEMFC 老化机理的前提下建立经验模型、半经验模型或等效电路模型等, 然后通过粒子滤波器 (Particle Filter, PF)、卡尔曼滤波器 (Kalman Filter, KF)、无迹卡尔曼滤波器 (Unscented Kalman Filter, UKF)、扩展卡尔曼滤波器 (Extended Kalman Filter, EKF) 等方法来实现 PEMFC 老化状态的估计。M. Jouin 等^[5]通过仿真和实验, 验证了 PF 方法实现 PEMFC 寿命预测功能方面的可行性, 通过建立 PEMFC 物理老化模型, 将输出电压与电

化学活性表面积退化速率相联系, 从而进行剩余寿命预测。K. Chen 等^[6]将 UKF 方法与电压老化模型相结合, 采用燃料电池汽车 (Fuel Cell Electric Vehicle, FCEV) 真实工况下的实验数据实现 PEMFC 老化预测。该方法研究了不同训练长度对预测结果的影响以及不同动态工况下 PEMFC 系统的老化预测性能。M. Bressel 等^[7]使用 EKF 方法对 PEMFC 的老化状态以及相关的不确定性进行了估算, 通过反向一阶可靠性方法推断健康状态, 并根据由老化数据集建立的模型对该方法进行了验证。由于 PEMFC 的老化机理复杂, 构建精确的等效模型较为困难, 因此模型驱动方法在实际应用过程中很难全方位的考虑 PEMFC 老化过程^[8]。

数据驱动的方法主要基于机器学习理论, 无需揭示 PEMFC 的内部老化机理, 目前已得到广泛应用^[9]。Tang Xingwang 等^[10]提出一种基于迁移学习和 Transformer 神经网络的端到端预测算法, 解决了机器学习模型中训练数据和测试数据运行条件需要一致的问题。Peng Yulin 等^[11]将卷积神经网络与长短期记忆网络 (Long Short Term Memory, LSTM) 相结合, 对 PEMFC 的 RUL 进行预测, 提高了模型的训练和预测速度。He Kai 等^[12]将回声状态网络

(Echo State Network, ESN)、最小绝对值收敛和选择算子方法结合,实现了 RUL 的长期预测。Jin Jiashu 等^[13]提出一种确定性跳跃循环状态 (Cycle Reservoir with Jump, CRJ) 网络,将 PEMFC 运行中的电流、温度、压力和反应物流量作为输入变量,提取更多的老化信息来预测电压趋势。Zhang Chu^[14]等提出一种堆叠式预测模型来预测 PEMFC 的老化趋势,堆叠模型包含了支持回归向量机、门控递归单元和正则化极限学习机。该方法采用最大信息系数 (Maximum Information Coefficient, MIC) 和赤池信息量准则 (Akaike Information Criterion, AIC) 对输入变量进行降维优化,之后在两种不同电流条件下的对比实验中验证了堆叠模型的优越性。

混合驱动方法将模型驱动与数据驱动相结合,首先建立老化模型,通过 PF、KF、UKF、EKF 等方法实现参数估计,再通过数据驱动方法实现 PEMFC 的寿命预测以提升预测精度。赵波等^[15]提出一种混合驱动方法,将深度卷积神经网络与 LSTM 相结合从而实现电压预测,将电压的预测值作为自适应卡尔曼滤波器的观测值,最后基于稳态和准动态两组数据集实现了 PEMFC 寿命的短期和长期预测。Ma Rui 等^[16]提出一种基于 EKF-LSTM 的混合预测方法,通过 EKF 实现 PEMFC 老化参数估计,再通过 LSTM 对老化电压进行预测。Cheng Yujie 等^[17]通过构造二阶等效电路模型来实现混合健康指标的提取,再通过基于分位数回归-双向门控递归单元的数据驱动方法来实现 PEMFC 的老化预测。实验结果表明该方法在不同工况、不同预测步长、不同训练数据长度条件下的预测精度较高。

极限学习机 (Extreme Learning Machine, ELM) 作为一种数据驱动方法,具有泛化性能强、学习速度快的优点^[18-19]。在 PEMFC 的剩余使用寿命预测领域, Xie Yuchen 等^[20]提出一种基于深度信念网络与 ELM 相结合的方法,与传统预测方法相比,该方法在不同的训练样本量和预测范围内具有更高的精度和更稳定的性能。Zhang Xuexia 等^[21]将离散小波分解和自适应差分进化算法优化的增强型 ELM 结合,用于预测 PEMFC 的剩余使用寿命。与传统神经网络相比,该方法具备收敛速度快,所需训练数据少的优点。Deng Zhihua 等^[22]提出了一种基于模糊可拓广义学习系统和自编码器 (Auto Encoder, AE) 的 ELM 方法, ELM-AE 继承了 ELM 的快速学习能力,同时保留了 AE 的降维和特征学习能力。实验结果表明,与 ELM、基于粒子群优化算法的 ELM

和广义学习系统相比,该方法在不同运行条件、不同训练长度和不同输入变量下对 PEMFC 剩余使用寿命的预测具有更高的准确性。刘嘉蔚等^[23]等通过局部加权回归散点平滑法对老化电压数据进行预处理,并与核超限学习机结合,在稳态电流条件下实现 PEMFC 剩余使用寿命预测。实验结果表明相对于反向传播神经网络,该方法在预测精度上有显著提高。

目前关于 ELM 在 PEMFC 寿命预测领域的研究多为 RUL 的短期预测,在上述引用文献中,文献[5-8,10-11,14,20-23]实现了 PEMFC 寿命的短期预测,文献[12-13,15-16]实现了寿命的长期预测。但若以延长寿命为目的,采用长期预测方式要比短期预测更有实际意义,扩展预测范围有助于用户提前采取维护措施以避免因电池老化故障对整个系统造成不可逆的损失。此外, ELM 在训练时会随机生成输入权重和隐藏层偏置,这种随机性会使预测结果具备不稳定性并影响预测精度。但是即便对这二者进行优化,每次优化的结果也是不相同的,不能改变输入权重和隐藏层偏置是随机生成的本质。本文针对这一问题,为提高 ELM 的鲁棒性和精确性,提出一种集成 ELM (Ensemble Extreme Learning Machine, EELM) 结构对 PEMFC 的 RUL 进行长期预测,研究内容的主要创新之处为:

1) 基于统计学原理提出 ELM 模型簇,研究模型的不确定性对预测结果的影响。给出预测结果的 95% 置信区间,有效提升系统鲁棒性。

2) 对预测结果以及预测的置信区间都进行了优化。集成结构采用多输入模型以增加数据特征维度,使用局部强化器优化 (Partial Reinforcement Optimizer, PRO) 算法对 ELM 的输入权重和隐藏层偏置进行优化。

1 研究方法

1.1 极限学习机

ELM 的结构图如图 1 所示,由输入层、隐藏层、输出层三部分组成。在 PEMFC 寿命预测过程中,输入端包含电压、电流、气体压力、气体温度等影响因素,输出端为定义的老化指标 (如电压、功率等)。输入层和隐藏层之间通过输入权重 W 和隐藏层偏置 b 连接,隐藏层和输出层通过输出权重 β 连接。对于一个隐藏层数量为 L 的 ELM,假设训练集 $X_j=[x_1, x_2, \dots, x_N]^T \in R^n$, $T_j=[t_1, t_2, \dots, t_n]^T \in R^m$, ELM 的计算过程可以表示为

$$f_L(x) = \sum_{i=1}^L \beta_i g_i(x) = \sum_{i=1}^L \beta_i g(W_i \cdot X_j + b_i), j=1, \dots, N \quad (1)$$

式中, N 为训练集中样本的个数; g 为激活函数; W_i 为输入权重, $W_i = [\omega_1, \omega_2, \dots, \omega_n]$; β_i 为输出权重; b_i 为隐藏层中第 i 个神经元的偏置。




图 1 ELM 典型结构

Fig.1 Typical structure of the extreme learning machine

单隐层前馈神经网络的学习目标是使输出误差达到最小, 可表示为

$$\sum_{j=1}^N \|f_L(x) - T_j\| = 0 \quad (2)$$

式 (1) 可改为

$$\sum_{i=1}^L \beta_i g(W_i \cdot X_j + b_i) = T_j, j=1, \dots, N \quad (3)$$

式 (3) 可简写为

$$T = H\beta \quad (4)$$

式中, H 为隐藏层神经元的输出; T 为预期输出。

当激活函数无限可微, 输入权重 W 和隐藏层偏置 b 为随机确定时, W 和 b 在训练过程中保持不变, 输出矩阵 H 也被唯一确定。

β 可以通过求解式 (5) 的最小二乘解来获得。

$$\min \|H\beta - T\| \quad (5)$$

通过矩阵运算, β 可以表示为

$$\hat{\beta} = H^+ T \quad (6)$$

式中, H^+ 为 H 的 Moore-Penrose 广义逆。

在实验过程中, 激活函数选择 sigmoid 函数, 隐藏层个数设置为 3。

1.2 局部强化器优化算法

为使 PEMFC 的老化预测得到更精确的结果, 需要将 ELM 的输入权重和隐藏层偏置进行优化。PRO 算法是一种基于局部强化影响 (Partial

Reinforcement Effect, PRE) 理论的元启发式算法。根据 PRE 理论, 在学习和训练过程中, 学习者会间歇性地受到强化以提高其学习过程中行为模式的得分。强化模式通过选择适当的强化行为和强化时间来实现, 可对学习者产生影响。为实现 PRO 算法, 需将 PRE 理论中的学习者、行为、种群与时间间隔四个因素进行数学建模以求解全局优化问题。

1.2.1 制定计划表

每个学习者都有一个计划表, 学习者的行为会通过评分机制打分, 得分较高行为在下次迭代中被选中的机会更大。同时采用动态机制对时间间隔进行建模, 该过程分析为

$$\tau = \frac{F'}{F} \quad (7)$$

$$s = e^{-(1-\tau)} \quad (8)$$

$$\mu \subseteq \{1, 2, 3, \dots, N\}, \forall j \in \mu, S^j \geq S^{*,\lambda}, \quad (9)$$

$$\lambda = \|\mu\|, \|\mu\| = [U(1, N \times \alpha)]$$

式中, τ 为时间因子; F' 为已迭代的次数; F 为最大迭代次数; α 为选择率; μ 为根据计划表选择的行为子集; λ 为所选子集的大小; N 为行为总数; S^* 为得分按降序排列的计划表; $S^{*,\lambda}$ 为 S^* 中第 λ 个行为得分。

在每次迭代过程中, 选择计划表 i 中得分最高的子集 μ , 并按照计划表中的得分降序排序。通过式 (9) 选择前 λ 个行为作为下次迭代的候选。

1.2.2 激励学习

学习者的行为会受到激励, 通过式 (10)~式 (12) 不断学习, 得到新的解。

$$\rho = \tau + U(0, \bar{\rho}), \bar{\rho} = \sum_{j \in \mu} \frac{S_{i,j}}{\max S_i} \quad (10)$$

$$M_i^\mu = \begin{cases} X_b^\mu - X_i^\mu, p < 0.5 \\ X_i^\mu - X_j^\mu, p \geq 0.5 \end{cases} \quad (11)$$

$$X_{i,w}^\mu = X_i^\mu + \rho \times M_i^\mu \quad (12)$$

式中, ρ 为激励因子; $\bar{\rho}$ 为第 i 个学习者的计划表中所选择行为的标准化得分均值; S_i 为第 i 个学习者的计划表; M_i^μ 为第 i 个学习者行为子集受到的刺激; X_b^μ 为行为子集中当前得分最高的行为; X_i^μ 为第 i 个学习者行为子集中的行为; $X_{i,w}^\mu$ 为新的行为。

1.2.3 强化学习与计划表更新

强化学习可以分为正强化和负强化, 在正强化阶段时, 强化学习可以提高学习者行为的分数, 该

过程由式 (13) 表示；在负强化阶段时，强化学习会导致特定行为的分数降低，如式 (14) 所示。

$$S_i^\mu = S_i^\mu + S_i^\mu \times R \quad (13)$$

$$S_i^\mu = S_i^\mu - S_i^\mu \times R \quad (14)$$

式中， R 为强化率； S_i^μ 为第 i 个学习者行为的得分。

当学习者的所有行为均受到负强化时，PRO 将计划表的标准偏差 (Standard Deviation, SD) 作为指标以确定更新计划表的时间。式 (15)、式 (16) 表示这一过程，当第 i 个学习者计划表的 SD 为 0 时：

$$S_i = U(0,1) \quad (15)$$

$$X_i = U(L_B, U_B) \quad (16)$$

式中， L_B 、 U_B 分别为下限和上限； X_i 为第 i 个学习者的行为； $U(0,1)$ 、 $U(L_B, U_B)$ 分别为在 $(0,1)$ 和 (L_B, U_B) 间均匀分布的随机值。

在实验过程中，将训练阶段的均方误差 (Mean Square Error, MSE) 作为适应值，种群数量设置为 60，行为数量设置为 10，最大迭代次数设置为 100。

1.3 基于 PRO-ELM 的 PEMFC 老化预测

本文采用 PRO 算法对 ELM 的输入权重和隐藏层偏置进行优化，输入权重和隐藏层偏置连接输入层和隐藏层，对预测精度起到决定性作用。基于 PRO-ELM 的 PEMFC 老化预测流程图如图 2 所示。

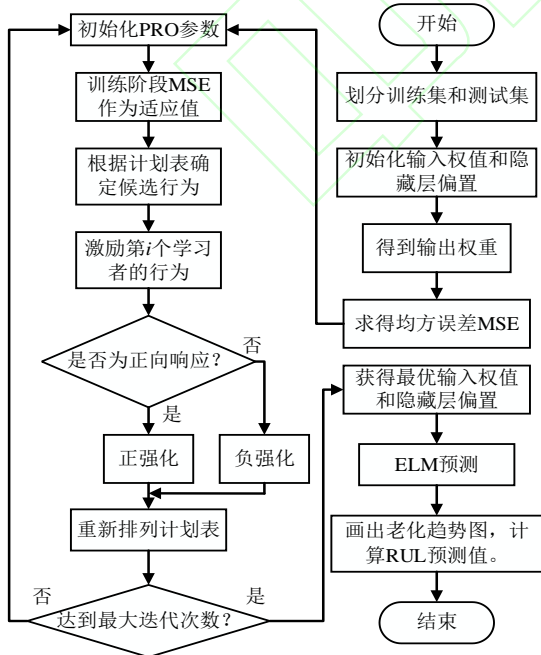


图 2 基于 PRO-ELM 的 PEMFC 老化预测

Fig.2 Flowchart of PEMFC degradation prediction based

on PRO-ELM

1) 将 PEMFC 老化数据集划分为训练集和测试集，本文取 50% 的数据作为训练集，剩余 50% 数据为测试集。

2) 将 ELM 的输入权重和隐藏层偏置作为优化目标，并将训练阶段的均方误差作为适应值。

3) 根据 PRO 中的计划表机制确定候选行为 (当前最优解)，并对该行为进行激励。

4) 判断上一步是否为正向响应，若为正向响应，则进入正强化学习，反之进入负强化学习，并将计划表重新排列，当达到最大迭代次数时，优化结束，输出全局最优解。

5) 通过优化得来的输入权重和隐藏层偏置最优解进入预测阶段，得到预测结果，得到 RUL 预测值。

1.4 EELM 预测流程

基于 EELM 的老化预测流程如图 3 所示，分为以下四个步骤。

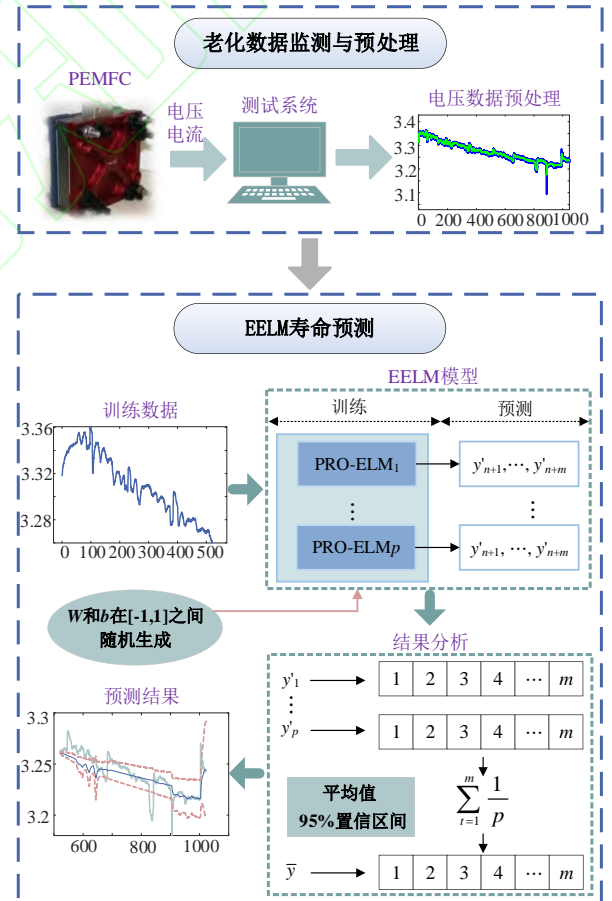


图 3 EELM 预测流程

Fig.3 The Flowchart of EELM prediction

1) 数据采集与预处理阶段。首先通过传感器收集 PEMFC 的电压、电流数据，再对电压老化数据

进行滤波处理。在 PEMFC 系统测试过程中, 由于实验条件、电堆电压的恢复特性和电解质材料性质的固有差异, 从复杂的原始老化数据中提取到准确的降解趋势较为困难。为了便于后续研究, 需将原始数据进行滤波处理, 过滤掉噪声和尖峰以获取平滑数据。本实验采用 30 min 的时间间隔进行采样, 通过移动平均滤波法对老化电压数据进行滤波处理。

2) 集成结构中的单个 ELM 对 PEMFC 的寿命进行预测。ELM 的输入数量和隐藏层个数会影响输入权重和隐藏层偏置, 基于前期对多输入和单输入的研究结果可以得出, 多输入组合在大多数情况下比单输入的预测精度更高。实际预测过程中, 电流 (I_s) 是一个可规划的变量, 可选择将电流同样作为 ELM 的输入以提高寿命预测精度。在预测过程中, 将总数据的 50% 作为训练集, 剩余 50% 作为测试集。首先采用 PRO 算法对 ELM 的输入权重和隐藏层偏置进行优化来提高预测精度, 随后进行 PEMFC 的 RUL 长期预测。

3) 将预测结果集合。集成结构中包含了 50 个单独的 ELM, 对预测结果进行统计分析。设 50 次预测结果所占权重是相同的, 将每个时间点的预测结果进行平均处理即可得到最终预测值。

4) 结果分析。采用均方根误差 (Root Mean Square Error, RMSE) 和平均绝对百分比误差 (Mean Absolute Percentage Error, MAPE) 作为评估预测精度的 2 个量化指标。

$$RMSE = \sqrt{\frac{1}{l} \sum_{i=1}^l (y'(t) - y(t))^2} \quad (17)$$

$$MAPE = \frac{1}{l} \sum_{i=1}^l \left| \frac{y'(t) - y(t)}{y'(t)} \right| \quad (18)$$

每个 ELM 都会得到不同的预测结果, 对于某一时刻 t , 其预测值的平均值和方差为

$$\begin{cases} \bar{y}(t) = \frac{1}{p} \sum_{i=1}^p y_i'(t) \\ D(t) = \frac{1}{p-1} \sum_{i=1}^p (\bar{y}(t) - y_i'(t))^2 \end{cases} \quad (19)$$

式中, p 为集成结构中 ELM 的个数, $y_i'(t)$ 代表预测值, $y(t)$ 为实际值, $\bar{y}(t)$ 为平均值, $D(t)$ 为方差。假设预测值服从标准高斯分布, 某一时刻 t 的预测结果的 95% 置信区间可以表示为

$$CI(t) = [\bar{y}(t) - 1.96\sqrt{D(t)}, \bar{y}(t) + 1.96\sqrt{D(t)}] \quad (20)$$

在预测结果分析过程中, 置信区间是评价预测模型可靠性的重要因素, 同时置信区间也可以帮助用户更好的理解预测的不确定性。本文在预测过程中采用了将电压和电流共同作为 ELM 输入的多输入模型, 并通过 PRO 算法对 ELM 的输入权重和隐藏层偏置进行了优化, 在优化预测模型的同时也对置信区间进行优化。再将预测结果进行平均处理得到最终集成结构的预测值可以有效降低预测结果的不确定性, 提升预测精度与鲁棒性。

2 实验结果

本实验使用了稳态电流、准动态电流、动态电流负载下的三组数据对 EELM 的预测性能进行了验证。统计分析了不同输入权重和隐藏层偏置对长期预测结果造成的不确定性, 并讨论分析系统的鲁棒性。稳态和准动态数据集使用了 IEEE PHM 2014 data challenge 的两组开放数据^[24]。在稳态电流和准动态电流条件下, 对于两个电堆进行 1 000 h 的测试, 每个电堆包含 5 个单体燃料电池, 稳态电流条件下的燃料电池堆在 0.7 A/cm² 的恒定电流密度的条件下测试; 在准动态电流条件下, 将恒定频率 5 kHz 的电流纹波叠加到恒定电流上进行电化学阻抗谱测量^[25]。动态数据集来自于 PEMFC 电堆在动态 μ -CHP 负载下进行的测试^[26]。该电堆由 8 个电池组成, 在 80℃ 下运行, 有效面积为 220 cm²。405 h 的测试分为四个阶段。第 1 阶段 (0~125 h): 0~25 h 内负载电流密度为 0.36 A/cm², 在其余时间内变为 0.45 A/cm²; 第 2 阶段 (125~250 h): 125~225 h 内负载电流密度在 0.45 A/cm² 和 0.23 A/cm² 之间变化, 其余时间维持在 0.23 A/cm²; 第 3 阶段 (250~375 h): 负载电流密度在 0 A/cm² 和 0.23 A/cm² 之间交替变换; 第 4 阶段 (375~405 h): 负载电流密度为 0.23 A/cm²。

美国能源部指出, PEMFC 系统的使用者可以在车辆用、便携式设备、固定发电站等不同应用场景中定义合适的失效阈值。根据 data challenge 中对 RUL 的定义, 将初始功率的 3.5%、4.0%、4.5%、5.0%、5.5% 定为失效阈值。在动态测试中 (μ -CHP), 通常将初始功率衰减 20% 定为失效阈值, 但动态电流条件的持续测试时间小于 1 000 h, 其失效点并不是电堆真正的寿命终止点。实际应用中, 可根据使用者对燃料电池的需求来规定失效阈值, 再根据失

效时对应的时间计算 PEMFC 的 RUL。本文在稳态电流条件下失效阈值初始功率的 96.5%，准动态电流条件下失效阈值为初始功率的 95.5%，动态电流条件下将实验结束时间视为功率失效点。

2.1 长期预测结果

研究团队在前期的研究工作中定义了“预测视野 (Prediction Horizon, PH)”这一概念^[27]，即从当前时刻开始到不依赖实际采样数据所能达到的最长预测时刻为止所能持续的时间范围。更长的 PH 意味着可以预测更远时间范围内的老化数据，更能为用户采取基于状态的维护 (Condition-Based Maintenance, CBM) 措施预留足够的时间，但 PH 越长也会带来误差累计的问题。根据实验获得的数百小时的实际老化数据，此处将 $PH < 24 \text{ h}$ (1 天) 定义为短期预测，将 $24 \text{ h} (1 \text{ 天}) < PH < 168 \text{ h}$ (1 周) 定义为中期预测，将 $PH > 168 \text{ h}$ (1 周) 定义为长期预测。

在实际算法表现形式上，短期预测通常基于单步预测来实现，即将 t 时刻的真实值作为输入来获得 $t+1$ 时刻的预测值。相比短期预测，中期/长期预测采用的是多步预测模式，即在预测时间尺度上更长，即从预测起点开始预测后便没有健康指标的测量数据作为输入，对于 $t+1$ 时刻的预测值可采用将 t 时刻的预测值作为输入来得到。对于长期预测，应更多地关注整体趋势，而不是预测特定电压点的精度。本文利用集成 ELM 模型，基于预测起始点前的老化数据直接预测未来数百小时的电压老化趋势，从而实现了 PEMFC 寿命的长期预测。如图 4 所示为长期预测与短期预测的预测过程。

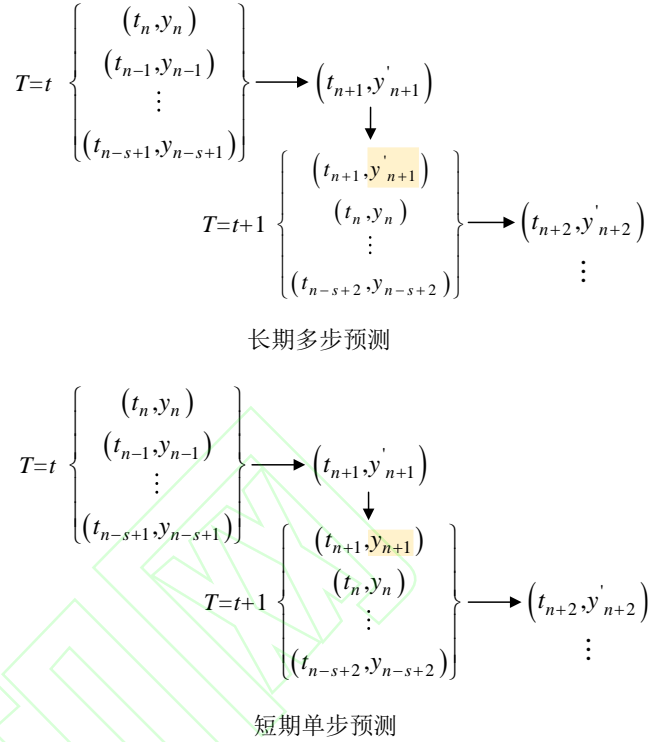


图 4 长期预测与短期预测

Fig.4 The process of long-term prediction and short-term prediction

2.1.1 稳态电流条件

在稳态电流条件下，选择 PEMFC 电堆输出电压作为老化指标进行预测，将“ $U_s + I_s$ ”作为 ELM 的输入，失效阈值为初始电压的 96.5% (3.232 75 V)。在预测过程中，集成结构中的 50 个 ELM 会得到 50 个不同的预测结果。计算每次预测结果的 RMSE, MAPE 并求得每一个时刻预测结果的平均值、方差和 95% 置信区间，将平均值与每次预测结果的 RMSE、MAPE 进行比较。图 5 所示为训练时长为 500 h 条件下的预测结果。

通过图 5b 可以看出，集成平均后的预测结果可以模拟 550~650 h 的波动，并在 677 h 之后的电压失效区间同样可以模拟老化趋势，这得益于将“ I_s ”作为 ELM 的输入。表 1 为 5 组独立 ELM 与 EELM 预测结果对比，EELM 的预测结果要比大部分独立 ELM 的精度更高。根据实验比较可得：在稳态电流条件下，RMSE 大于平均结果的独立 ELM 占集成结构总数的 86%。集成平均结果普遍优于独立 ELM 的预测结果。

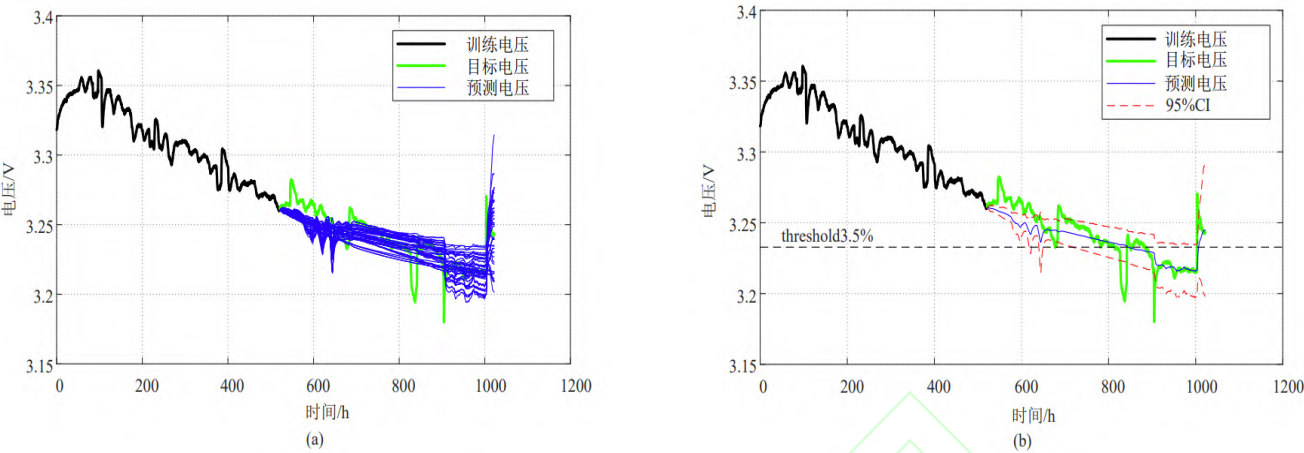


图5 稳态电流条件下预测结果：（a）50个独立 ELM 预测结果；（b）集成平均预测结果与 95%CI

Fig.5 Prediction results under steady-state

表 1 独立 ELM 与 EELM 预测误差对比（稳态条件）

Tab.1 Comparison of prediction error between single ELM and ensemble ELM (steady-state)

	ELM1	ELM2	ELM3	ELM4	ELM5	EELM
RMSE	0.014 42	0.011 21	0.012 01	0.013 08	0.010 41	0.010 44
MAPE(%)	0.363 9	0.269 1	0.274 1	0.286 4	0.209 4	0.221 8

2.1.2 准动态电流条件

准动态电流条件下，电堆电压变化趋势更加复杂。与稳态电流条件下相同，同样将输出电压 (U_s) 作为老化指标，“ U_s+I_s ”作为 ELM 的输入，失效阈值为初始电压的 95.5% (3.180 15 V)。集成结构会得到 50 个不同的预测结果，计算每一次预测结果的 RMSE、MAPE，并求得每一个时刻预测结果的平均值、方差和 95%置信区间。图 6 所示为训练时长为 500 h 条件下的预测结果。

预测结果表明，EELM 可以预测电压老化的大

致趋势，并可以模拟电压的波动，在 799 h 后的电压失效区间同样可以预测电压的老化趋势。准动态电流条件下的预测结果对比见表 2。根据实验比较可得：在准动态电流条件下，RMSE 大于平均结果的独立 ELM 占集成结构总数的 88%，集成平均结果普遍优于独立 ELM 的预测结果。

此外，将 EELM 的两组预测结果与其他文献中 CRJ、ESN、数据分组处理方法（Group Method of Data Handling, GMDH）继续对比，预测结果对比见表 3 和表 4。

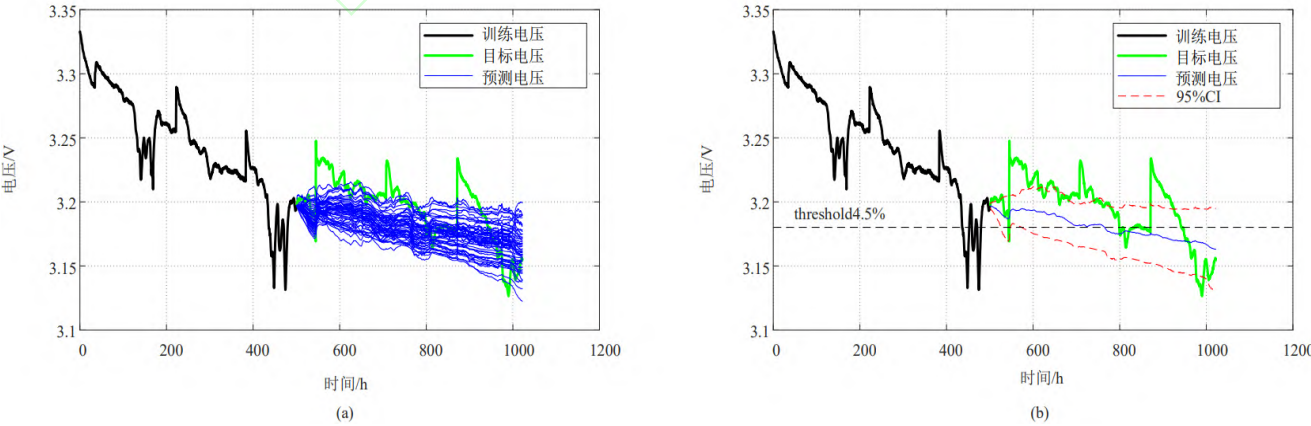


图6 准动态电流条件下预测结果：（a）50个独立 ELM 预测结果；（b）集成平均预测结果与 95%CI

Fig.6 Prediction results under quasi-dynamic

表 2 独立 ELM 与 EELM 预测误差对比（准动态条件）

Tab.2 Comparison of prediction error between single ELM and ensemble ELM (quasi-dynamic)

	ELM1	ELM2	ELM3	ELM4	ELM5	EELM
RMSE	0.026 79	0.031 99	0.028 54	0.030 42	0.020 84	0.023 73
MAPE(%)	0.712 1	0.876 9	0.747 2	0.818 3	0.473 4	0.629 6

表 3 EELM 与其他算法精度对比（稳态条件）

Tab.3 Comparison with the long-term prediction of other models based on steady-state

预测方法	RMSE	MAPE(%)
EELM(500h)	0.010 44	0.221 8
CRJ ^[13] (550h)	0.013 22	0.288
GMDH ^[28] (550h)	0.026 25	0.822
ESN ^[29] (550h)	0.011 06	0.369

表 4 EELM 与其他算法精度对比（准动态条件）

Tab.4 Comparison with the long-term prediction of other models based on quasi-dynamic

预测方法	RMSE	MAPE(%)
EELM(500h)	0.023 73	0.629 6
CRJ ^[13] (550h)	0.034 65	0.955
GMDH ^[28] (550h)	0.036 25	1.615
ESN ^[29] (550h)	0.024 95	0.874

通过表 3 和表 4 可以看出，对于稳态电流和准动态电流条件下，EELM 都得到了更为精确的预测结果。这是由于集成结构能够降低 ELM 参数随机生成所造成的预测结果不确定性，同时在每次独立 ELM 预测中，都通过 PRO 算法对 ELM 的输入权重

和隐藏层偏置进行优化。并且 EELM 在训练数据比其他三种方法更少时的预测精度更高，有效反映了 EELM 具有更强的泛化能力。

2.1.3 动态电流条件

在动态电流条件下，基于先前对动态健康指标的研究工作^[26]，将相对功率损耗率（Relative Power-Loss Rate, RPLR）作为老化指标，“ $R_{PLR}+I_s$ ”作为输入。时间 t 处的 R_{PLR} 由式（21）计算。集成结构会得到 50 个不同的预测结果，计算每一次预测结果的 RMSE、MAPE，并求得每一个时刻预测结果的平均值、方差和 95%置信区间。图 7 所示为训练时长为 195 h 的预测结果。

$$R_{PLR} = (P_t - P_0) / P_t \quad (21)$$

式中， P_t 为时间 t 处的功率； P_0 为初始功率。

预测结果表明，集成平均结果可以模拟整体老化趋势，并可以模拟在 195~225 h、260~280 h 之间的波动，具有较高的预测精度。动态电流条件下的预测结果对比见表 5。根据实验比较可得：在动态电流条件下，RMSE 大于平均结果的独立 ELM 占集成结构总数的 92%，集成平均值普遍优于独立 ELM 的预测结果。




图 7 动态电流条件下预测结果：（a）50 个独立 ELM 预测结果；（b）集成平均预测结果与 95%CI

Fig.7 Prediction results under dynamic

表 5 独立 ELM 与 EELM 预测误差对比（动态条件）

Tab.5 Comparison of prediction error between single ELM and ensemble ELM (dynamic)

	ELM1	ELM2	ELM3	ELM4	ELM5	EELM
RMSE	0.007 673	0.006 779	0.005 909	0.010 22	0.004 741	0.004 861
MAPE(%)	8.396	11.54	7.351	10.62	7.032	7.146

2.2 鲁棒性分析

ELM 输入权重和隐藏层偏置的随机生成会导致输出权重的不同,从而使得预测结果具有随机性。基于统计学原理,通过集成 ELM 结构对预测结果的随机性进行分析,求得平均值并设定 95%置信区间,在提高了预测精度的同时,进一步的提升了预测的鲁棒性。对于鲁棒性的分析,将 ELM 与 EELM 进行 50 次重复实验,以 RMSE 为评价指标,两种负载条件下的精度对比如图 8~图 10 所示。




图 8 50 次实验的精度对比 (稳态条件)

Fig.8 Accuracy results for 50 trails (steady-state)

通过图 8~图 10 可以看出, EELM 的预测精度要比大部分独立 ELM 的预测精度高,并且波动更小,分布更集中。这表明 EELM 预测的稳定性更强,集成结构有效提升了 ELM 的鲁棒性。




图 9 50 次实验的精度对比 (准动态条件)

Fig.9 Accuracy results for 50 trails (quasi-dynamic)

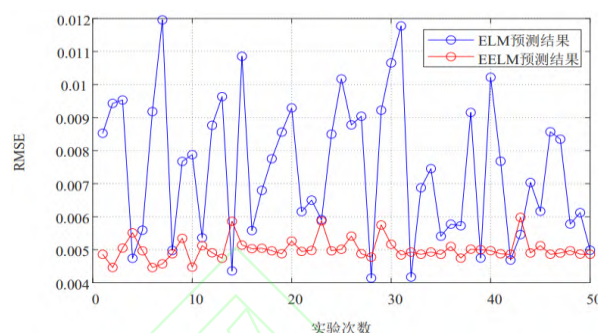


图 10 50 次实验的精度对比 (动态条件)

Fig.10 Accuracy results for 50 trails (dynamic)

3 结论

本文对数据驱动算法自身不确定性在 PEMFC 寿命长期预测过程中的量化影响问题进行研究。在 ELM 的使用过程中, ELM 的输入权重和隐藏层偏置都是随机生成的,这种随机生成所造成的不确定性会影响最终的预测结果,从而造成 ELM 预测的不稳定性。本文提出了一种集成 ELM 结构来对预测结果的随机性进行统计分析,并在稳态电流、准动态电流和动态电流负载条件下进行测试,实验结果验证了所提出方法的精确性和鲁棒性。采用该方法得到的寿命预测结果是一个区间范围,能够给使用人员提供燃料电池老化状态的多维度信息,有助于操作人员更加精确的明晰燃料电池的健康状态,避免因燃料电池因老化而突然失效对整个系统造成不可挽回的损失。最终结论如下:

- 1) 输入权重和隐藏层偏置的随机性会直接影响寿命预测的结果,通过 EELM 结构对其进行统计分析,给出 95%置信区间,可以观察到预测结果的分布,将预测结果平均处理可以提升预测精度。
- 2) 鲁棒性得到提高。通过集成结构对预测结果进行统计分析,可以使预测的稳定性和精度得到提升,这一点在准动态条件和动态条件下效果更明显。通过集合平均得到预测结果可以提高预测精度,增强系统的鲁棒性。
- 3) 将 ELM 与其他预测方法结合,寻找能够有效实施在线预测的方法,提升预测精度,将是未来工作研究的重点。

参考文献

- [1]陈锦洲, 林飞, 何洪文, 等. 质子交换膜燃料电池/电槽系统建模及负荷追踪策略[J]. 电工技术学报, 2020, 35(增刊 2): 636-643.
Chen Jinzhou, Lin Fei, He Hongwen, et al. Modeling and load tracking strategy of proton exchange membrane fuel cell/electrolyzer system[J]. Transactions of China Electrotechnical Society, 2020, 35(S2): 636-643.
 - [2]潘光胜, 顾伟, 张会岩, 等. 面向高比例可再生能源消纳的电氢能源系统[J]. 电力系统自动化, 2020, 44(23): 1-10.
Pan Guangsheng, Gu Wei, Zhang Huiyan, et al. Electricity and hydrogen energy system towards accomodation of high proportion of renewable energy[J]. Automation of Electric Power Systems, 2020, 44(23): 1-10.
 - [3]Li Qi, Wang Tianhong, Li Shihan, et al. Online extremum seeking-based optimized energy management strategy for hybrid electric tram considering fuel cell degradation[J]. Applied Energy, 2021, 285: 116505.
 - [4]张雪霞, 黄平, 蒋宇, 等. 动态机车工况下质子交换膜燃料电池电堆衰退性能分析[J]. 电工技术学报, 2022, 37(18): 4798-4806.
Zhang Xuexia, Huang Ping, Jiang Yu, et al. Degradation performance analysis of proton exchange membrane fuel cell stack under dynamic locomotive conditions[J]. Transactions of China Electrotechnical Society, 2022, 37(18): 4798-4806.
 - [5]Jouin M, Gouriveau R, Hissel D, et al. Prognostics of PEM fuel cell in a particle filtering framework[J]. International Journal of Hydrogen Energy, 2014, 39(1): 481-494.
 - [6]Chen Kui, Laghrouche S, Djerdir A. Fuel cell health prognosis using Unscented Kalman Filter: Postal fuel cell electric vehicles case study[J]. International Journal of Hydrogen Energy, 2019, 44(3): 1930-1939.
 - [7]Bressel M, Hilairet M, Hissel D, et al. Remaining useful life prediction and uncertainty quantification of proton exchange membrane fuel cell under variable load[J]. IEEE Transactions on Industrial Electronics, 2016, 63(4): 2569-2577.
 - [8]Zuo Jian, Lv Hong, Zhou Daming, et al. Deep learning based prognostic framework towards proton exchange membrane fuel cell for automotive application[J]. Applied Energy, 2021, 281: 115937.
 - [9]唐钧涛, 戚志东, 裴进, 等. 基于电荷泵的燃料电池有源网络升压变换器[J]. 电工技术学报, 2022, 37(4): 905-917.
Tang Juntao, Qi Zhidong, Pei Jin, et al. An active network DC-DC boost converter with a charge pump employed in fuel cells[J]. Transactions of China Electrotechnical Society, 2022, 37(4): 905-917.
 - [10]Tang Xingwang, Qin Xiaojin, Wei Kai, et al. A novel online degradation model for proton exchange membrane fuel cell based on online transfer learning[J]. International Journal of Hydrogen Energy, 2023, 48(36): 13617-13632.
 - [11]Peng Yulin, Chen Tao, Xiao Fei, et al. Remaining useful lifetime prediction methods of proton exchange membrane fuel cell based on convolutional neural network-long short-term memory and convolutional neural network-bidirectional long short-term memory[J]. Fuel Cells, 2023, 23(1): 75-87.
 - [12]He Kai, Mao Lei, Yu Jianbo, et al. Long-term performance prediction of PEMFC based on LASSO-ESN[J]. IEEE Transactions on Instrumentation and Measurement, 1964, 70: 3511611.
 - [13]Jin Jiashu, Chen Yuepeng, Xie Changjun, et al. Remaining useful life prediction of PEMFC based on the multi-input cycle reservoir with jump network[J]. International Journal of Hydrogen Energy, 2023, 48(34): 12844-12860.
 - [14]Zhang Chu, Hu Haowen, Ji Jie, et al. An evolutionary stacked generalization model based on deep learning and improved grasshopper optimization algorithm for predicting the remaining useful life of PEMFC[J]. Applied Energy, 2023, 330: 120333.
 - [15]赵波, 张领先, 章雷其, 等. PEMFC 剩余使用寿命直接预测的混合方法[J/OL]. 中国电机工程学报, 2023: 1-14. <https://doi.org/10.13334/j.0258-8013.pcsee.230769>.
- Zhao Bo, Zhang Lingxian, Zhang Leiqi, Xie Changjun, Chen Zhe, Liu Xiangwan. A Hybrid Method for Direct Prediction of PEMFC Remaining Useful Life[J]. Proceedings of the CSEE, 2023: 1-14. <https://doi.org/10.13334/j.0258-8013.pcsee.230769>.

- [16]Ma Rui, Xie Renyou, Xu Liangcai, et al. A hybrid prognostic method for PEMFC with aging parameter prediction[J]. IEEE Transactions on Transportation Electrification, 2021, 7(4): 2318-2331.
- [17]Cheng Yujie, Zerhouni N, Lu Chen. A hybrid remaining useful life prognostic method for proton exchange membrane fuel cell[J]. International Journal of Hydrogen Energy, 2018, 43(27): 12314-12327.
- [18]Chen Kui, Laghrouche S, Djerdj A. Degradation model of proton exchange membrane fuel cell based on a novel hybrid method[J]. Applied Energy, 2019, 252: 113439.
- [19]Dong Qichao, Zhou Yafu, Lian Jing, et al. Online adaptive humidity monitoring method for proton exchange membrane fuel cell based on fuzzy C-means clustering and online sequence extreme learning machine[J]. Electrochimica Acta, 2022, 429: 141059.
- [20]Xie Yucen, Zou Jianxiao, Li Zhongliang, et al. A novel deep belief network and extreme learning machine based performance degradation prediction method for proton exchange membrane fuel cell[J]. IEEE Access, 2020, 8: 176661-176675.
- [21]Zhang Xuexia, Yu Zixuan, Chen Weirong. Life prediction based on D-S ELM for PEMFC[J]. Energies, 2019, 12(19): 3752.
- [22]Deng Zhihua, Chan S H, Chen Qihong, et al. Efficient degradation prediction of PEMFCs using ELM-AE based on fuzzy extension broad learning system[J]. Applied Energy, 2023, 331: 120385.
- [23]刘嘉蔚, 李奇, 陈维荣, 等. 基于核超限学习机和局部加权回归散点平滑法的 PEMFC 剩余使用寿命预测方法[J]. 中国电机工程学报, 2019, 39(24): 7272-7279, 7500.
- Liu Jiawei, Li Qi, Chen Weirong, et al. Remaining useful life prediction method of PEMFC based on kernel extreme learning machine and locally weighted scatterplot smoothing[J]. Proceedings of the CSEE, 2019, 39(24): 7272-7279, 7500.
- [24]Li Changzhi, Lin Wei, Wu Hangyu, et al. Performance degradation decomposition-ensemble prediction of PEMFC using CEEMDAN and dual data-driven model[J]. Renewable Energy, 2023, 215: 118913.
- [25]Xia Zetao, Wang Yining, Ma Longhua, et al. A hybrid prognostic method for proton-exchange-membrane fuel cell with decomposition forecasting framework based on AEKF and LSTM[J]. Sensors, 2022, 23(1): 166.
- [26]Hua Zhiguang, Zheng Zhixue, Pahon E, et al. Remaining useful life prediction of PEMFC systems under dynamic operating conditions[J]. Energy Conversion and Management, 2021, 231: 113825.
- [27]Hua Zhiguang, Zheng Zhixue, Pahon E, et al. A review on lifetime prediction of proton exchange membrane fuel cells system[J]. Journal of Power Sources, 2022, 529: 231256.
- [28]Liu Hao, Chen Jian, Hou Ming, et al. Data-based short-term prognostics for proton exchange membrane fuel cells[J]. International Journal of Hydrogen Energy, 2017, 42(32): 20791-20808.
- [29]Mezzi R, Morando S, Steiner N Y, et al. Multi-reservoir echo state network for proton exchange membrane fuel cell remaining useful life prediction[C]//IECON 2018 - 44th Annual Conference of the IEEE Industrial Electronics Society, Washington, DC, USA, 2018: 1872-1877.
- 作者简介
杨 洪 男, 2000 年生, 硕士研究生, 研究方向为氢燃料电池寿命预测与健康管理。
E-mail: yan9qi97@163.com
华志广 男, 1990 年生, 教授、博导, 研究方向为氢燃料电池寿命预测与健康管理。
E-mail: zhiguang.hua@nwpu.edu.cn (通信作者)

Research on PEMFC Lifetime Prediction Based on Ensemble Extreme Learning Machine

Yang Qi¹ Chen Jingwen¹ Hua Zhiguang² Li Xianglong³ Zhao Dongdong² Lan Tianyi¹
Dou Manfeng²

(1. School of Electrical and Control Engineering Shaanxi University of Science and Technology
Xi'an 710021 China

2. School of Automation Northwestern Polytechnical University Xi'an 710072 China

3. School of Materials Science and Engineering Beijing University of Chemical Technology
Beijing 100029 China)

Abstract Data-driven methods can accurately predict the remaining useful lifetime of the proton exchange membrane fuel cell (PEMFC), the improvement of the prediction performance is the current research hotspot in the field of lifetime prediction. Aiming to improve prediction accuracy and robustness in the lifetime prediction field of PEMFC, an ensemble extreme learning machine (ELM) structure is proposed to predict the lifetime of PEMFC in the long term based on the statistical lifetime prediction principle. The ensemble structure contains 50 times repetitive tests, and for each ELM, it is optimized by the partial reinforcement optimizer algorithm, which improves the lifetime prediction accuracy.

Firstly, the aging data were filtered by the moving average filtering method to filter out the noise and spikes to get smooth data. Then an ensemble extreme learning machine (EELM) model is introduced to predict the lifetime of the PEMFC in the long term by independent ELMs in the ensemble structure. The EELM model adopts a multi-input structure and optimizes the input weights and hidden layer bias by Partial Reinforcement Optimizer to improve the model's generalization ability and prediction accuracy. After that, the prediction results are assembled, and the ensemble structure contains 50 independent ELMs, and the 50 times prediction results are statistically analyzed. Assuming the weights of the 50 times predictions are the same, the final prediction value is obtained by averaging the predictions at each time point. In the results of the long-term prediction, the average and 95% confidence interval of the prediction results of the ensemble ELM are given. To verify the validity and feasibility of the proposed method, three sets of aging data sets under steady-state, quasi-dynamic and dynamic conditions are verified. Based on the experiments, it can be obtained that the RMSE of the proposed method is 0.010 44 and the MAPE is 0.221 8% under steady state, 0.023 73 and 0.6296% under quasi-dynamic, and 0.004 861 and 7.716% under dynamic. Comparing the prediction results with the cycle reservoir with jump (CRJ), echo state network (ESN), and group method of data handling (GMDH) in the past literature, the EELM model can obtain more accurate results with less training data. This effectively reflects the fact that EELM has a stronger generalization ability. The robustness of the EELM is also analyzed in these three conditions. For the robustness analysis, the ELM and EELM are subjected to 50 repetitions of experiments, and the RMSE is used as the evaluation index. The experimental results show that the prediction accuracy of the EELM is higher than that of most of the independent ELMs, and the prediction results of EELM are less fluctuating and more centrally distributed. This indicates that the EELM prediction is more stable, and the ensemble structure effectively improves the robustness of the ELM.

The validation results show that: (1) the randomness of input weights and hidden layer bias will directly affect the results of lifetime prediction, which is statistically analyzed by the EELM structure with 95% confidence intervals, and the distribution of the prediction results can be observed. The prediction accuracy can be improved by averaging the prediction results. (2) The robustness is improved. Statistical analysis of the prediction results through the ensemble structure can improve the stability and accuracy of the prediction, which is more obvious in the quasi-dynamic and dynamic conditions. Getting the prediction results through ensemble averaging can improve the prediction accuracy and enhance the system's robustness. (3) Combining ELM with other prediction methods to find methods that can effectively implement online prediction and improve prediction accuracy will be the focus of research in future work.

Keywords: Proton exchange membrane fuel cell (PEMFC), extreme learning machine (ELM), ensemble structure, partial reinforcement optimizer