

文章编号:1004-3918(2024)12-1717-24

# 锂离子电池健康状态评估方法研究新进展

张欣怡<sup>1</sup>, 伍嘉浩<sup>1</sup>, 张璐平<sup>1</sup>, 戴厚德<sup>2</sup>, 柏文琦<sup>3</sup>,

林海军<sup>1</sup>, 张甫<sup>1</sup>, 杨宇祥<sup>1</sup>

(1. 湖南师范大学 工程设计学院, 长沙 410081; 2. 中国科学院海西研究院 泉州装备制造研究中心, 福建 泉州 362200;  
3. 湖南省计量检测研究院, 长沙 410018)

**摘要:** 锂离子电池(LIB)健康状态(SOH)的评估对于电池管理效率和安全性至关重要。详细回顾了锂电池SOH估计方法的最新研究进展,介绍了基于容量、内阻、电量、循环次数和功率的SOH五个主要定义,系统地梳理了实验测量方法、模型估计方法和数据驱动方法三类主要的SOH估计方法,并深入分析了每种方法的优点和局限性。综合分析表明,当前的SOH估计方法在精度和实用性方面仍存在显著挑战,需要在以下几个方面进行深入研究:开发自适应的SOH估计方法、提升数据驱动方法的精度和鲁棒性、发展多物理场耦合模型以更准确地描述电池行为。这些研究有望在实现高精度SOH估计的同时,扩大其在更多测量场合的适用性。研究结果有助于对SOH估计方法的前沿理论分析和实际应用的理解,并探索LIBs SOH估计的进一步发展方向。

**关键词:** 锂离子电池; 健康状态估计; 实验检测法; 模型估计法; 数据驱动法

中图分类号: TM912 文献标识码: A

## New Research Progress of the State of Health Estimation Methods for Lithium-Ion Batteries

ZHANG Xinyi<sup>1</sup>, WU Jiahao<sup>1</sup>, ZHANG Luping<sup>1</sup>, DAI Houde<sup>2</sup>, BAI Wenqi<sup>3</sup>,

LIN Haijun<sup>1</sup>, ZHANG Fu<sup>1</sup>, YANG Yuxiang<sup>1</sup>

(1. College of Engineering and Design, Hunan Normal University, Changsha 410081, China;  
2. Quanzhou Equipment Manufacturing Research Center, Haixi Institute of Chinese Academy of Sciences, Quanzhou 362200, Fujian, China;  
3. Hunan Institute of Metrology and Testing, Changsha 410018, China)

**Abstract:** Assessment of state of health (SOH) for lithium-ion batteries (LIBs) is crucial for the efficiency and safety of battery management. This review summarizes the latest research progress on SOH estimation methods for LIBs, introduces five main definitions of SOH based on capacity, internal resistance, energy, cycle count, and power respectively, and provides a detailed overview of three major SOH estimation methods: experimental measurement methods, model-based estimation methods, and data-driven methods. The advantages and limitations of each method are analyzed in depth. The comprehensive analysis shows that there are still significant challenges in the accuracy and practicability of the current SOH estimation methods, and in-depth researches are needed in the following aspects: developing adaptive SOH estimation methods, improving the accuracy and robustness of data-driven methods, and developing multi-physics coupling models to describe battery behavior more accurately, which

收稿日期: 2024-07-10

基金项目: 国家自然科学基金(32171366, 32201134); 湖南省自然科学基金(2022JJ90035, 2024JJ5271)

作者简介: 张欣怡(2000-), 女, 硕士, 研究方向为锂电池健康状态检测

通信作者: 杨宇祥(1974-), 男, 教授, 博士, 研究方向为信号检测与处理

柏文琦(1980-), 男, 高级工程师, 硕士, 研究方向为电磁计量

are expected to enhance the accuracy of SOH estimation while expanding its applicability to more measurement scenarios. This review will promote understanding of advanced theoretical analysis and practical applications of battery SOH estimation methods, and explore further development directions of battery SOH estimation.

**Key words:** lithium-ion batteries; SOH estimation; experimental measurement methods; model estimation methods; data-driven method

锂离子电池(Lithium-ion battery, LIB)作为一种可代替传统铅酸电池和镍氢电池的新型电能能源储能器件<sup>[1]</sup>,具有能量密度和功率密度大、循环寿命长、自放率低、工作温度范围宽、制造成本低、充放电周期长等优点,因此常被广泛应用于便携式终端、新能源电动汽车及可再生能源等相关领域<sup>[2-6]</sup>,是下一代便携式电子产品、电动汽车最具前景的能源之一<sup>[7]</sup>.然而,LIB在生产、保存和使用过程中可能会出现许多问题.电池材料、制造工艺、工作环境等异常因素都会导致系统失常<sup>[8]</sup>.同时,由于电池内部正负极发生副反应,电池寿命会随着使用时间的增加而下降,也称为电池老化现象<sup>[9]</sup>.一般认为,当电池容量下降至初始容量的80%以下或电池内阻增加100%时,达到LIB的终止寿命(End of Life, EOL),该状态下电池无法再继续正常稳定的工作<sup>[10]</sup>.故对LIB的健康状态进行精准评估,有助于及时确认LIB的老化状态,确保LIB的其运行安全。

## 1 评估方法概述

锂电池的健康状态(State of health, SOH)以当前电池与新电池电量存储容量的百分比表示,可用于定量描述电池从使用寿命开始到结束的当前性能状态. SOH也可以定义为,电池从充满电状态以一定速率放电时,在截止电压下释放的容量与一定条件下电池额定容量的百分比<sup>[11]</sup>.然而,LIB在充放电过程中内部物理化学过程错综复杂,SOH评估受到许多内外部因素的影响,难以直接测量获取. LIB老化退化最直接的指标是可用容量的减少<sup>[12]</sup>和内部阻抗的增加<sup>[13]</sup>.因此目前主流的SOH指标主要包括电池容量和内阻(阻抗)<sup>[14]</sup>.

对于电池容量,SOH定义如下<sup>[15-16]</sup>:

$$\text{SOH}_C = \frac{C_a}{C_r} \times 100\%. \quad (1)$$

式中: $C_a$ 表示电池使用后的最大可用容量; $C_r$ 表示新电池在工厂时的额定容量.这个定义由于其简单性和易于测量而被广泛使用.

对于电池内阻,SOH定义如下<sup>[17]</sup>:

$$\text{SOH}_R = \frac{R_{\text{EOL}} - R}{R_{\text{EOL}} - R_{\text{NEW}}} \times 100\%. \quad (2)$$

式中: $R_{\text{EOL}}$ 为电池使用寿命结束时的内阻; $R_{\text{NEW}}$ 是新电池的内阻; $R$ 为当前状态下的电池内阻.虽然这个定义较为直观,但由于它受到温度和荷电状态等外部因素的影响,因此很难有效利用.

同样,SOH可以用电量的百分比来表示<sup>[18-19]</sup>:

$$\text{SOH}_Q = \frac{Q_{\text{am}}}{Q_{\text{nm}}} \times 100\%. \quad (3)$$

式中: $Q_{\text{am}}$ 为当前电池的最大放电量; $Q_{\text{nm}}$ 为新电池的最大放电量.该定义为电池退化提供了一个独特的视角,但直接的容量测量并不总相一致.

另外,SOH也可以用电池循环次数的百分比来表示<sup>[20]</sup>:

$$\text{SOH}_c = \frac{C_{\text{rem}}}{C_{\text{tot}}} \times 100\%. \quad (4)$$

式中: $C_{\text{rem}}$ 为当前电池的剩余循环次数; $C_{\text{tot}}$ 是电池从开始到结束寿命的总循环次数.虽然这种方法提供了电池健康状况的长期视角,但对总循环次数的预测不太精确.

此外,SOH也可以用功率百分比来表示<sup>[21]</sup>:

$$\text{SOH}_p = \frac{A_{\text{ocmp}} - A_{\text{min}}}{A_{\text{new}} - A_{\text{min}}} \times 100\% . \quad (5)$$

式中: $A_{\text{ocmp}}$ 为实时启动功率; $A_{\text{new}}$ 是荷电状态(State of Charge, SOC)为100%时的预测启动功率, $A_{\text{min}}$ 是所需的最小启动功率. 这种基于功率的定义特别适用于需要高功率输出的场景,但无法提供电池整体健康状况的全面视图.

上述给出了目前文献中最全面的电池SOH定义,其中容量(式(1))和电量(式(3))的定义最常见,且具有较高的通用性. 可测量性与内阻(式(2))、循环次数(式(4))和功率百分比(式(5))的定义进行比较. 例如,在式(2)中,内阻与SOC和温度有关,不易测量,而在式(4)中,剩余循环数和总循环数通常无法准确预测.

除此之外,LIB充放电过程中某些参数将随着电池的衰减老化逐渐发生变化,因此衍生了多种SOH新型估算方法. 例如,基于开路电压曲线(电池处于平衡态时的电压值)的微分电压或微分容量曲线分析,将电池在不同电压平台期的放电容量的变化作为SOH指示因子<sup>[22]</sup>;利用等效电路模型仿真电池恒压充电过程中的充电电流变化曲线,建立基于模型参数的SOH指示因子等<sup>[23]</sup>. 近年来,大数据技术的蓬勃发展催生了大量数据驱动的SOH估计算法,这类算法具有较高的灵活性,并且无需对电池电化学机理进行深入描绘<sup>[24]</sup>. 这些SOH估算方法凭借输入参数可直接在线快速测量、无需额外表征测试等优点,在某些实际工程应用场景中展现了良好的应用前景.

近年来,关于动力LIB的SOH检测已经成为电池检测的研究热点. 根据检测原理的不同,将目前SOH的估算方法总体上分为实验检测法、模型估计法和数据驱动法三类(图1). 详细阐述了早期综述中未涵盖的最新关键进展,例如对公共电池老化数据集和电池组SOH估计方法的综述. 讨论了这些电池SOH估算方法的优点和局限性,并分析了未来的发展趋势和研究挑战,以推动电池SOH估算的发展.

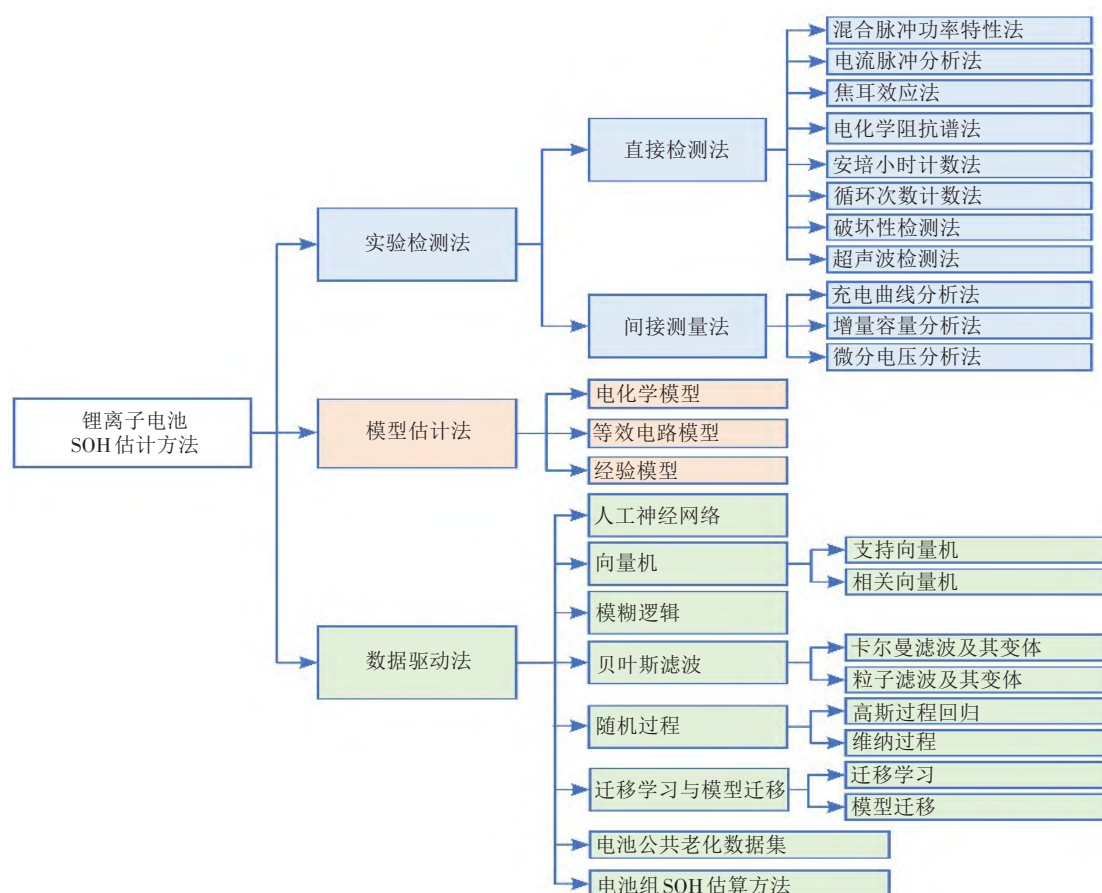


图1 锂离子电池SOH估计方法分类

Fig.1 Classification of SOH estimation methods for lithium-ion batteries

## 2 实验检测法

实验检测法是在实验室环境下对锂电池的SOH进行估算,需要进行大量精确的测量实验来分析电池的健康特征参数,如电池容量、电池阻抗、电池循环次数等<sup>[25-26]</sup>。该方法可以从物理角度了解锂电池当前的SOH,为其他估算方法提供准确的校准数据和理论基础<sup>[2]</sup>。实验检测法包括直接检测法和间接测量法。直接检测法通过直接测量电池健康状态指标,从而对电池SOH进行分析。间接测量法通过得到的电池相关数据进行分析,从而得出SOH的相关参数<sup>[27]</sup>。

近年来,实验检测法在提高精度、缩短测试时间和增强实际应用适用性方面取得了显著进展。例如,混合脉冲功率特性法(HPPC)通过改进脉冲测试流程,显著提升了电池健康状态的估算精度。Huang等<sup>[28]</sup>通过集成SOC和温度因素,减少了HPPC测量中的误差,为后续研究提供了更精确的方法。Sun和Kainz<sup>[29]</sup>则通过Taguchi方法优化了HPPC的模型,使其在不同的应用场景下表现出色。电流脉冲分析法(CPA)凭借其快速响应能力和对动态条件的鲁棒性,在电池内阻测量领域得到广泛应用。Bao等<sup>[30]</sup>开发的实时内阻检测装置,使CPA能够在复杂应用环境中保持稳定的测量精度。电化学阻抗谱法(EIS)则在表征电池内部化学特性方面表现突出。Tang等<sup>[31]</sup>通过结合分数阶电路模型与机器学习技术,显著加快了EIS的预测速度,并提升了测量精度。笔者团队也开发了基于AD5941芯片的便携式EIS系统,使得EIS的实用性大大增加<sup>[32]</sup>。

尽管实验检测法在锂电池SOH估算精度方面取得了许多进展,但仍面临高成本、长测试时间和复杂环境下精度受限等挑战<sup>[14]</sup>。未来需要进一步关注降低设备成本、缩短测试时间及开发便携式、适用于现场测量的检测装置,从而提升实验检测法在实际应用中的可行性和有效性。

### 2.1 直接检测法

直接检测法需要测量LIB的特征参数(如电池容量、电池内阻、电池循环次数等),再根据不同方法得到其精确的SOH值<sup>[2,33]</sup>。直接检测法主要有混合脉冲功率特性法、电流脉冲分析法、焦耳效应法、电化学阻抗谱法、安培小时计数法、循环次数计数法、破坏性检测法、超声波检测法等。

#### 2.1.1 混合脉冲功率特性法

混合脉冲功率特性法(HPPC)又称混合脉冲法(Hybrid Power Pulse Test, HPPT),是一种离线条件下通过直流电测量电池内阻的方法<sup>[34]</sup>。由于需要准确测量动态功率能力和内阻,HPPT可以更全面地了解电池的健康状况,尤其是在其他技术不满足要求的情况下。该方法依赖于包含放电和再生脉冲的实验曲线的分析<sup>[35]</sup>。由于不同的电池具有不同的规格和要求,因此在测试过程中必须相应地调整脉冲大小和持续时间<sup>[36]</sup>。HPPC是顺序充电和放电脉冲的组合<sup>[37]</sup>。根据顺序充放电模式可以分为正常电池充放电循环、舰队式过放电循环、24 h式过放电循环、电池过充电循环<sup>[27]</sup>。锂电池的HPPC操作流程如图2所示。

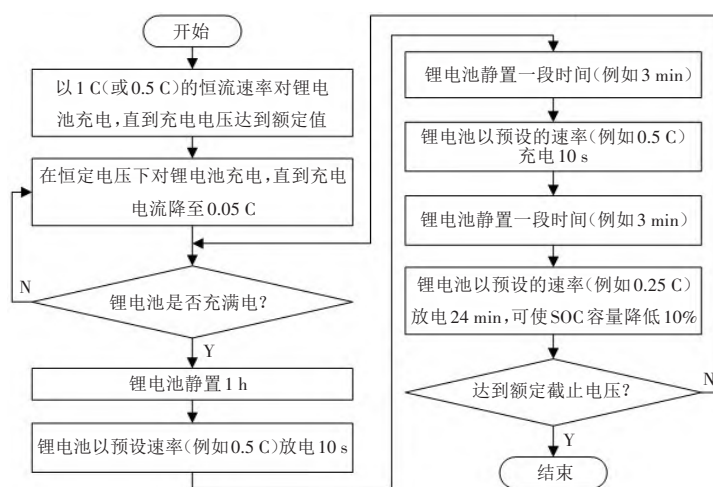


图2 锂电池的HPPT流程图

Fig.2 The HPPT flow chart of lithium battery



此外, Huang等<sup>[38]</sup>通过集成SOC和温度减少了误差, 为Liu等<sup>[39]</sup>增强热分析铺平了道路. Sun和Kainz<sup>[29]</sup>使用Taguchi方法进一步提高了模型精度, Lyu等<sup>[40]</sup>通过将L-HPPC与CLTC结合, 成功缩短了测试时间. 基于上述研究, Białoń等<sup>[41]</sup>为车辆中的特定LIB开发了量身定制的模拟模型.

尽管HPPC取得了进步, 但仍面临挑战, 它通常依赖于单一的标准, 可能忽略了电池行为的复杂方面, 如充电状态、温度和电流方向<sup>[42]</sup>. 同时, 基于HPPC的模型在恒流放电测试中可能难以准确预测<sup>[43]</sup>.

### 2.1.2 电流脉冲分析法

电流脉冲分析法(Current Pulse Analysis, CPA)是一种通过采集电池放电脉冲前后的电压差来估计电池直流内阻的方法<sup>[44]</sup>, 一般不适合线测量应用中<sup>[30]</sup>. CPA法的测量原理如下式:

$$R_i = \frac{\Delta U}{\Delta I}. \quad (6)$$

式中: $R_i$ 表示电池在某一时刻的内阻; $\Delta I$ 表示放电脉冲电流的幅值; $\Delta U$ 表示在此放电脉冲下产生的电压降<sup>[45]</sup>.

Widanage等<sup>[46]</sup>利用脉冲多线信号增强了CPA的动态响应, 为该领域研究提供了新思路<sup>[47]</sup>. Bao等<sup>[30]</sup>在CPA中开发了一种实时内阻检测装置, 通过恒流源控制脉冲电流来稳定测量, 如图3所示. 该检测装置在电池两电极之间插入电流脉冲电路, 在电池正极附近设置脉冲开关来控制电流脉冲的时间. 值得一提的是, 脉冲电流的数值由电路中的恒流源控制, 有效解决了放电过程中电流波动造成的测量不稳定问题.




图3 电池内阻检测装置

Fig.3 Battery internal resistance detection device

与其他方法相比, CPA因其快速响应和对动态条件的弹性特点而受到青睐<sup>[48]</sup>. 然而, 它也面临着诸多问题, 例如放电过程中的可变电压降和电荷转移反应的非线性, 这些都会影响其精度<sup>[49]</sup>. 同时, 该方法还需要预热电池以获得最佳性能, 特别是在较低温度下<sup>[50]</sup>.

### 2.1.3 焦耳效应法

焦耳效应(Joule Effect, JE)法是由焦耳效应衍生出来的一种估计电池内阻的物理方法, 其能够定量描述传导电流经过负载时将电能转换为热能的定律, 即单位时间内产生的热量与传导电流的平方和负载电阻成正比<sup>[2, 51]</sup>. 因此, JE法也是测量电池内阻的常用方法<sup>[47]</sup>. 为了确定内阻, 必须使用电化学量热计来控制循环过程中的温度变化<sup>[21]</sup>. 测量原理如下式所示:

$$R_i = \frac{Q_i}{I^2 t} = \frac{Q_i}{(C_{cal} + C_{cell}) \times \Delta T}. \quad (7)$$

式中: $R_i$ 表示电池在0~ $i$ 时段的平均内阻; $Q_i$ 表示电池在0~ $i$ 时段总共释放的热量; $I$ 表示电池在0~ $i$ 时段的平均放电电流; $t$ 表示电池的持续放电时间; $C_{cal}$ 为量热计的热容; $C_{cell}$ 为电池的热容; $\Delta T$ 为温差.

在实际应用中, 焦耳效应法通常使用量热计来测量电池热量并估计内阻. 这种方法适用于需要较低成本和精度的场景, 对电池动态不确定性具有良好的鲁棒性和精度<sup>[47, 52]</sup>. Pm等<sup>[53]</sup>专注于恒流循环中的能量损失测量, 而Shahjalal等<sup>[54]</sup>集成了焦耳热源和熵热源, 改进了实时电热模拟. 然而, 该方法有其局限性. 它往往忽略了一些方面, 如电池内部的可逆熵热、电池阴极阳极的副反应和混合热, 这些都会影响内阻测量的准确性<sup>[26, 55]</sup>.

### 2.1.4 电化学阻抗谱法

电化学阻抗谱法(Electrochemical Impedance Spectroscopy, EIS)是一种用于电池阻抗测量的技术. 该方法利用广泛频率范围内的小正弦电流或电压作为微扰信号, 使研究人员能够观察电池系统内的阻抗变化<sup>[56-58]</sup>. 值得注意的是, 电池EIS数据、SOH和LIB内部的老化表现之间存在很强的相关性. EIS不仅可以获得阻抗信息, 还可以获得电荷转移电阻和固体电解质界面等参数<sup>[26]</sup>. 这些参数可以同时反映LIB的外

部电气特性和内部化学特征。因此,EIS逐渐成为电池表征和建模中不可或缺的工具<sup>[59]</sup>。此外,弛豫时间分布(DRT)成为一种优越的机制诊断工具,能够提高EIS分析精度,且传输线模型(TLM)在分析多孔电极方面表现出色<sup>[60-61]</sup>。

EIS的最新研究有望解决其传统局限性。Tang等<sup>[31]</sup>将分数阶电路模型与机器学习相结合,用于快速预测EIS。Duan等<sup>[62]</sup>使用CNN从恒流充电数据中预测LIB的EIS,绕过了传统的复杂性。He等<sup>[63]</sup>和Py等<sup>[64]</sup>的研究进一步增强了EIS的应用,前者使用DRT寻址半圆重叠,后者通过基于高斯过程的框架提高了分析精度。笔者团队曾使用ADI公司最新研发的AD5941芯片开发了便携式、经济高效的EIS测量系统,用于获取0.1~2000 kHz的电池EIS数据,且能够对LIB进行等效电路建模,了解不同条件下LIB的SOH特性<sup>[32]</sup>。

然而,EIS也面临着诸多的挑战:其测量可能会受到准非线性电化学反应的影响,特别是在充放电循环期间;专用设备的高成本限制了其广泛使用;电化学系统带宽的固有限制导致EIS分析的模糊性,使得难以辨别特征时间常数的微小差异<sup>[2, 65-66]</sup>。

### 2.1.5 安培小时计数法

安培小时计数法(Ampere-hour Counting, AHC),又称库仑计数法,旨在已知电池额定容量的情况下精确计算荷电状态(State of Charge, SOC)<sup>[67]</sup>,通过计算流经电池电流对时间的积分,从而获得电池在一段时间内充电或放电的电量<sup>[68]</sup>:

$$\text{SOC}(t) = \text{SOC}(t_0) - \frac{1}{Q_N} \eta \int_{t_0}^t I(t) dt. \quad (8)$$

式中: $\text{SOC}(t_0)$ 表示初始时间 $t_0$ 时的SOC; $Q_N$ 表示额定容量; $\eta$ 表示库仑效率,其等于1且保持恒定; $I(t)$ 表示电流,充电时为负,放电时为正。

AHC方法的创新主要集中在提高准确性和弹性上。Locorotondo等<sup>[69]</sup>引入增量容量分析来减轻其开环性质。Wang等<sup>[70]</sup>将AHC与混合电池组的重新校准相结合,即使在传感器干扰下也能达到2%的显著精度。Zhao等<sup>[71]</sup>将AHC与EKF框架相结合,利用斜率方差和欧几里得距离进行快速纠错,进一步提高了SOC精度。

AHC方法的主要优点是简单、计算量较小、对于测试环境要求不高及易于实现<sup>[72]</sup>。然而,其主要限制在于其开环、纯粹集成的性质、初始SOC的不准确性<sup>[73]</sup>及测试环境和外部噪声的影响随着充放电时间累积不断扩大<sup>[74]</sup>。此外,AHC方法在高温测试条件下或存在不稳定电流波动时可能产生显著误差。

### 2.1.6 循环次数计数法

循环次数计数法(Cycle Number Counting, CNC)通过比较锂电池完全放电的循环次数和总循环次数来量化SOH<sup>[2, 20]</sup>。在该方法中,将电池的循环次数作为锂电池老化情况的重要指标。通过识别当前循环次数和电池预计总循环次数,获得SOH<sup>[75]</sup>。用公式(9)表示其测量原理:

$$\text{SOH} = \delta \times \frac{1 - P}{P_0} \times 100\%. \quad (9)$$

式中: $\delta$ 表示电池转换系数(一般设置为1); $P_0$ 是额定电池循环次数; $P$ 是电池已完全放电次数。

针对CNC方法的局限性,Huang等<sup>[28]</sup>率先采用局部库仑计数曲线结合遗传算法的数据驱动方法,显著提高了CNC的精度和计算效率。Wang等<sup>[76]</sup>引入了movIRVM-Coulomb方法,这是一种机器学习和库仑计数的混合方法,尤其适用于动态条件和温度变化工况下。最近,Akpınar等<sup>[77]</sup>开发了一种专门针对并网系统的算法,专注于大规模电池储能系统中的精确循环计数。

CNC方法虽然易于操作,但由于不易得到电池总寿命周期数 $P_0$ ,因此只适合于粗略估计<sup>[78]</sup>。此外, $P_0$ 要求电池完全放电,否则,需要调整转换系数<sup>[79]</sup>。最后,考虑到电池间的差异,虽然CNC方法有优点,但它需要彻底的校准,以确保不同电池系统的可靠性和匹配性。

### 2.1.7 破坏性检测法

破坏性检测法(Destructive Tests)是一种使用不同物理观测器件观察和分析特定环境中(通常是充满惰性气体的环境中)LIB内部的物理系统微观变化,来实现LIB老化机制研究的直观方法<sup>[14, 80]</sup>。该方法可分为形态表征分析(Morphology Characterization Analysis, MCA)、成分表征分析(Composition Characterization

Analysis,CCA)和结构表征分析(Structure Characterization Analysis,SCA)<sup>[80]</sup>.MCA是对电池电极表面形貌的分析,主要仪器有扫描电子显微镜(SEM)<sup>[81-84]</sup>、透射电子显微镜(TEM)<sup>[85-86]</sup>、原子力显微镜(AFM)<sup>[87-88]</sup>.CCA是分析电池表面和内部元素的组成、元素浓度的弥散及元素的化学价态,主要仪器有能量色散X射线能谱(EDX)<sup>[89-90]</sup>、X射线光电子能谱(XPS)<sup>[91-92]</sup>.SCA是分析电池内部晶体结构(原子的大小、排列和分布),其观察方法包括X射线衍射(XRD)<sup>[93-95]</sup>和拉曼光谱<sup>[96-97]</sup>.由于破坏性测试可以对电池内部进行微观测量,因此可以准确地掌握电池SOH<sup>[2]</sup>.然而,破坏性测试会对电池造成不可逆的损害,并且需要特定的高精度监测设备进行测试,因此不适合实际的工业应用<sup>[98]</sup>.

2.1.8 超声波检测法

超声波检测法(Ultrasonic Testing)为识别电池内部老化过程提供了一种开创性且非破坏性的途径.它通过换能器将超声信号引入电池,可以通过分析传播时间和总信号幅度的变化来预测SOH<sup>[99]</sup>.根据换能器接收方式的不同,超声波法可分为两种模式:第一种模式为脉冲回波模式,通过换能器实现超声信号的激发和接收;第二种模式为直通传输模式,超声信号通过两个换能器进行激发和接收<sup>[100]</sup>.Li和Zhou<sup>[101]</sup>开发了一种超声传播模型,增强了锂电池的可视化分析,为理解信号复杂性奠定了基础.Robinson等<sup>[102]</sup>注意到了空间分辨测量的重要性,为电池超声分析领域增加了深度.Cai等<sup>[103]</sup>随后将该方法应用于SOC估计,利用超声熵将理论与实际、准确的评估联系起来.Gao等<sup>[104]</sup>进一步将超声波传播与SOC联系起来,展示了该方法实时评估SOC的能力.

超声波检测技术具有明显的优势,包括其直接的方法、成本效益和非破坏性,使其成为SOH估计的一个重要方法.尽管如此,这项技术也有一些挑战难题,如何构建电池状态参数无损的声学表示模型仍然是一项复杂的工作,需要进一步研究和改进<sup>[105]</sup>.

锂电池SOH估算的直接检测方法的比较如表1所示.

表1 锂电池SOH直接检测法的比较  
Tab.1 Comparison of direct SOH test methods for lithium batteries

方法	关键参数	优点	缺点
混合脉冲功率特性法	电压、电流	在更小精度去测量LIB的特征参数 在更短的时间尺度上进行估算较高放电速率下的放电性能	需要切换充放电状态 充电电流的不均匀分布会影响SEI界面的阻抗 特征参数的电压扰动比较难以拟合
电流脉冲分析法	电流、温度	测量时间较短,测量步骤简单 对电池动态不确定性具有较强的鲁棒性	电池电压无法完全下降到额定放电电压 电荷转移反应出现非线性 无法准确获得负载下的内阻
焦耳效应法	温度	对电池动态不确定性具有良好的鲁棒性和精度	可逆熵热、电池阴极阳极的副反应和混合热容易被忽视
电化学阻抗谱法	电压、阻抗、温度	宽的频率范围内以低电流获得高精度的电池阻抗	较长的测试时间和稳定的测试环境 依赖价格高昂的设备 结果呈现在有限的带宽上
安倍小时计数法	电压、电流、温度	不需要考虑电池内部复杂机理,操作简单 对电池动态不确定性具有较强的鲁棒性	容易产生累计误差,对初始值精确性要求高
循环次数计数法	循环次数、电流、温度	在已知电池最大循环次数的情况下,估计SOH精度较高	电池最大循环次数不易精确得知 测试时间较长,难以实现在线测量 可能需要估算转换系数
破坏性检测法		对电池内部的微观情况进行测量,可以提供电池准确的退化信息	可能造成电池的不可逆破坏 依赖于特定的高精度监测设备
超声波检测法	飞行位移偏移和总信号幅值	直接、经济有效、无损	难从波形中掌握电池的SOH

2.2 间接测量法

在实际工业环境下,锂电池的容量、内阻与循环次数等都不易直接测量,因此间接测量法得到了广泛的研究.间接测量方法主要是基于已知的电池老化数据,推导出电池SOH特性参数.间接测量方法主要有充电曲线分析、增量容量分析和微分电压分析三种.



2.2.1 充电曲线分析

充电曲线分析(Charge Curve Analysis, CCA)通过分析电池的充电曲线(电池电压、电流或容量随时间的变化)来了解电池的健康状态<sup>[106]</sup>。充电过程中的电压分布本质上与 LIB 内发生的相变反应有关<sup>[107]</sup>。大多数 LIB 采用恒流恒压充电模式。为了使用 CCA 进行全面的 SOH 估计,理想情况下电池应该经历从 0% 到 100% SOC 的完整充电周期。在此循环中得出的关键指标包括恒流(Constant Current, CC)阶段充电时间、恒压(Constant Voltage, CV)阶段充电时间、CC 充电容量和 CV 充电容量<sup>[108]</sup>。如果有足够的数据集,CCA 在 SOH 预测中具有很高的精度<sup>[109]</sup>。

CCA 的最新研究多集中在提高精度和适用性上。Ni 等<sup>[110]</sup>结合 CCA 和卡尔曼滤波方法进行 SOC 估计,即使在有噪声的数据下也能实现高度的准确性。Zhang 等<sup>[111]</sup>、Feng 和 Li<sup>[112]</sup>进一步将 CCA 用于 SOH 估计和差热容分析的特征融合,在预测精度和鲁棒性方面均有显著提高。

CCA 有效性源于其在整个充电周期中对恒流和恒压阶段的详细检查<sup>[108]</sup>。然而,CCA 仍然存在一些挑战,例如温度的敏感性、电池类型和充电标准的差异<sup>[113]</sup>。并且由于电池行为的变化和外部因素的影响,CCA 的应用仍然很复杂,需要不断改进以获得更广泛的适用性。

2.2.2 增量容量分析

增量容量分析(Incremental Capacity Analysis, ICA)源于电池插层工艺的电化学性能研究,是分析电池老化机制的重要方法<sup>[122-114]</sup>。ICA 通过解析电池充电容量对电池开路电压的求导关系,得到 IC 曲线。该方法可以将电池内部的化学反应所造成的电压突变转换成 IC 曲线上的峰值和波谷,有效解决了两相转变的电池开路电压数据不易精确获取的问题<sup>[115]</sup>。

为了进一步提高 ICA 的精确性,Tian 等<sup>[116]</sup>将归一化 ICA 引入,显著降低了容量估计误差;Li 等<sup>[117]</sup>将 ICA 与灰色关联分析相结合,进一步细化 SOH 估计。针对噪声脆弱性,Tang 等<sup>[118]</sup>开发了一种无模型拟合过程,显著提高了峰值位置精度和 SOH 估计。Wang 等<sup>[119]</sup>采用了 IC 曲线的实时平滑技术,减少了误差,提高了在电动汽车上的适用性。此外,Gismero 等<sup>[120]</sup>将 ICA 用于电动汽车电池的高级 SOH 估计,取得了高精度的结果。

然而,ICA 的主要挑战是过于依赖差分电压而容易受到噪声的影响,其有效性取决于细致的数据预处理,以避免多重共线性等问题,考虑到它产生的大量数据点,多重共线性是一个潜在的挑战<sup>[37, 121]</sup>。

2.2.3 微分电压分析

微分电压分析(Differential Voltage Analysis, DVA)通过监测电池电压在短时间内与其容量相关的微小变化来估计电池的 SOH<sup>[122]</sup>。与 IC 曲线不同,DVA 强调差分电压(DV)曲线,其中波峰代表相变过程,而波谷代表相平衡位置。可以利用 DV 曲线的关键特征,如峰值位置、振幅和包络面积来预测 SOH<sup>[123-124]</sup>。DVA 相较于其他方法,仅需要很少的数据(电压、电流和时间)就可以实现对 SOH 的快速估计,但由于 DV 曲线会随着电池的老化机制而变化,尤其对电池内阻和极化的变化非常敏感,导致其失去可靠性,因此一般将 DV 曲线作为次要指标<sup>[125]</sup>。

针对此,Bensaad 等<sup>[126]</sup>简化了 DVA 的数据分析,提高了实时应用效率。Xia 等<sup>[127]</sup>将 ICA 与 DVA 结合,引入了先进的 SOH 和 RUL 预测,提高了该方法的准确性和降噪能力。但 DVA 对内部电池变化的敏感性很高,因此在其应用中必须仔细考虑以进行可靠的 SOH 评估。

锂电池 SOH 间接估计方法的比较如表 2 所示。

表 2 锂电池 SOH 间接检测法的比较

Tab.2 Comparison of indirect SOH test methods for lithium batteries

方法	关键参数	优点	缺点
充电曲线分析法	电流、电压、容量	在有该电池充足数据集的情况下,可以准确推导出电池的 SOH	充电曲线易于受到温度等外界环境的影响 同电池型号需要参考不同的标准进行充电
增量容量分析法	电压、容量	IC 曲线易于获取且信息量大 直接、无损、鲁棒性好 可与机器学习方法相结合	模型训练过于冗余,且数据预处理的任务量巨大 可能出现多重共线性问题
微分电压分析法	电压、容量	DV 曲线易于获取且信息量大 直接、无损、鲁棒性好 可与机器学习方法相结合	DV 曲线会随着电池的老化机制而变化 可靠性能不高



### 3 基于模型的估计方法

与实验测量方法不同的是,基于模型的估计方法是间接检测方法的一种扩展<sup>[128]</sup>,它通过对电池观测数据的分析模型来识别和估计电池SOH. 该方法通过建立电池的物理或电化学反应模型,观察电池内部的物理和电化学反应性能,同时获得电池系统内部状态与外部特性的关系及其老化演变规律<sup>[2]</sup>. 基于模型的估计方法一般可分为电化学反应模型法、等效电路模型法和经验模型法.

近年来,基于模型的估计方法在SOH预测领域取得了显著的研究进展. 例如,通过整合更加精准的电化学反应过程模型,能够有效模拟电池的老化机制,特别是在处理快速充电条件下的老化问题时取得了显著效果<sup>[129-130]</sup>. 同时,研究人员在模型参数的识别和优化方面也做出了创新,提升了模型在不同环境下的适应性和计算效率<sup>[131-132]</sup>. 新的优化方法不仅加快了计算速度,还进一步提升了电池寿命预测的准确性. 此外,经验模型通过大量实验数据进行校正,逐渐在快速计算和实际工业中被广泛应用,特别是在老化过程的预测方面取得了明显的进步<sup>[133-134]</sup>.

尽管如此,基于模型的估计方法在处理复杂电池行为和实现更高的精度方面仍然面临挑战. 研究人员正不断尝试通过引入机器学习和其他数据驱动技术,进一步增强模型的自适应性和在线应用能力<sup>[135-136]</sup>.

#### 3.1 电化学反应模型法

电化学反应模型法是利用多孔电极理论研究电池内部的电化学反应过程,包括开路电压、液相扩散、反应极化和欧姆极化等因素. 基于这一理论,该方法建立了一套非线性耦合偏微分方程来描述电池的电化学行为. 通过构建的电化学模型,与实际测量的电池数据相比较,可以对电池SOH进行有效评估<sup>[137]</sup>. 这种模型源于电池的工作原理,能够详尽描述电池的内部电化学反应动力学<sup>[24]</sup>,通过该方法可以确定电池的老化过程机制与固体电解质界面的生长、活性物质的损失和锂库存损失的相关性<sup>[138]</sup>. 但该方法存在求解微分方程难度大、计算过程繁琐复杂、建立标准模型困难及模型参数辨识困难等问题,从而限制了此方法的实际应用<sup>[139]</sup>.

在新兴的电化学模型浪潮中,伪二维(Pseudo-two-dimensional, P2D)模型因其在准确性和计算便捷性之间的平衡而备受关注<sup>[140]</sup>. Yin和Choe<sup>[129]</sup>将阴极单粒子模型与阳极P2D模型合并在一起,这种为快速充电而设计的混合充电方式提高了充电速度,并解决了某些老化机制的限制. Kupper等<sup>[130]</sup>采用P2D模型,通过投射的LAM、LLI等内部状态来聚焦电池老化的细微差别. 然而,由于参数不断变化,实际应用也需要考虑精度的一致性. Wang等<sup>[135]</sup>提出了一种改进的SOC估计方法,将粒子滤波方法与粒子群优化相结合进行参数微调,该方法以简化的单粒子模型为基础,有望在不同的驾驶循环中提高精度. 利用周期性参数的调整,Streb等<sup>[141]</sup>使用真实的驾驶数据对这种基于P2D模型的系统进行重新参数化.

尽管在电化学反应模型法参数化和模型复杂性方面的挑战仍然存在,但这些进步表明了电化学反应模型法向着更实用与更精确的电化学建模的转变.

#### 3.2 等效电路模型法

等效电路模型法(Equivalent Circuit Model, ECM)使用电子元件(通常由恒压源、电阻、电感、电容等基本元件组成)来模拟电池的充放电过程. 利用电路模型,可以描述电池的动态特性和容量衰减特性,从而对锂电池的SOH进行估计<sup>[142-143]</sup>. ECM参数辨识的框架主要分为以下几个方面<sup>[144]</sup>:

- 1) 电池的开路电压(Open Circuit Voltage, OCV)可以用于充电状态相关的电压源来表示.
- 2) 电池的逐渐扩散过程可以用一系列串联的并联RC网络来描述.
- 3) 电池的欧姆电阻或其直流激励响应可以通过电压源串联来表示.

通过整合这些组件,电池的运行模式可以通过一个包含电压源及各种电阻和电容的电路来模拟. 图4展示了ECM的通用模型.

根据研究领域可以将其分为时域ECM和频域ECM<sup>[145]</sup>. 此外,依据对物理模型的阻抗和电容特性的描述方法,ECM还可以进一步细分为多种模型,如Rint模型<sup>[146]</sup>、Thevenin模型<sup>[147]</sup>、PNGV模型<sup>[148]</sup>、RC网络模型<sup>[149]</sup>、非线性ECM<sup>[150]</sup>、Randles模型<sup>[151]</sup>等. ECM方法的一个显著优势在于不需要深入探讨电池的化学成分和内部反应,而是侧重于LIB的宏观特性,如欧姆内阻和开路电压. 与电化




图4 一般的m阶等效电路

Fig.4 General m-order equivalent circuit

学模型相比,ECM 的计算量显著减少<sup>[152]</sup>。

近年来,等效电路模型法在实用性和精确性方面取得了显著进展。Agarwal 等<sup>[131]</sup>提出了等效电路控制优化(ECCO)方法,有效地将优化问题转化为等效电路,从而加速了收敛。Chen 等<sup>[132]</sup>引入了动态等效电路模型,解决了电热动态问题,有效地解决了热能和电能系统整合难题。这些研究反映了 ECM 从基础电路模型向复杂的多维建模的转变,尽管在实现精确建模和特定参数识别方面存在挑战,但 ECM 的适用性得到了扩展<sup>[153]</sup>。

3.3 经验模型法

经验模型法是使用电池老化过程数据(如温度、电流速率与放电深度等)来预测 LIB 的 SOH,而不需要详细了解电化学电池设计和材料特性<sup>[154]</sup>。在该方法中,通常使用多项式、指数和幂律等作为拟合模型,以实现快速计算过程<sup>[155]</sup>。根据电池老化方式的不同,经验模型方法可分为日历模型和循环模型。一般优先考虑日历模型,因为它包含了电池的主要老化过程<sup>[156]</sup>。

众多学者针对该方法进行了研究。Baghdadi 等<sup>[133]</sup>假设电池容量的对数值呈现出逐渐下降的趋势,而电阻增加则与老化线性相关,进而提出了 Dakin 老化模型,该模型将电荷状态、温度和电流作为其经验模型的自变量,并在特定温度范围内调整老化速率。Guha 和 Patra<sup>[134]</sup>提出了一种基于双指数容量衰减模型与四阶多项式内阻增长模型相结合的方法进行容量估计的日历模型,随着数据量的增加,该模型的预测精度逐渐提高。Zhang 等<sup>[136]</sup>提出了一种基于指数模型和粒子滤波的 SOH 估计法,该方法解决了 LIB 容量衰减的非线性和非高斯因素,显著提高了预测精度。

然而,经验模型方法也存在其局限性<sup>[157-158]</sup>。首先,这些方法的准确性高度依赖于基础经验模型的精度。其次,这类模型通常忽视了对电池内部参数的内在物理意义的深入探讨。然后,构建一个经验模型需要大量的时间投入,同时收集数据集的成本也相当高昂。此外,这些模型往往受限于实验条件的规定。

基于模型的锂电池 SOH 估算分析方法比较如表 3 所示。

表 3 基于模型的锂电池 SOH 估计法比较

Tab.3 Comparison of model-based SOH estimation methods for lithium batteries

方法	关键参数	优点	缺点
电化学模型法	电流、电压、阻抗	准确,鲁棒性好 可以探究电池老化的原因	构建模型复杂 电池老化因子测试困难
等效电路模型法	电流、电压、温度	适用于不同化学成分在线电池储能 不考虑电池内部的化学成分和反应	对电池物理意义研究方面不详细
经验模型法	电流、电压、温度、电流速率、放电深度、循环次数	易于建立、适应性强	预测精度易受系统误差影响 需要经验知识

4 数据驱动法

数据驱动法通过机器学习或统计算法,直接挖掘一段时间内观察到的电池电量数据与电池 SOH 之间的关系,探索电池健康状态或老化特性的隐含信息<sup>[159]</sup>。该方法避免了模型估计方法中使用的电池模型和额外的滤波器,因而更加灵活和适用。本节将数据驱动方法大致分为基于人工神经网络的方法、基于向量机的方法、基于模糊逻辑的方法、基于贝叶斯滤波的方法、基于随机过程的方法和基于迁移学习与模型迁移的方法。

深度学习算法在处理电池健康数据时表现出色。通过人工神经网络,尤其是长短期记忆网络(LSTM),Li 等<sup>[160]</sup>提出的 AST-LSTM 模型显著提高了电池老化特征的捕捉能力,准确预测了 SOH。此类研究表明了深度学习在捕捉复杂的电池非线性行为方面的优越性。Wei 等<sup>[161]</sup>提出的 LSTM 与非线性回归模型相结合的混合算法,在实际实验中实现了极低的预测误差。

除了深度学习,基于支持向量机(SVM)的方法也显示了其在数据稀缺和高维场景下的适用性。SVM 通过优化算法有效降低了电池 SOH 估算中的误差,Feng 等<sup>[162]</sup>的 SVM 方法将 SOH 预测误差控制在了 3% 以内,进一步提升了其在不同场景中的适用性<sup>[163]</sup>。

贝叶斯滤波和随机过程方法也在电池健康状态的预测中取得了关键进展。扩展卡尔曼滤波和无迹卡尔曼滤波被广泛用于非线性和非高斯环境中的动态预测,提升了实时 SOH 估算的精度<sup>[164]</sup>。随机过程中的高斯

过程回归被证明在建模电池寿命和容量衰退时具有极高的准确性,而维纳过程通过其处理不确定性的能力,为长期的电池健康状态预测提供了新的方法<sup>[165-166]</sup>。此外,迁移学习等新兴技术的引入显著降低了对大规模训练数据的依赖,Liu等<sup>[167-168]</sup>通过将已有模型迁移到新的数据集,大幅提升了预测的准确性和适应性。

尽管数据驱动法在SOH估算中表现出色,但是仍需解决数据质量、模型的鲁棒性及实际工况复杂性等问题。未来的研究可以重点关注如何结合更多实际数据,以进一步提升预测精度和在复杂工况下的应用能力。

#### 4.1 人工神经网络

基于人工神经网络(Artificial Neural Network, ANN)的方法旨在解决电池健康状态参数的非线性特性,这些方法只需大量特征参数数据集,而无需掌握电池老化的内部原理<sup>[169]</sup>。ANN包括多种类型,如前馈神经网络(FNN)、递归神经网络(RNN)、长短期记忆网络(LSTM)、反向传播神经网络(BPNN)等。其中,LSTM是自适应时间序列预测的有效方法之一<sup>[5]</sup>。

基于ANN的方法,Li等<sup>[160]</sup>提出的用于SOH预测的AST-LSTM神经网络,采用多对一映射结构。Wei等<sup>[161]</sup>引入了一种结合非线性自回归模型与LSTM的混合算法,减少了梯度爆炸风险,并实现了小于1%的均方根误差。Ren等<sup>[72]</sup>使用PSO-LSTM进行SOC估计,与实际SOC达到了高一致性。Chen等<sup>[170]</sup>开发了AD4DBPNN模型,通过输入电压、电流、温度和充电时间来预测锂电池的SOH。最后,Manoharan等<sup>[159]</sup>采用了具有多个双向LSTM(BiLSTM)层的并行ANN(PANNs)来估计电动汽车电池的SOC,在简化架构的同时保持了高准确性<sup>[171]</sup>。

#### 4.2 基于向量机的方法

##### 4.2.1 支持向量机

支持向量机(Support Vector Machine, SVM)是一种广泛应用于非线性系统的机器学习方法,擅长使用惩罚函数和核函数技术处理样本数据的线性不可分性,通过在高维空间中构建最优分离超平面来构建分类预测模型<sup>[24, 172]</sup>。

通过SVM方法,Feng等<sup>[162]</sup>提出了一个基于SVM的在线SOH估计算法,实现了低于3%的误差。Yao等<sup>[173]</sup>通过整合交叉验证和网格搜索等优化技术,将SVM的准确性提高到95%以上。Lyu等<sup>[163]</sup>结合SVM和HKRVM的混合方法,将SOH估计误差进一步降低到2.777 3%。Liu等<sup>[174]</sup>引入了量子辐射向量回归(QRVR)到SVM中,展示了强大的泛化能力,平均误差约为1%。此外,Chatterjee等<sup>[175]</sup>将无迹卡尔曼滤波器(UKF)与SVM结合,用于电池故障检测,提高了检测速度与范围。

综上所述,这些研究结果展示了SVM在锂电池健康监测中的巨大潜力和广阔应用前景。

##### 4.2.2 相关向量机

相关向量机(Relevance Vector Machine, RVM)与SVM类似,同样是使用核函数和相关函数在高维特征空间中对数据进行非线性变换。不同之处在于,RVM比SVM使用核函数的频率更低,其高度稀疏的特性使得方程中的大量权重为零,从而提高了计算效率并避免了使用自由参数集<sup>[176-179]</sup>。常用的核函数包括Sigmoid核函数、多项式核函数、线性核函数、径向基核函数和复合核函数<sup>[180]</sup>。

Chang和Fang<sup>[181]</sup>将RVM与粒子滤波器(PF)融合,准确定位了模型的最佳性能时间段。Jia等<sup>[180]</sup>通过整合样本熵提高了RVM的预测精度,提出了一种去噪熵模型,其性能优于传统模型。Qian等<sup>[182]</sup>引入了一种独特的SOH估计方法,结合了RVM与等放电电压差的能量累积(EAEDVD)进行特征提取,利用麻雀搜索算法优化RVM参数,在测试中取得了显著的误差控制。此外,Cai等<sup>[103]</sup>强调RVM的多功能性,采用超声波无损检测来估计锂电池的SOC,通过处理超声波信号并提取其特征,开发了一种基于RVM的估计模型,将声学信号用于锂电池SOH分析。

综上,这些研究成果表明了RVM在各种应用中的适应性和潜力,特别是在电池健康监测领域。

#### 4.3 模糊逻辑法

模糊逻辑(Fuzzy Logic, FL)提供了一种独特的方法来理解输入和输出变量之间的复杂关系。与传统的二值逻辑(即真或假)不同,模糊逻辑引入了多值逻辑,通过隶属函数来区分模糊集,并处理模糊关系<sup>[183-184]</sup>。

鉴于FL在电池健康监测中的潜力,许多研究利用了其在锂电池中的优势。Saji等<sup>[185]</sup>有效地将模糊逻辑与安培小时计数法相结合,提高了荷电状态预测的准确性和速度。Wang等<sup>[186]</sup>随后应用模糊逻辑提高了LIB的均衡效率,显著减少了时间并提升了性能。Wu等<sup>[187]</sup>提出了一种动态模糊逻辑控制算法,大大提高了能效。

综上,这些研究结果表明了模糊逻辑在不同电池管理场景中的适应性及提高准确性和效率的能力。



#### 4.4 基于贝叶斯滤波的方法

基于贝叶斯滤波的方法源自隐马尔可夫模型,其主要内容是利用观测数据构建概率密度函数(Probability Density Function, PDF)的形式参数估计模型<sup>[188]</sup>。其关键问题是如何将置信度转换为可计算的PDF或可观测的分布特征,因此贝叶斯滤波算法通常分为参数滤波(如卡尔曼滤波器及其变体)和非参数滤波(如粒子滤波器及其变体)<sup>[2, 189]</sup>。

##### 4.4.1 卡尔曼滤波及其变体

经典的卡尔曼滤波(Kalman Filter, KF)算法是一种可靠且成熟的高斯线性动态估计方法,它由一组递归方程组成,在系统运行时进行重复运算<sup>[190]</sup>。但由于锂电池的老化过程是宏观时间下的非线性衰退过程,因此需保留传统KF优势的前提下进行非线性动态改造。应用比较广泛的KF变体包括扩展卡尔曼滤波器EKF<sup>[191-192]</sup>、双扩展卡尔曼滤波D-EKF<sup>[193-194]</sup>、无迹卡尔曼滤波器UKF<sup>[164, 195]</sup>等。

##### 4.4.2 粒子滤波及其变体

经典的粒子滤波(Particle Filter, PF)算法将蒙特卡洛采样原理和递归贝叶斯推断相结合,其算法核心是找到一组具有相关重要性权重的随机粒子样本表示后验概率密度。此类方法适用于处理非高斯非线性的在线动态问题,且不需要大量历史研究数据作为基础,是KF算法的发展和延伸<sup>[196]</sup>。然而,关于经典PF算法存在粒子多样性退化的问题,此类问题源于算法本身的规则,由于无法获得最新的观测数据,导致只有极个别参数作为重要权重,而其他参数权重则趋近于零<sup>[197]</sup>。根据此类情况,可以采取两种策略解决问题。一是采用重复采样,二是选择合理的后验分布建议<sup>[16]</sup>。但重复采样这一举措会影响粒子分布,导致粒子失去多样性。因此选择合理的后部分布建议是改进PF算法的有效途径<sup>[5]</sup>。该类型下应用较为广泛的是无迹粒子滤波(Unscented Particle Filter, UPF),应用UPF可以有效地适应电池在充放电下具有非线性和非高斯性质的OCV。同时,UPF能够结合最新的测量信息,提供比PF更接近真实后验分布的建议分布<sup>[198]</sup>。Liu等<sup>[199]</sup>在LIB老化半经验模型的基础上,结合UPF算法,实现了不同时间尺度的短期SOH评估和RUL预测。为了应对不可控的环境因素,Tang等<sup>[200]</sup>提出了一种基于模型的梯度校正粒子滤波方法来预测LIB的老化过程。Duan等<sup>[201]</sup>以EKF作为采样密度函数,优化基于电池退化模型的PF算法,提出了一种新的扩展卡尔曼粒子滤波器(EKPF),并详细分析了LIB的老化性能,从而预测由于体积和局部因素导致电池失效的老化机理。

近年来,智能算法与PF的结合成为提高PF性能的常用方法。例如,文献[202]提出了一种结合经验模态分解(EMD)和粒子滤波-高斯过程回归(PF-GPR)算法的新型LIB健康预测模型。该模型分析了电池容量退化,并融合IMF和残差序列,可以准确预测电池的健康状态(SOH)和剩余使用寿命(RUL)。

#### 4.5 随机过程的方法

基于随机过程的方法主要通过建立随机老化模型来估计SOH,该模型可以描述锂电池老化过程中的不确定性<sup>[203]</sup>。

##### 4.5.1 高斯过程回归

高斯过程回归(Gaussian Process Regression, GPR)是一种概率预测工具,可以通过高斯过程的适当组合对任何系统的行为进行建模,并结合先验知识实现基于贝叶斯框架的预测<sup>[166]</sup>。该方法由于其灵活性、非参数性和概率性,已成为电池SOH估计领域最流行的工具之一<sup>[204]</sup>。例如,基于GPR的数据驱动诊断技术被用于锂电池的在线容量评估,该技术可以在短时间内估计出锂电池在恒流下的容量<sup>[205]</sup>。此外,GPR还可以对电压和IC曲线中提取的特征进行回归跟踪<sup>[206]</sup>。

##### 4.5.2 维纳过程

维纳过程(Wiener Process, WP)是一种带有漂移系数的独立增量过程,也称为布朗运动过程<sup>[165]</sup>。因其具有强马尔可夫性质,适用于描述LIB老化模型的不连续增减趋势的非单调特征<sup>[207]</sup>。

维纳过程在退化建模中的应用已经有了显著的发展。Tang等<sup>[208]</sup>首先将固定效应和随机效应与维纳过程结合使用,捕捉不同个体单元之间的差异。Xu等<sup>[209]</sup>将分数阶引入维纳建模,增强了其反映历史依赖退化的记忆特性。Zhang等<sup>[210]</sup>通过结合时间变化协变量和奥恩斯坦-乌伦贝克过程,扩展了WP的应用范围,将外部因素纳入退化建模。Zheng等<sup>[211]</sup>引入了一种非线性维纳过程,并结合实时自适应变点检测方法,解决了多阶段退化的复杂性问题。

总之,维纳过程的适应性和多功能性促使它不断改进,使其成为退化建模和剩余寿命预测的有力工具。



随着技术进步及产品和环境复杂性的增加,预计这种建模技术将进一步发展,提供更加准确的预测. 锂电池 SOH 估计的数据驱动法的比较如表 4 所示.

表 4 锂离子电池的 SOH 数据驱动估计法的比较  
Tab.4 Comparison of SOH data-driven estimation methods for lithium batteries

方法		关键参数	优点	缺点
人工神经网络		电压、电流、温度	具有较强的非线性处理能力,无需建立高精度电池模型	估算精度受训练样本影响较大
向量机		电压、电流、温度	在高维模式识别、非线性回归等问题中精度较好	仅适用于规模较小的数据样本
模糊逻辑		电压、电流、温度	适用性广,可延展性能强	复杂度较高
贝叶斯滤波	卡尔曼滤波	电压、电流	收敛速度快、对噪声的抑制能力强	系统噪声不确定,同时算法中的线性化过程受模型影响很大
	粒子滤波	电压、电流	较好地描述非线性系统,简单可靠	估算结果容易受电池模型参数扰动影响,估算精度不高
随机过程	高斯过程回归	电压、电流、温度	适用于小样本、高维的回归问题 灵活性、非参数性和概率性强	计算量大 超参数调整非常复杂
	维纳过程	电压、电流、温度	表达不确定性的能力强 适用于不连续增减趋势的非单调特征过程建模	不适用于非线性和时间非齐次数据 基于马尔可夫性质

4.6 迁移学习与模型迁移

在电池管理系统中,由于不同电池化学成分的独特性,创建一个能够在各种电池类型中泛化的强大模型是一项挑战<sup>[212]</sup>. 迁移学习和模型迁移是克服这一挑战的两个关键方法,可使为一种电池类型开发的模型应用于其他电池类型.

4.6.1 迁移学习

迁移学习(Transfer Learning, TL)在机器学习领域,尤其是 SOH 监测这一领域中产生了显著影响<sup>[213]</sup>. TL 的核心优势在于它能够将在大型和多样化数据集上训练的模型适应于特定或较小的数据集,无论电池类型或条件如何,这种适应能力在数据可用性不一致、但对精确和高效的 SOH 估计有迫切需求的领域中非常宝贵<sup>[214]</sup>.

Tan 和 Zhao<sup>[215]</sup>使用 TL 技术预测 LIB 的健康状况,克服了传统数据驱动方法通常受限于训练数据量的问题,并结合了 LSTM 和全连接层,展示了如何利用 TL 在数据有限的情况下提升模型性能. 此外, Li 等<sup>[214]</sup>将 TL 应用于提高 CNN 模型对 LIB 容量估计的准确性,将最初在综合数据集上开发的预训练模型适应于更具针对性和较小的电池数据集,从而显著提高了估计的准确性和计算效率.

近年来, Liu 等<sup>[167]</sup>提出了一种结合大数据驱动和深度融合 TL 方法的电动汽车电池组 SOH 估计方法. 该研究利用 TL 技术将最初在大规模数据集上训练的模型调整到特定的电池数据集上,显著提高 SOH 估计的准确性和鲁棒性. Yang 等<sup>[168]</sup>提出了一种联合自适应深度迁移学习(JADTL)模型,该模型利用 TL 技术将最初在大型多样化数据集上训练的模型调整到特定或较小的数据集,以适应不同的工作条件和电池类型,从而提高动态工作条件下 SOC 和 SOH 估计的准确性和鲁棒性. 此外,莫易敏等<sup>[213]</sup>提出了一种结合迁移学习与 GRU 神经网络的方法,用于锂电池 SOH 估计. 该方法通过从高相似度电池的数据中提取健康特征训练初始模型,然后将模型参数迁移到低相似度电池数据上进行微调,从而在使用较少训练数据的情况下提升预测精度和稳定性. 该方法有效解决了退役电池梯次利用过程中测试流程复杂、能耗高的问题,显示了迁移学习在提升 SOH 预测性能上的重要作用.

4.6.2 模型迁移

模型迁移(Model Migration, MM)是将知识从一个领域转移到另一个领域,利用已有的模型来节省时间和资源,其目的是减少模拟类似过程的实验工作量<sup>[216]</sup>. MM 方法尤其适用于在不同条件或变量下研究类似过程或系统的领域<sup>[217]</sup>. Tang 等<sup>[218]</sup>提出了一种 MM 神经网络来预测电池老化轨迹,在 4 种不同商用电池上的实验结果表明,仅使用前 30% 的老化轨迹进行神经网络训练时,预测误差均小于 2.5%,表明所提出的小尺寸前馈迁移神经网络能够满足电池老化轨迹的预测. 申江卫等<sup>[219]</sup>提出了一种基于迁移模型的锂电池 SOC 估计方法,该方法通过动态调整模型参数以应对温度变化,显著提升了 SOC 估计的精度和效率. 通过参数辨

识和关系拟合,迁移模型减少了建模工作量,并在不同温度条件下表现出较高的SOC估计精度和计算效率,验证了其在实际应用中的有效性。

总的来说,MM方法减少了实验工作量、提高了预测准确性。它允许有效地调整模型以适应新的数据集,使其成为SOH监测的重要工具。然而,MM的成功在很大程度上取决于源领域模型的相关性和质量及其对目标领域的适用性。如果源模型不能充分捕捉新应用程序的细微差别,这种依赖将是一种限制。

#### 4.7 公共老化数据集

虽然数据驱动的方法提供了对电池行为和退化的重要见解,但它们往往受到观察数据的不确定性和不完整性的限制。这种限制可能导致使用这些方法开发模型的鲁棒性和适应性方面存在问题。解决问题,对于开发更准确、更稳健的模型至关重要。这些数据集通常包括各种参数,如充放电周期、温度、电压、电流和容量随时间的衰减,提供了各种条件下电池老化的详细情况。

##### 4.7.1 LiFePO<sub>4</sub> (LFP)/石墨电池综合数据集

Severson等<sup>[220]</sup>建立了一个来自商用LFP/石墨电池的综合数据集,该数据集涵盖了72种不同快速充电条件下的124个电池,显示循环寿命在150~2300次之间。该数据集的关键元素包括高倍率放电电压曲线,及详细的充电和放电电压和电流。该数据集在数据驱动的方法中提供了显著的预测精度,特别是前100个周期的测试误差为9.1%,而使用最初的5个周期进行分类的误差仅为4.9%。这种精度主要是通过从高倍率放电电压曲线中提取关键信息来实现的,有效地避免了延长诊断周期和复杂的细胞化学知识的必要性。

然而,该数据集也有其局限性。它主要关注的是快速充电条件,这可能不够全面,无法捕捉到锂电池所有可能的老化轨迹。此外,在某些数据方面可能存在不一致或空白,特别是在充电电压和电流,及放电电压和电流方面。

##### 4.7.2 电动汽车电池老化数据集

Tang等<sup>[221]</sup>提出了一种通过融合电动汽车现场数据和加速老化测试生成稳健电池老化数据集的新策略。该数据集包含了15种操作模式下进行的8947个老化循环。该方法的核心在于对电压和电流数据的实时监控,并通过TL方法进一步增强。该方法能够以高精度恢复高质量的电池老化数据集。事实上,该方法可以将老化数据的误差控制在不到1%的微小范围内。此外,数据收集所需的实验时间大幅缩短。该方法将实验时间大幅缩短了90%,提供了一条快速高效的数据获取途径。

尽管其具有上述优势,潜在挑战仍然存在。由于数据集主要基于实验室测试的加速老化数据之上,外推到实际操作场景时可能会出现差异。尽管基于插值的迁移方法具有创新性,但它依赖于现场操作中的有限容量参考点,这可能是一个争论点。

##### 4.7.3 NASA数据集

NASA 艾姆斯卓越预测中心<sup>[222]</sup>设计了一系列锂电池加速老化实验,在不同的环境参数和使用条件下对锂电池进行测试。在不同的实验中,锂电池的工作环境温度 and 放电速率各不相同。在每个充放电循环后,测量电池的阻抗并获得表征电池老化的内部参数。反复的充放电循环实验加速了锂电池的老化速率,当电池的容量降至其额定容量的70%以下(例如,从2 Ah降至1.4 Ah)时,实验终止。该中心共提供了6个数据集,这些数据集常用于剩余使用寿命(RUL)预测。例如,Zou等<sup>[223]</sup>使用该数据集中的容量数据进行了容量预测和RUL预测实验。Altintas<sup>[224]</sup>利用NASA电池老化数据集开发了基于IC曲线和温度特征的混合特征集,并采用两层前馈ANN实现高精度SOH估计。Yang等<sup>[225]</sup>利用NASA数据集提出了一种GBLS Booster多任务学习模型,用于同时评估锂电池SOH和RUL。

##### 4.7.4 CS2数据集

CS2是由马里兰大学高级生命周期工程中心(CALCE)提供的电池数据集<sup>[226-227]</sup>。该数据集已在许多研究中用于验证所提出的SOH估计算法和寿命预测算法。例如,Liu等<sup>[228]</sup>利用该数据集,提出了一种结合CNN、EMD和GRU-FC模型的方法,实现了RUL的高精度预测,所有估计误差均保持在7.0%以内。Chen等<sup>[229]</sup>利用牛津数据集和该数据集,提出并验证了稳健高斯滤波(RGSF)在锂离子电池SOH估计中的卓越性能。该数据集包括6类实验数据,均在相同的恒流-恒压充电条件下工作,但其放电电流不同。锂电池首先以0.55 A的恒流充电,当充电电压达到4.2 V时,开始恒压充电,充电电流达到0.05 A时结束充电。在不同的放电速率下,将电压降低到规定的放电截止电压。

4.7.5 牛津电池退化数据集

牛津大学提供的电池退化数据集<sup>[230]</sup>包含8个小型锂离子软包电池的电池老化数据测量值。所有电池均在40℃的热室中进行测试。LIB采用CCCV充电模式,这是LIB充电的常用方法,其中电流保持恒定,直到电压达到某个阈值,然后切换到恒定电压,直到电池充满电。测试中使用的放电曲线是从“Urban Artemis Curve”获得的。电池的放电方式模拟了真实的城市驾驶条件。在测试期间,每100次循环进行一次表征测量。表5总结了每个数据集的详细信息。

表5 锂电池公共数据集  
Tab.5 Public datasets for lithium batteries

数据集	优点	局限性	数据参数	关键特性
LiFePO4 (LFP)/石墨电池综合数据集	高精度 需要较少的诊断操作	主要关注快速 充电条件	放电电压曲线 充放电电压和电流	数据驱动方法
电动汽车电池老化数据集	数据恢复精度高 实验时间减少90%	与现实的差异	电压和电流数据	行业& 加速测试
NASA 数据集	—	—	3种条件下的实验 电池阻抗和老化参数	常用于RUL预测
CS2 数据集	在各种研究中广泛验证	—	来自6个实验设置的数据	CC-CV一致性
牛津电池退化数据集	模拟现实世界驾驶	限制在40℃条件	8个锂离子软包电池的老化数据	城市驾驶条件模拟

4.8 电池组SOH估算方法

上述研究主要针对单个电池SOH的评估,但电池组SOH的评估对实际应用更为重要,尤其是电池组的健康状况对于电动汽车等应用。例如,Tang等<sup>[216]</sup>提出了一种“领导者-跟随者”策略,展示了在降低计算负担的情况下,有效估计电池组中所有电池的SOH。在另一项研究中,Zhang等<sup>[231]</sup>利用逐渐减小的电流、双重相关分析和门控循环单元对单个电池和电池组进行SOH估计。

5 挑战与展望

5.1 挑战

实验检测法可以准确获得SOH的特征参数,如电池容量、电池内阻和电池循环次数,但需要严格控制温度、充放电电流和充放电截止电压等实验条件,从而增加了SOH研究的难度。此外,准确监测电池内部状态变量(如温度、电解液浓度和内阻等)也很困难,因此不适合在线测量。基于模型的估计方法能够分析电池内部的电化学动态,但SOH测量的参数精度直接关系到构建模型的精度。模型的构建高度复杂,须具备深厚的理论和实践基础。此外,基于模型的估计方法需要进行多物理场(如电化学、热力学和机械学等)分析,这些物理场之间的相互作用和耦合对SOH估计提出了挑战。数据驱动法灵活性高、预测精度强,适应性强,无需太多预设工作,但需要大规模、高质量的数据采集和计算,特别是针对特定应用场景和新型电池技术。此外,在实际应用中,还需要考虑系统的可扩展性、可操作性和成本效益,以满足不同规模和需求的电池系统。因此,有必要开发自适应的SOH估计方法并理解其特殊的行为模式和退化特性。

综上所述,上述方法具有不同的适用范围,并在一定条件下取得了良好的理论和结果。然而,由于LIB应用系统中存在多种不同的模型、数量和连接方式,这些方法的通用性受到很大限制。同时,由于在锂电池使用过程中(如电动汽车运行)存在各种不确定因素,因此难以维持电池组物理和化学状态的稳定性。

5.2 展望

1)数据驱动方式不断完善。随着大数据和机器学习技术的发展,基于数据驱动的SOH估算方法将进一步完善。更强大的算法和更多的数据样本将提高预测的准确性和稳健性。此外,特征选择和提取方法的改进有助于更好地捕捉电池状态的关键特征。

2)研究将侧重于耦合多物理场模型的开发。目前电池SOH估计方法主要集中在电化学模型或数据驱动模型上,而多物理场耦合模型的研究相对有限,未来的研究将侧重于开发更全面的多物理场模型,以更准确地描述电池行为和退化过程。



3)实时性和可扩展性将得到提高。电池SOH估计在实时应用中的可行性是一个重要挑战。未来的研究将集中于开发硬件平台和高效算法来快速估计和预测电池SOH。此外,研究人员还将重点关注SOH估计方法在大规模电池系统和能源网络中的可扩展性。

4)无损测量技术将更广泛地应用于电池SOH估计。声学、光学、热学等无损测量技术将更广泛地应用于电池SOH估算,这些技术能够提供更加全面、实时的电池状态信息,在实际应用中具有更好的可操作性和可靠性。

5)电动汽车、可再生能源系统和移动设备等领域对电池SOH估算的需求增加。考虑到锂电池老化过程的复杂性和内外部特性,针对不同场景和使用条件的电池SOH估计方法的优化和定制是重要的研究方向。

## 6 结论

SOH是锂电池一个非常重要的参数,与电池内阻、电池老化状态、SOC等密切相关,是电池系统安全运行的方向。然而,SOH估计方法并不唯一,导致一些研究方法的适应性较差。本文系统地将目前锂电池SOH估计方法分为三类:实验检测法、基于模型的估计法和数据驱动法,并全面分析它们的优缺点。相信未来锂电池SOH预测将在准确性、实用性、适应性等方面取得重大进步,最终促进LIB技术的进一步发展。

## 参考文献:

- [1] 姜久春,高洋,张彩萍,等.电动汽车锂离子动力电池健康状态在线诊断方法[J].机械工程学报,2019,55(20):60-72,84.
- [2] GE M F, LIU Y B, JIANG X X, et al. A review on state of health estimations and remaining useful life prognostics of lithium-ion batteries[J]. Measurement, 2021, 174: 109057.
- [3] SUN C C, LIN H P, CAI H, et al. Improved parameter identification and state-of-charge estimation for lithium-ion battery with fixed memory recursive least squares and sigma-point Kalman filter[J]. Electrochimica Acta, 2021, 387: 138501.
- [4] TOKORO C, LIM S, TERUYA K, et al. Separation of cathode particles and aluminum current foil in lithium-ion battery by high-voltage pulsed discharge Part I: Experimental investigation[J]. Waste Management, 2021, 125: 58-66.
- [5] ZHANG Y Z, XIONG R, HE H W, et al. Long short-term memory recurrent neural network for remaining useful life prediction of lithium-ion batteries[J]. IEEE Transactions on Vehicular Technology, 2018, 67(7): 5695-5705.
- [6] 李博文,赵光金,董锐锋,等.储能用锂离子电池加速寿命老化研究综述[J].河南科学,2024,42(4):484-496.
- [7] 祝红英,时玮,朱志贤.关于锂离子电池健康状态预测方法的研究进展[J].电源技术,2017,41(9):1380-1382.
- [8] 李炳金,韩晓霞,张文杰,等.锂离子电池剩余使用寿命预测方法综述[J].储能科学与技术,2024,13(4):1266-1276.
- [9] 俞佳欢,潘光杰,谢彬.退役锂离子电池健康状态在线评估技术综述[J].上海汽车,2024(2):45-50.
- [10] 熊庆,邸振国,汲胜昌.锂离子电池健康状态估计及寿命预测研究进展综述[J].高电压技术,2024,50(3):1182-1195.
- [11] 吴盛军,袁晓冬,徐青山,等.锂电池健康状态评估综述[J].电源技术,2017,41(12):1788-1791.
- [12] CORDOBA-ARENAS A, ONORI S, GUEZENNEC Y, et al. Capacity and power fade cycle-life model for plug-in hybrid electric vehicle lithium-ion battery cells containing blended spinel and layered-oxide positive electrodes[J]. Journal of Power Sources, 2015, 278: 473-483.
- [13] WANG X Y, WEI X Z, DAI H F. Estimation of state of health of lithium-ion batteries based on charge transfer resistance considering different temperature and state of charge[J]. Journal of Energy Storage, 2019, 21: 618-631.
- [14] XIONG R, LI L L, TIAN J P. Towards a smarter battery management system: A critical review on battery state of health monitoring methods[J]. Journal of Power Sources, 2018, 405: 18-29.
- [15] 胡晓亚,郭永芳,张若可.锂离子电池健康状态估计方法研究综述[J].电源学报,2022,20(1):126-133.
- [16] LIU D T, YIN X H, SONG Y C, et al. An on-line state of health estimation of lithium-ion battery using unscented particle filter[J]. IEEE Access, 2021, 9: 40990-41001.
- [17] KLASS V, BEHM M, LINDBERGH G. A support vector machine-based state-of-health estimation method for lithium-ion batteries under electric vehicle operation[J]. Journal of Power Sources, 2014, 270: 262-272.
- [18] LIU Z T, TAN C, LENG F. A reliability-based design concept for lithium-ion battery pack in electric vehicles[J]. Reliability Engineering & System Safety, 2015, 134: 169-177.
- [19] SHAHRIARI M, FARROKHI M. Online state-of-health estimation of VRLA batteries using state of charge[J]. IEEE Transactions on Industrial Electronics, 2013, 60(1): 191-202.
- [20] BARRÉ A, DEGUILHEM B, GROLLEAU S, et al. A review on lithium-ion battery ageing mechanisms and estimations for automotive applications[J]. Journal of Power Sources, 2013, 241: 680-689.
- [21] ZHOU D, YIN H T, FU P, et al. Prognostics for state of health of lithium-ion batteries based on Gaussian process regression[J].



- Mathematical Problems in Engineering, 2018, 2018: 8358025.
- [22] WENG C H, FENG X N, SUN J, et al. State-of-health monitoring of lithium-ion battery modules and packs via incremental capacity peak tracking[J]. Applied Energy, 2016, 180: 360-368.
- [23] WANG Z K, ZENG S K, GUO J B, et al. State of health estimation of lithium-ion batteries based on the constant voltage charging curve[J]. Energy, 2019, 167: 661-669.
- [24] HOW D N T, HANNAN M A, HOSSAIN LIPU M S, et al. State of charge estimation for lithium-ion batteries using model-based and data-driven methods: A review[J]. IEEE Access, 2019, 7: 136116-136136.
- [25] 杨博, 钱玉村. 锂离子电池健康状态估计综述[J]. 昆明理工大学学报(自然科学版), 2024, 49(3): 147-165.
- [26] BARAI A, UDDIN K, WIDANAGE W D, et al. A study of the influence of measurement timescale on internal resistance characterisation methodologies for lithium-ion cells[J]. Scientific Reports, 2018, 8: 21.
- [27] RAHMAN M, ANWAR S, IZADIAN A. Electrochemical model-based condition monitoring via experimentally identified Li-ion battery model and HPPC[J]. Energies, 2017, 10(9): 1266.
- [28] HUANG H Y, MENG J H, WANG Y H, et al. A comprehensively optimized lithium-ion battery state-of-health estimator based on Local Coulomb Counting Curve[J]. Applied Energy, 2022, 322: 119469.
- [29] SUN J H, KAINZ J. Optimization of hybrid pulse power characterization profile for equivalent circuit model parameter identification of Li-ion battery based on Taguchi method[J]. Journal of Energy Storage, 2023, 70: 108034.
- [30] BAO Y, DONG W B, WANG D. Online internal resistance measurement application in lithium ion battery capacity and state of charge estimation[J]. Energies, 2018, 11(5): 1073.
- [31] TANG X P, LAI X, LIU Q, et al. Predicting battery impedance spectra from 10-second pulse tests under 10 Hz sampling rate[J]. iScience, 2023, 26(6): 106821.
- [32] WU J H, BAI W Q, ZHANG L P, et al. Design of a portable electrochemical impedance spectroscopy measurement system based on AD5941 for lithium-ion batteries[J]. Journal of Energy Storage, 2024, 84: 110856.
- [33] GUO J, LI Z J, LI M Y. A review on prognostics methods for engineering systems[J]. IEEE Transactions on Reliability, 2020, 69(3): 1110-1129.
- [34] 彭思敏, 徐璐, 张伟峰, 等. 锂离子电池功率状态预测方法综述[J]. 机械工程学报, 2022, 58(20): 361-78.
- [35] 凌六一, 张虎, 张婷, 等. 基于预测静置开路电压法的锂电池 SOC 估算[J/OL]. 电源学报: 1-10(2024-04-26)[2024-06-22]. <http://kns.cnki.net/kcms/detail/12.1420.tm.20240425.1849.028.html>.
- [36] HOSSAIN LIPU M S, HANNAN M A, HUSSAIN A, et al. Lithium-ion battery state of charge estimation method using optimized deep recurrent neural network algorithm[C]//Proceedings of the IEEE Industry Applications Society Annual Meeting, 2019: 1-9.
- [37] LI Y, ABDEL-MONEM M, GOPALAKRISHNAN R, et al. A quick on-line state of health estimation method for Li-ion battery with incremental capacity curves processed by Gaussian filter[J]. Journal of Power Sources, 2018, 373: 40-53.
- [38] HUANG Y D, LI Y, JIANG L, et al. Research on fitting strategy in HPPC test for Li-ion battery[C]//Proceedings of the IEEE Sustainable Power and Energy Conference (iSPEC), 2019: 1776-1780.
- [39] LIU Z H, WANG C, GUO X M, et al. Thermal characteristics of ultrahigh power density lithium-ion battery[J]. Journal of Power Sources, 2021, 506: 230205.
- [40] LYU Z Q, ZHANG Y F, WANG G, et al. A semiparametric clustering method for the screening of retired Li-ion batteries from electric vehicles[J]. Journal of Energy Storage, 2023, 63: 107030.
- [41] BIAŁOŃ T, NIESTRÓJ R, SKARKA W, et al. HPPC test methodology using LFP battery cell identification tests as an example[J]. Energies, 2023, 16(17): 6239.
- [42] BROATCH A, OLMEDA P, MARGOT X, et al. A generalized methodology for lithium-ion cells characterization and lumped electro-thermal modelling[J]. Applied Thermal Engineering, 2022, 217: 119174.
- [43] FENG Y F, SHEN J N, MA Z F, et al. Equivalent circuit modeling of sodium-ion batteries[J]. Journal of Energy Storage, 2021, 43: 103233.
- [44] 蒋杭廷, 张倩倩, 张松通, 等. 化学电源内阻测量及状态监测策略分析研究[J]. 储能科学与技术, 2024, 13(10): 3400-3422.
- [45] GOUD J S, KALPANA R, SINGH B. Modeling and estimation of remaining useful life of single cell Li-Ion battery[C]//Proceedings of the IEEE International Conference on Power Electronics, Drives and Energy Systems (PEDES), 2018: 1-5.
- [46] WIDANAGE W D, BARAI A, CHOUCHELAMANE G H, et al. Design and use of multisine signals for Li-ion battery equivalent circuit modelling. Part 1: Signal design[J]. Journal of Power Sources, 2016, 324: 70-78.
- [47] GRANDJEAN T R B, GROENEWALD J, MCGORDON A, et al. Accelerated internal resistance measurements of lithium-ion cells to support future end-of-life strategies for electric vehicles[J]. Batteries, 2018, 4(4): 49.
- [48] WAAG W, FLEISCHER C, SAUER D U. Critical review of the methods for monitoring of lithium-ion batteries in electric and hybrid vehicles[J]. Journal of Power Sources, 2014, 258: 321-339.

- [49] WANG S Q, VERBRUGGE M, WANG J S, et al. Power prediction from a battery state estimator that incorporates diffusion resistance[J]. *Journal of Power Sources*, 2012, 214: 399–406.
- [50] QU Z G, JIANG Z Y, WANG Q. Experimental study on pulse self-heating of lithium-ion battery at low temperature[J]. *International Journal of Heat and Mass Transfer*, 2019, 135: 696–705.
- [51] BENAVIDES M, ARIAS A, CERDAS J D, et al. Remaining useful life of lithium-ion batteries as a function of the joule effect[C]// *Proceedings of the IEEE International Autumn Meeting on Power, Electronics and Computing (ROPEC)*, 2020: 1–6.
- [52] BEREICIBAR M, GANDIAGA I, VILLARREAL I, et al. Critical review of state of health estimation methods of Li-ion batteries for real applications[J]. *Renewable and Sustainable Energy Reviews*, 2016, 56: 572–587.
- [53] PM V N, HIRSHIK R S, UTHAN P, et al. Estimating the internal resistance of Li-ion battery with Joule's Law to find the open circuit voltage[C]// *Proceedings of the IEEE Industrial Electronics and Applications Conference (IEACon)*, 2021: 146–150.
- [54] SHAHJALAL M, TRIPATHY Y, SHEIKH M. Investigation on thermal performance analysis of a pouch Li-ion battery under various drive cycle profiles[J]. *Journal of Energy Storage*, 2023, 73: 108977.
- [55] DOH C H, HA Y C, EOM S W. Entropy measurement of a large format lithium ion battery and its application to calculate heat generation[J]. *Electrochimica Acta*, 2019, 309: 382–391.
- [56] FERNÁNDEZ PULIDO Y, BLANCO C, ANSEÁN D, et al. Determination of suitable parameters for battery analysis by Electrochemical Impedance Spectroscopy[J]. *Measurement*, 2017, 106: 1–11.
- [57] ZENATI A, DESPREZ P, RAZIK H, et al. Impedance measurements combined with the fuzzy logic methodology to assess the SOC and SOH of lithium-ion cells[C]// *Proceedings of the IEEE Vehicle Power and Propulsion Conference*, 2010: 1–6.
- [58] UNGUREAN L, CÂRSTOIU G, MICEA M V, et al. Battery state of health estimation: A structured review of models, methods and commercial devices[J]. *International Journal of Energy Research*, 2017, 41(2): 151–181.
- [59] 田爱娜, 潘壮壮, 吴铁洲, 等. 基于单频阻抗的锂离子电池热失控分级预警[J]. *电池*, 2024, 54(2): 194–199.
- [60] HU W X, PENG Y F, WEI Y M, et al. Application of electrochemical impedance spectroscopy to degradation and aging research of lithium-ion batteries[J]. *The Journal of Physical Chemistry C*, 2023, 127(9): 4465–4495.
- [61] ZHANG M, LIU Y S, LI D Z, et al. Electrochemical impedance spectroscopy: A new chapter in the fast and accurate estimation of the state of health for lithium-ion batteries[J]. *Energies*, 2023, 16(4): 1599.
- [62] DUAN Y Z, TIAN J P, LU J H, et al. Deep neural network battery impedance spectra prediction by only using constant-current curve[J]. *Energy Storage Materials*, 2021, 41: 24–31.
- [63] HE R, HE Y L, XIE W L, et al. Comparative analysis for commercial li-ion batteries degradation using the distribution of relaxation time method based on electrochemical impedance spectroscopy[J]. *Energy*, 2023, 263: 125972.
- [64] PY B, MARADESA A, CIUCCI F. Gaussian processes for the analysis of electrochemical impedance spectroscopy data: Prediction, filtering, and active learning[J]. *Electrochimica Acta*, 2023, 439: 141688.
- [65] VADHVA P, HU J, JOHNSON M J, et al. Electrochemical impedance spectroscopy for all-solid-state batteries: Theory, methods and future outlook[J]. *ChemElectroChem*, 2021, 8(11): 1930–1947.
- [66] XIAO B, XIAO B, LIU L S. Rapid measurement method for lithium-ion battery state of health estimation based on least squares support vector regression[J]. *International Journal of Energy Research*, 2021, 45(4): 5695–5709.
- [67] 万广伟, 张强. 锂离子电池荷电状态估算综述[J]. *蓄电池*, 2022, 59(5): 213–216.
- [68] LIU Z X, LI Z, ZHANG J B, et al. Accurate and efficient estimation of lithium-ion battery state of charge with alternate adaptive extended Kalman filter and ampere-hour counting methods[J]. *Energies*, 2019, 12(4): 757.
- [69] LOCOROTONDO E, PUGI L, BERZI L, et al. Online state of health estimation of lithium-ion batteries based on improved ampere-count method[C]// *Proceedings of the IEEE International Conference on Environment and Electrical Engineering and 2018 IEEE Industrial and Commercial Power Systems Europe (EEEIC / I&CPS Europe)*, 2018: 1–6.
- [70] WANG G, JIN B, WANG M Z, et al. State of charge estimation for “ $\text{LiFePO}_4 - \text{LiCo}_x\text{Ni}_y\text{Mn}_{1-x-y}\text{O}_2$ ” hybrid battery pack[J]. *Journal of Energy Storage*, 2023, 65: 107345.
- [71] ZHAO X Z, SUN B X, ZHANG W G, et al. Error theory study on EKF-based SOC and effective error estimation strategy for Li-ion batteries[J]. *Applied Energy*, 2024, 353: 121992.
- [72] REN X Q, LIU S L, YU X D, et al. A method for state-of-charge estimation of lithium-ion batteries based on PSO-LSTM[J]. *Energy*, 2021, 234: 121236.
- [73] LI Z, HUANG J, LIAW B Y, et al. On state-of-charge determination for lithium-ion batteries[J]. *Journal of Power Sources*, 2017, 348: 281–301.
- [74] LAI X, WANG S Y, HE L, et al. A hybrid state-of-charge estimation method based on credible increment for electric vehicle applications with large sensor and model errors[J]. *Journal of Energy Storage*, 2020, 27: 101106.
- [75] 孟鹏飞, 李腾飞, 王万岗, 等. 基于双端电流测量的电缆早期故障定位研究[J/OL]. *工程科学与技术*: 1–11 (2024-05-24)

- [2024-06-22]. <http://kns.cnki.net/kcms/detail/51.1773.tb.20240523.1708.002.html>.
- [76] WANG C, ZHANG X, YUN X, et al. A novel hybrid machine learning coulomb counting technique for state of charge estimation of lithium-ion batteries[J]. *Journal of Energy Storage*, 2023, 63: 107081.
- [77] AKPINAR K N, GUNDOGU B, OZGONENEL O. A novel cycle counting perspective for energy management of grid integrated battery energy storage systems[J]. *Energy Reports*, 2023, 9: 123–131.
- [78] LU W Q, ZHANG L H, QIN Y, et al. Calendar and cycle life of lithium-ion batteries containing silicon monoxide anode[J]. *Journal of the Electrochemical Society*, 2018, 165(10): A2179–A2183.
- [79] WOGENSEN E R, HAVERKORT B R, JONGERDEN M, et al. A score function for optimizing the cycle-life of battery-powered embedded systems[M]//*Lecture Notes in Computer Science*. Cham: Springer International Publishing, 2015: 305–320.
- [80] LI Y Q, GUO J, PEDERSEN K, et al. Recent health diagnosis methods for lithium-ion batteries[J]. *Batteries*, 2022, 8(7): 72.
- [81] LI R, XIAO W, MIAO C, et al. Sphere-like  $\text{SnO}_2/\text{TiO}_2$  composites as high-performance anodes for lithium ion batteries[J]. *Ceramics International*, 2019, 45(10): 13530–13535.
- [82] ZHANG L Q, YANG T T, DU C C, et al. Lithium whisker growth and stress generation in an *in situ* atomic force microscope–environmental transmission electron microscope set-up[J]. *Nature Nanotechnology*, 2020, 15: 94–98.
- [83] VANPEENE V, SOUCY P, XIONG J H, et al. Sequential focused ion beam scanning electron microscopy analyses for monitoring cycled-induced morphological evolution in battery composite electrodes. Silicon-graphite electrode as exemplary case[J]. *Journal of Power Sources*, 2021, 498: 229904.
- [84] CAO Z G, YANG Y B, QIN J L, et al.  $\text{Co}_3\text{O}_4$  Polyhedron@ $\text{MnO}_2$  nanotube composite as anode for high-performance lithium-ion batteries[J]. *Small*, 2021, 17(19): 2008165.
- [85] YOUSAF M, NASEER U, LI Y J, et al. A mechanistic study of electrode materials for rechargeable batteries beyond lithium ions by *in situ* transmission electron microscopy[J]. *Energy & Environmental Science*, 2021, 14(5): 2670–2707.
- [86] CHENG Y, ZHANG L Q, ZHANG Q B, et al. Understanding all solid-state lithium batteries through *in situ* transmission electron microscopy[J]. *Materials Today*, 2021, 42: 137–161.
- [87] ZHANG X R, YANG J Y, REN Z Y, et al. *In-situ* observation of electrolyte-dependent interfacial change of the graphite anode in sodium-ion batteries by atomic force microscopy[J]. *Carbon*, 2022, 196: 2.
- [88] WAN J, ZUO Z C, SHEN Z Z, et al. Interfacial evolution of the solid electrolyte interphase and lithium deposition in graphdiyne-based lithium-ion batteries[J]. *Journal of the American Chemical Society*, 2022, 144(21): 9354–9362.
- [89] NOEROCHIM L, WIBOWO A T, WIDYASTUTI, et al. Direct double coating of carbon and nitrogen on fluoride-doped  $\text{Li}_4\text{Ti}_5\text{O}_{12}$  as an anode for lithium-ion batteries[J]. *Batteries*, 2022, 8(1): 5.
- [90] HE J R, TAO T, YANG F, et al. Unravelling  $\text{Li}^+$  intercalation mechanism and cathode electrolyte interphase of  $\text{Na}_3\text{V}_2(\text{PO}_4)_3$  and  $\text{Na}_3(\text{VOPO}_4)_2\text{F}$  cathode as robust framework towards high-performance lithium-ion batteries[J]. *ChemSusChem*, 2022, 15(15): e202200817.
- [91] WOOD K N, STEIRER K X, HAFNER S E, et al. Operando X-ray photoelectron spectroscopy of solid electrolyte interphase formation and evolution in  $\text{Li}_2\text{S-P}_2\text{S}_5$  solid-state electrolytes[J]. *Nature Communications*, 2018, 9: 2490.
- [92] LIU F F, LIU Y C, ZHAO X D, et al. Prelithiated  $\text{V}_2\text{C}$  MXene: A high-performance electrode for hybrid magnesium/lithium-ion batteries by ion cointercalation[J]. *Small*, 2020, 16(8): 1906076.
- [93] LIANG H J, HOU B H, LI W H, et al. Staging Na/K-ion de-/intercalation of graphite retrieved from spent Li-ion batteries: *in operando* X-ray diffraction studies and an advanced anode material for Na/K-ion batteries[J]. *Energy & Environmental Science*, 2019, 12(12): 3575–3584.
- [94] FRIEDRICH F, STREHLE B, FREIBERG A T S, et al. Editors' choice—Capacity fading mechanisms of NCM-811 cathodes in lithium-ion batteries studied by X-ray diffraction and other diagnostics[J]. *Journal of the Electrochemical Society*, 2019, 166(15): A3760–A3774.
- [95] BAK S M, SHADIKE Z, LIN R Q, et al. In situ/operando synchrotron-based X-ray techniques for lithium-ion battery research[J]. *NPG Asia Materials*, 2018, 10: 563–580.
- [96] FLORES E, NOVÁK P, BERG E J. *In situ* and *operando* Raman spectroscopy of layered transition metal oxides for Li-ion battery cathodes[J]. *Frontiers in Energy Research*, 2018, 6: 82.
- [97] CHENG Q, WEI L, LIU Z, et al. Operando and three-dimensional visualization of anion depletion and lithium growth by stimulated Raman scattering microscopy[J]. *Nature Communications*, 2018, 9: 2942.
- [98] 《中国公路学报》编辑部. 中国汽车工程学术综述·2023[J]. *中国公路学报*, 2023, 36(11): 1–192.
- [99] 郝奕帆, 祝夏雨, 王静, 等. 电池无损检测监测方法分析[J]. *储能科学与技术*, 2023, 12(5): 1713–1737.
- [100] WU Y, WANG Y R, YUNG W K C, et al. Ultrasonic health monitoring of lithium-ion batteries[J]. *Electronics*, 2019, 8(7): 751.
- [101] LI H G, ZHOU Z G. Numerical simulation and experimental study of fluid-solid coupling-based air-coupled ultrasonic

- detection of stomata defect of lithium-ion battery[J]. *Sensors*, 2019, 19(10):2391.
- [102] ROBINSON J B, OWEN R E, KOK M D R, et al. Identifying defects in Li-ion cells using ultrasound acoustic measurements[J]. *Journal of the Electrochemical Society*, 2020, 167(12):120530.
- [103] CAI Z D, PAN T L, JIANG H Y, et al. State-of-charge estimation of lithium-ion batteries based on ultrasonic detection[J]. *Journal of Energy Storage*, 2023, 65:107264.
- [104] GAO J, ZHANG L H, LYU Y, et al. Ultrasonic guided wave measurement and modeling analysis of the state of charge for lithium-ion battery[J]. *Journal of Energy Storage*, 2023, 72:108384.
- [105] GAO J, LYU Y, HE C F. Estimating state of charge of lithium-ion batteries by using ultrasonic guided waves detection technology[J]. *Journal of Physics: Conference Series*, 2022, 2198(1):012015.
- [106] GUO Z, QIU X P, HOU G D, et al. State of health estimation for lithium ion batteries based on charging curves[J]. *Journal of Power Sources*, 2014, 249:457-462.
- [107] HAN X B, FENG X N, OUYANG M G, et al. A comparative study of charging voltage curve analysis and state of health estimation of lithium-ion batteries in electric vehicle[J]. *Automotive Innovation*, 2019, 2(4):263-275.
- [108] DENG Y W, YING H J, JIAQIANG E, et al. Feature parameter extraction and intelligent estimation of the State-of-Health of lithium-ion batteries[J]. *Energy*, 2019, 176:91-102.
- [109] ROMAN D, SAXENA S, ROBU V, et al. Machine learning pipeline for battery state-of-health estimation[J]. *Nature Machine Intelligence*, 2021, 3:447-456.
- [110] NI Z C, XIU X C, YANG Y. Towards efficient state of charge estimation of lithium-ion batteries using canonical correlation analysis[J]. *Energy*, 2022, 254:124415.
- [111] ZHANG M, YIN J, CHEN W L. SOH estimation and RUL prediction of lithium batteries based on multidomain feature fusion and CatBoost model[J]. *Energy Science & Engineering*, 2023, 11(9):3082-3101.
- [112] FENG H L, LI N J. A multi-feature fusion model based on differential thermal capacity for prediction of the health status of lithium-ion batteries[J]. *Journal of Energy Storage*, 2023, 72:108419.
- [113] ZHENG Y J, WANG J J, QIN C, et al. A novel capacity estimation method based on charging curve sections for lithium-ion batteries in electric vehicles[J]. *Energy*, 2019, 185:361-371.
- [114] OUYANG M G, CHU Z Y, LU L G, et al. Low temperature aging mechanism identification and lithium deposition in a large format lithium iron phosphate battery for different charge profiles[J]. *Journal of Power Sources*, 2015, 286:309-320.
- [115] DUBARRY M, LIAW B Y, CHEN M S, et al. Identifying battery aging mechanisms in large format Li ion cells[J]. *Journal of Power Sources*, 2011, 196(7):3420-3425.
- [116] TIAN J P, XIONG R, YU Q Q. Fractional-order model-based incremental capacity analysis for degradation state recognition of lithium-ion batteries[J]. *IEEE Transactions on Industrial Electronics*, 2019, 66(2):1576-1584.
- [117] LI X Y, WANG Z P, ZHANG L, et al. State-of-health estimation for Li-ion batteries by combing the incremental capacity analysis method with grey relational analysis[J]. *Journal of Power Sources*, 2019, 410/411:106-114.
- [118] TANG X P, WANG Y J, LIU Q, et al. Reconstruction of the incremental capacity trajectories from current-varying profiles for lithium-ion batteries[J]. *iScience*, 2021, 24(10):103103.
- [119] WANG G F, CUI N X, LI C L, et al. A state-of-health estimation method based on incremental capacity analysis for Li-ion battery considering charging/discharging rate[J]. *Journal of Energy Storage*, 2023, 73:109010.
- [120] GISMERO A, NØRREGAARD K, JOHNSEN B, et al. Electric vehicle battery state of health estimation using Incremental Capacity Analysis[J]. *Journal of Energy Storage*, 2023, 64:107110.
- [121] CHANG C, WANG Q Y, JIANG J C, et al. Lithium-ion battery state of health estimation using the incremental capacity and wavelet neural networks with genetic algorithm[J]. *Journal of Energy Storage*, 2021, 38:102570.
- [122] ZHU J G, DEWI DARMA M S, KNAPP M, et al. Investigation of lithium-ion battery degradation mechanisms by combining differential voltage analysis and alternating current impedance[J]. *Journal of Power Sources*, 2020, 448:227575.
- [123] ZHANG S Z, GUO X, DOU X X, et al. A rapid online calculation method for state of health of lithium-ion battery based on coulomb counting method and differential voltage analysis[J]. *Journal of Power Sources*, 2020, 479:228740.
- [124] FATH J P, DRAGICEVIC D, BITTEL L, et al. Quantification of aging mechanisms and inhomogeneity in cycled lithium-ion cells by differential voltage analysis[J]. *Journal of Energy Storage*, 2019, 25:100813.
- [125] ZHENG L F, ZHU J G, LU D D C, et al. Incremental capacity analysis and differential voltage analysis based state of charge and capacity estimation for lithium-ion batteries[J]. *Energy*, 2018, 150:759-769.
- [126] BENSAAAD Y, FRIEDRICHS F, SIEG J, et al. Multidimensional estimation of inhomogeneous lithium-ion cell aging via modal differential voltage analysis[J]. *Journal of Energy Storage*, 2023, 63:107108.
- [127] XIA F, WANG K G, CHEN J J. State of health and remaining useful life prediction of lithium-ion batteries based on a



- disturbance-free incremental capacity and differential voltage analysis method[J]. *Journal of Energy Storage*, 2023, 64: 107161.
- [128] SUN X F, ZHONG K, HAN M. A hybrid prognostic strategy with unscented particle filter and optimized multiple kernel relevance vector machine for lithium-ion battery[J]. *Measurement*, 2021, 170: 108679.
- [129] YIN Y L, CHOE S Y. Actively temperature controlled health-aware fast charging method for lithium-ion battery using nonlinear model predictive control[J]. *Applied Energy*, 2020, 271: 115232.
- [130] KUPPER C, WEIBHAR B, RIBMANN S, et al. End-of-life prediction of a lithium-ion battery cell based on mechanistic aging models of the graphite electrode[J]. *Journal of the Electrochemical Society*, 2018, 165(14): A3468-A3480.
- [131] AGARWAL A, FISCKO C, KAR S, et al. An equivalent circuit workflow for unconstrained optimization[EB/OL]. (2023-05-23)[2024-06-25]. <http://arxiv.org/abs/2305.14061>.
- [132] CHEN J, LI F, LI H R, et al. Novel dynamic equivalent circuit model of integrated energy systems[J]. *Energy*, 2023, 262: 125266.
- [133] BAGHDADI I, BRIAT O, DELÉTAGE J Y, et al. Lithium battery aging model based on Dakin's degradation approach[J]. *Journal of Power Sources*, 2016, 325: 273-285.
- [134] GUHA A, PATRA A. State of health estimation of lithium-ion batteries using capacity fade and internal resistance growth models[J]. *IEEE Transactions on Transportation Electrification*, 2018, 4(1): 135-146.
- [135] WANG J R, MENG J H, PENG Q, et al. Lithium-ion battery state-of-charge estimation using electrochemical model with sensitive parameters adjustment[J]. *Batteries*, 2023, 9(3): 180.
- [136] ZHANG L J, MU Z Q, SUN C Y. Remaining useful life prediction for lithium-ion batteries based on exponential model and particle filter[J]. *IEEE Access*, 2018, 6: 17729-17740.
- [137] 咎文达, 张睿, 丁飞. 锂离子电池电化学模型发展与应用[J]. *储能科学与技术*, 2023, 12(7): 2302-2318.
- [138] LI J, ADEWUYI K, LOTFI N, et al. A single particle model with chemical/mechanical degradation physics for lithium ion battery State of Health (SOH) estimation[J]. *Applied Energy*, 2018, 212: 1178-1190.
- [139] LI J F, WANG L X, LYU C, et al. A parameter estimation method for a simplified electrochemical model for Li-ion batteries[J]. *Electrochimica Acta*, 2018, 275: 50-58.
- [140] 魏立婷, 贾力, 安周建. 基于伪二维电化学-热耦合模型的锂电池热特性研究[J]. *热科学与技术*, 2020, 19(4): 365-373.
- [141] STREB M, ANDERSSON M, LÖFQVIST KLASS V, et al. Investigating re-parametrization of electrochemical model-based battery management using real-world driving data[J]. *eTransportation*, 2023, 16: 100231.
- [142] TRAN M K, MATHEW M, JANHUNEN S, et al. A comprehensive equivalent circuit model for lithium-ion batteries, incorporating the effects of state of health, state of charge, and temperature on model parameters[J]. *Journal of Energy Storage*, 2021, 43: 103252.
- [143] YOU H W, BAE J I, CHO S J, et al. Analysis of equivalent circuit models in lithium-ion batteries[J]. *AIP Advances*, 2018, 8(12): 125101.
- [144] 赵可沧, 江境宏, 邓进, 等. 基于遗忘因子递推最小二乘法的锂电池等效电路模型参数辨识方法[J]. *电子测量技术*, 2022, 45(23): 53-58.
- [145] SHEN M, GAO Q. A review on battery management system from the modeling efforts to its multiapplication and integration[J]. *International Journal of Energy Research*, 2019, 43(10): 5042-5075.
- [146] 黄莉莉, 任星星, 苗博博, 等. 基于改进 Rint 模型锂离子电池 SOC 估计[J]. *电池工业*, 2022, 26(4): 177-180.
- [147] HANNAN M A, LIPU M S H, HUSSAIN A, et al. A review of lithium-ion battery state of charge estimation and management system in electric vehicle applications: Challenges and recommendations[J]. *Renewable and Sustainable Energy Reviews*, 2017, 78: 834-854.
- [148] 程燕兵, 韩如成. 锂电池 PNGV 模型与二阶 RC 模型分析与比较[J]. *太原科技大学学报*, 2019, 40(6): 430-436.
- [149] 王宇伟, 赵阳, 华迪, 等. 基于二阶等效电路模型的锂电池状态估计方法研究[J]. *节能*, 2022, 41(4): 38-42.
- [150] FAN C X, O'REGAN K, LI L Y, et al. Data-driven identification of lithium-ion batteries: A nonlinear equivalent circuit model with diffusion dynamics[J]. *Applied Energy*, 2022, 321: 119336.
- [151] KESHAVERZI M, DERA KHSHAN M, GILAKI M, et al. Coupled electrochemical-mechanical modeling of lithium-ion batteries using distributed randle circuit model[C]//*Proceedings of the International Conference on Electrical, Computer and Energy Technologies (ICECET)*, 2021: 1-6.
- [152] 谭必蓉, 杜建华, 叶祥虎, 等. 基于模型的锂离子电池 SOC 估计方法综述[J]. *储能科学与技术*, 2023, 12(6): 1995-2010.
- [153] CHEN W D, LIANG J, YANG Z H, et al. A review of lithium-ion battery for electric vehicle applications and beyond[J]. *Energy Procedia*, 2019, 158: 4363-4368.
- [154] 王萍, 弓清瑞, 张吉昂, 等. 一种基于数据驱动与经验模型组合的锂电池在线健康状态预测方法[J]. *电工技术学报*, 2021, 36(24): 5201-5212.
- [155] KEIL P, SCHUSTER S F, WILHELM J, et al. Calendar aging of lithium-ion batteries[J]. *Journal of the Electrochemical*

- Society, 2016, 163(9): A1872–A1880.
- [156] EDDAHECH A, BRIAT O, VINASSA J M. Performance comparison of four lithium-ion battery technologies under calendar aging[J]. *Energy*, 2015, 84: 542–550.
- [157] SHEN S, SADOUGHI M, CHEN X Y, et al. A deep learning method for online capacity estimation of lithium-ion batteries[J]. *Journal of Energy Storage*, 2019, 25: 100817.
- [158] LIU K L, ASHWIN T R, HU X S, et al. An evaluation study of different modelling techniques for calendar ageing prediction of lithium-ion batteries[J]. *Renewable and Sustainable Energy Reviews*, 2020, 131: 110017.
- [159] MANOHARAN A, SOORIAMOORTHY D, BEGAM K M, et al. Electric vehicle battery pack state of charge estimation using parallel artificial neural networks[J]. *Journal of Energy Storage*, 2023, 72: 108333.
- [160] LI P H, ZHANG Z J, XIONG Q Y, et al. State-of-health estimation and remaining useful life prediction for the lithium-ion battery based on a variant long short term memory neural network[J]. *Journal of Power Sources*, 2020, 459: 228069.
- [161] WEI M, YE M, LI J B, et al. State of charge estimation of lithium-ion batteries using LSTM and NARX neural networks[J]. *IEEE Access*, 2020, 8: 189236–189245.
- [162] FENG X N, WENG C H, HE X M, et al. Online state-of-health estimation for Li-ion battery using partial charging segment based on support vector machine[J]. *IEEE Transactions on Vehicular Technology*, 2019, 68(9): 8583–8592.
- [163] LYU Z Q, WANG G, GAO R J. Synchronous state of health estimation and remaining useful lifetime prediction of Li-Ion battery through optimized relevance vector machine framework[J]. *Energy*, 2022, 251: 123852.
- [164] OUYANG Q, MA R, WU Z X, et al. Adaptive square-root unscented Kalman filter-based state-of-charge estimation for lithium-ion batteries with model parameter online identification[J]. *Energies*, 2020, 13(18): 4968.
- [165] 李玥铤, 刘淑杰, 高斯博, 等. 基于维纳过程的锂离子电池剩余寿命预测[J]. *大连理工大学学报*, 2017, 57(2): 126–132.
- [166] 邓鸿彬, 吴松荣, 刘齐, 等. 基于改进高斯过程回归的锂离子电池健康状态估计[J/OL]. *电源学报*: 1–12 (2024-04-26) [2024-06-25]. <http://kns.cnki.net/kcms/detail/12.1420.TM.20240426.0915.008.html>.
- [167] LIU H A, DENG Z W, CHE Y H, et al. Big field data-driven battery pack health estimation for electric vehicles: A deep-fusion transfer learning approach[J]. *Mechanical Systems and Signal Processing*, 2024, 218: 111585.
- [168] YANG Y S, XU Y C, NIE Y W, et al. Deep transfer learning enables battery state of charge and state of health estimation[J]. *Energy*, 2024, 294: 130779.
- [169] 刘冰, 周浩兵, 刘雨辰, 等. 基于 ANN 的锂离子电池 SOC 估算方法研究[J]. *电源技术*, 2019, 43(12): 2036–2039.
- [170] CHEN L P, XU C C, BAO X Y, et al. State-of-health estimation of Lithium-ion battery based on back-propagation neural network with adaptive hidden layer[J]. *Neural Computing and Applications*, 2023, 35(19): 14169–14182.
- [171] CUI Z H, WANG L C, LI Q, et al. A comprehensive review on the state of charge estimation for lithium-ion battery based on neural network[J]. *International Journal of Energy Research*, 2022, 46(5): 5423–5440.
- [172] CHEN Z, XIA X L, SUN M M, et al. State of health estimation of lithium-ion batteries based on fixed size LS-SVM[C]// *Proceedings of the IEEE Vehicle Power and Propulsion Conference (VPPC)*, 2018: 1–6.
- [173] YAO L, FANG Z P, XIAO Y Q, et al. An intelligent fault diagnosis method for lithium battery systems based on grid search support vector machine[J]. *Energy*, 2021, 214: 118866.
- [174] LIU L Z, HUANG Y K, HUANG S B. Prediction of battery capacity based on improved model of support vector regression[J]. *Journal of Physics: Conference Series*, 2023, 2427(1): 012012.
- [175] CHATTERJEE S, KUMAR GATLA R, SINHA P, et al. Fault detection of a Li-ion battery using SVM based machine learning and unscented Kalman filter[J]. *Materials Today: Proceedings*, 2023, 74: 703–707.
- [176] 侯小康, 袁裕鹏, 童亮. 基于改进相关向量机的锂电池剩余使用寿命预测[J]. *电源技术*, 2024, 48(2): 289–298.
- [177] LI H, PAN D H, PHILIP CHEN C L. Intelligent prognostics for battery health monitoring using the mean entropy and relevance vector machine[J]. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2014, 44(7): 851–862.
- [178] LIU D T, ZHOU J B, PAN D W, et al. Lithium-ion battery remaining useful life estimation with an optimized Relevance Vector Machine algorithm with incremental learning[J]. *Measurement*, 2015, 63: 143–151.
- [179] XU L, WU F, CHEN R J, et al. Data-driven-aided strategies in battery lifecycle management: Prediction, monitoring, and optimization[J]. *Energy Storage Materials*, 2023, 59: 102785.
- [180] JIA S, MA B, GUO W, et al. A sample entropy based prognostics method for lithium-ion batteries using relevance vector machine[J]. *Journal of Manufacturing Systems*, 2021, 61: 773–781.
- [181] CHANG Y, FANG H J. A hybrid prognostic method for system degradation based on particle filter and relevance vector machine[J]. *Reliability Engineering & System Safety*, 2019, 186: 51–63.
- [182] QIAN C, HE N, HE L L, et al. State of health estimation of lithium-ion battery using energy accumulation-based feature extraction and improved relevance vector regression[J]. *Journal of Energy Storage*, 2023, 68: 107754.

- [183] 吴铁洲,杨蒙蒙,吴笑民,等. 基于模糊控制的锂离子电池变频脉冲快速充电[J]. 电源技术,2016,40(7):1419-1421.
- [184] ANGUNDJAJA C Y, WANG Y, JIANG W Y. Power management for connected EVs using a fuzzy logic controller and artificial neural network[J]. Applied Sciences, 2021, 12(1):52.
- [185] SAJI D, BABU P S, ILANGO K. SoC estimation of lithium ion battery using combined coulomb counting and fuzzy logic method[C]//Proceedings of the 4th International Conference on Recent Trends on Electronics, Information, Communication & Technology (RTEICT), 2019:948-952.
- [186] WANG B, QIN F F, ZHAO X B, et al. Equalization of series connected lithium-ion batteries based on back propagation neural network and fuzzy logic control[J]. International Journal of Energy Research, 2020, 44(6):4812-4826.
- [187] WU T Z, QI Y B, LIAO L, et al. Research on equalization strategy of lithium-ion batteries based on fuzzy logic control[J]. Journal of Energy Storage, 2021, 40:102722.
- [188] DÍAZ C, QUINTERO V, PÉREZ A, et al. Particle-filtering-based prognostics for the state of maximum power available in lithium-ion batteries at electromobility applications[J]. IEEE Transactions on Vehicular Technology, 2020, 69(7):7187-7200.
- [189] CADINI F, SBARUFATTI C, CANCELLIERE F, et al. State-of-life prognosis and diagnosis of lithium-ion batteries by data-driven particle filters[J]. Applied Energy, 2019, 235:661-672.
- [190] 黄煜峰,梁焕超,许磊. 基于卡尔曼滤波算法优化Transformer模型的锂离子电池健康状态预测方法[J]. 储能科学与技术, 2024, 13(8):2791-2802.
- [191] HE H W, LIU Z T, HUA Y. Adaptive extended Kalman filter based fault detection and isolation for a lithium-ion battery pack[J]. Energy Procedia, 2015, 75:1950-1955.
- [192] ZHAO Y F, XU J, WANG X, et al. The adaptive fading extended Kalman filter SOC estimation method for lithium-ion batteries[J]. Energy Procedia, 2018, 145:357-362.
- [193] YANG S C, ZHOU S D, HUA Y, et al. A parameter adaptive method for state of charge estimation of lithium-ion batteries with an improved extended Kalman filter[J]. Scientific Reports, 2021, 11:5805.
- [194] LING L Y, WEI Y. State-of-charge and state-of-health estimation for lithium-ion batteries based on dual fractional-order extended Kalman filter and online parameter identification[J]. IEEE Access, 2021, 9:47588-47602.
- [195] WANG T P, CHEN S Z, REN H B, et al. Model-based unscented Kalman filter observer design for lithium-ion battery state of charge estimation[J]. International Journal of Energy Research, 2018, 42(4):1603-1614.
- [196] 张子超,邹必昌. 基于混合卡尔曼粒子滤波的电动汽车锂电池荷电状态估计[J]. 汽车工程师, 2024(3):28-34.
- [197] LIU Z B, SUN G Y, BU S H, et al. Particle learning framework for estimating the remaining useful life of lithium-ion batteries[J]. IEEE Transactions on Instrumentation and Measurement, 2017, 66(2):280-293.
- [198] MIAO Q, XIE L, CUI H J, et al. Remaining useful life prediction of lithium-ion battery with unscented particle filter technique[J]. Microelectronics Reliability, 2013, 53(6):805-810.
- [199] LIU C, WANG Y J, CHEN Z H. Degradation model and cycle life prediction for lithium-ion battery used in hybrid energy storage system[J]. Energy, 2019, 166:796-806.
- [200] TANG X P, LIU K L, WANG X, et al. Real-time aging trajectory prediction using a base model-oriented gradient-correction particle filter for Lithium-ion batteries[J]. Journal of Power Sources, 2019, 440:227118.
- [201] DUAN B, ZHANG Q, GENG F, et al. Remaining useful life prediction of lithium-ion battery based on extended Kalman particle filter[J]. International Journal of Energy Research, 2020, 44(3):1724-1734.
- [202] HUI Z L, SHI Z G, WANG R J, et al. Health prediction of lithium-ion batteries by combining with empirical mode decomposition and PF-GPR algorithm[J]. Materials Today Energy, 2024, 42:101562.
- [203] SI X S, WANG W B, HU C H, et al. Remaining useful life estimation-A review on the statistical data driven approaches[J]. European Journal of Operational Research, 2011, 213(1):1-14.
- [204] 张然,刘天宇,金光. 基于核自构建-高斯过程回归的锂离子电池剩余使用寿命预测[J]. 系统工程与电子技术, 2023, 45(8):2623-2633.
- [205] RICHARDSON R R, BIRKL C R, OSBORNE M A, et al. Gaussian process regression for *in situ* capacity estimation of lithium-ion batteries[J]. IEEE Transactions on Industrial Informatics, 2019, 15(1):127-138.
- [206] LI X Y, YUAN C G, WANG Z P. Multi-time-scale framework for prognostic health condition of lithium battery using modified Gaussian process regression and nonlinear regression[J]. Journal of Power Sources, 2020, 467:228358.
- [207] XU X D, YU C Q, TANG S J, et al. State-of-health estimation for lithium-ion batteries based on Wiener process with modeling the relaxation effect[J]. IEEE Access, 2019, 7:105186-105201.
- [208] TANG S J, YU C Q, WANG X, et al. Remaining useful life prediction of lithium-ion batteries based on the Wiener process with measurement error[J]. Energies, 2014, 7(2):520-547.
- [209] XU X D, YU C Q, TANG S J, et al. Remaining useful life prediction of lithium-ion batteries based on Wiener processes with

- considering the relaxation effect[J]. *Energies*, 2019, 12(9): 1685.
- [210] ZHANG S Y, ZHAI Q Q, LI Y Q. Degradation modeling and RUL prediction with Wiener process considering measurable and unobservable external impacts[J]. *Reliability Engineering & System Safety*, 2023, 231: 109021.
- [211] ZHENG H L, YANG J, ZHAO Y. Reliability analysis of multi-stage degradation with stage-varying noises based on the nonlinear Wiener process[J]. *Applied Mathematical Modelling*, 2024, 125: 445–467.
- [212] SHEN S, SADOUGHI M, LI M, et al. Deep convolutional neural networks with ensemble learning and transfer learning for capacity estimation of lithium-ion batteries[J]. *Applied Energy*, 2020, 260: 114296.
- [213] 莫易敏, 余自豪, 叶鹏, 等. 基于迁移学习与GRU神经网络结合的锂电池SOH估计[J]. *太阳能学报*, 2024, 45(3): 233–239.
- [214] LI Y H, LI K, LIU X, et al. Lithium-ion battery capacity estimation—A pruned convolutional neural network approach assisted with transfer learning[J]. *Applied Energy*, 2021, 285: 116410.
- [215] TAN Y D, ZHAO G C. Transfer learning with long short-term memory network for state-of-health prediction of lithium-ion batteries[J]. *IEEE Transactions on Industrial Electronics*, 2020, 67(10): 8723–8731.
- [216] TANG X P, ZHOU Y Q, GAO F R, et al. Joint estimation of state-of-charge and state-of-health for all cells in the battery pack using “leader-follower” strategy[J]. *eTransportation*, 2023, 15: 100213.
- [217] TANG X P, ZOU C F, YAO K, et al. Aging trajectory prediction for lithium-ion batteries via model migration and Bayesian Monte Carlo method[J]. *Applied Energy*, 2019, 254: 113591.
- [218] TANG X P, LIU K L, WANG X, et al. Model migration neural network for predicting battery aging trajectories[J]. *IEEE Transactions on Transportation Electrification*, 2020, 6(2): 363–374.
- [219] 申江卫, 刘伟强, 高承志, 等. 宽温度环境下基于迁移模型的锂电池组SOC估计[J]. *中国公路学报*, 2024, 37(5): 383–396.
- [220] SEVERSON K A, ATTIA P M, JIN N, et al. Data-driven prediction of battery cycle life before capacity degradation[J]. *Nature Energy*, 2019, 4: 383–391.
- [221] TANG X P, LIU K L, LI K, et al. Recovering large-scale battery aging dataset with machine learning[J]. *Patterns*, 2021, 2(8): 100302.
- [222] SAHA B, GOEBEL K. Model adaptation for prognostics in a particle filtering framework[J]. *International Journal of Prognostics and Health Management*, 2011, 2(1): 10.
- [223] ZOU G, SONG L, YAN Z. Lithium-ion battery remaining useful life prediction based on hybrid model[C]//*Proceedings of the 7th International Conference on Intelligent Computing and Signal Processing (ICSP)*, 2022: 714–719.
- [224] ALTINTAS H Y C. A novel on-board SOH estimation method for lithium-ion batteries with hybrid feature approach[EB/OL]. (2024-05-10)[2024-06-25]. <https://10.36227/techrxiv.171502845.55394768/v2>.
- [225] YANG P, YANG H D, MENG X B, et al. Joint evaluation and prediction of SOH and RUL for lithium batteries based on a GBLS booster multi-task model[J]. *Journal of Energy Storage*, 2024, 75: 109741.
- [226] HE W, WILLIARD N, OSTERMAN M, et al. Prognostics of lithium-ion batteries based on Dempster-Shafer theory and the Bayesian Monte Carlo method[J]. *Journal of Power Sources*, 2011, 196(23): 10314–10321.
- [227] XING Y J, MA E W M, TSUI K L, et al. An ensemble model for predicting the remaining useful performance of lithium-ion batteries[J]. *Microelectronics Reliability*, 2013, 53(6): 811–820.
- [228] LIU Y P, HOU B, AHMED M, et al. A hybrid deep learning approach for remaining useful life prediction of lithium-ion batteries based on discharging fragments[J]. *Applied Energy*, 2024, 358: 122555.
- [229] CHEN Y, BIN, ET AL. Filter methods comparison for incremental capacity analysis in Lithium-ion batteries health prediction[EB/OL]. (2024-04-16)[2024-06-25]. <https://doi.org/10.2139/ssrn.4807835>.
- [230] BIRKL C. Oxford Battery Degradation Dataset 1[DS]. University of Oxford, 2017.
- [231] ZHANG C L, LUO L J, YANG Z, et al. Battery SOH estimation method based on gradual decreasing current, double correlation analysis and GRU[J]. *Green Energy and Intelligent Transportation*, 2023, 2(5): 100108.

(编辑 许军策)