



控制工程  
*Control Engineering of China*  
ISSN 1671-7848, CN 21-1476/TP

## 《控制工程》网络首发论文

题目: 面向储能电池集群的记忆特征融合与 SOC 估计方法  
作者: 郑振巍, 陈旭, 赵春晖, 沈晓兵  
DOI: 10.14107/j.cnki.kzgc.20240397  
收稿日期: 2024-06-10  
网络首发日期: 2024-09-06  
引用格式: 郑振巍, 陈旭, 赵春晖, 沈晓兵. 面向储能电池集群的记忆特征融合与 SOC 估计方法[J/OL]. 控制工程. <https://doi.org/10.14107/j.cnki.kzgc.20240397>



**网络首发:** 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

**出版确认:** 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

## 面向储能电池集群的记忆特征融合与 SOC 估计方法

郑振巍<sup>1</sup>, 陈旭<sup>1</sup>, 赵春晖<sup>1</sup>, 沈晓兵<sup>2</sup>

(1. 浙江大学 控制科学与工程学院, 浙江 杭州 310027; 2. 浙江浙能电力股份有限公司萧山发电厂, 浙江 杭州 311251)



**摘 要：**电化学储能电池的电荷状态(State of charge, SOC)表示当前电池剩余可用电量占总容量的百分比, 是保障储能电站安全运维的必要估计量。储能系统通常由多个电池单体组成, 不同电池单体间存在一定差异, 面向单电池的方法难以准确估计储能电池组下所有单体的 SOC, 并且同一电池组下所有单体共同充放电, 整体电池组信息不可忽视。针对上述问题, 本文提出了一种单体记忆与集群特征融合的网络(Cell memory and cluster feature fusion network, CMCF), 通过集群单体双视角输入与单体特征记忆, 实现了对集群下多电池 SOC 的准确估计。一方面, 引入记忆模块, 可以记忆不同电池单体运行过程的典型特征形成单体记忆特征; 另一方面, 引入集群专家知识给整个模型提供整个电池组全局运行状况。并且对集群、单体、记忆三个特征进行融合, 实现对储能集群下各个电池单体的细粒度 SOC 估计。最终在真实储能数据集上进行实验验证, 相比与没有考虑集群特征的方法, 整体均方误差降低 71.37%。

**关键词：**电化学储能; 电池电荷状态; 深度网络; 多单体估计

**中图分类号：**TM912

**文献标识码：**A

### Memory Feature Fusion and SOC Estimation Method for Energy Storage Battery Cluster

JIA Zhenwei<sup>1</sup>, CHEN Xu<sup>1</sup>, ZHAO Chunhui<sup>1</sup>, SHEN Xiaobing<sup>2</sup>

(1. College of Control Science and Engineering, Zhejiang University, Hangzhou 310027, China; 2. Zhejiang Zheneng Co. Ltd. Xiaoshan Power Plants, Hangzhou, 311251, China)

**Abstract:** The state of charge (SOC) of electrochemical energy storage batteries represents the percentage of remaining usable electricity in the battery compared to its total capacity, which is a necessary estimate for ensuring the safe operation of energy storage stations. Energy storage systems typically consist of multiple individual battery cells, which exhibit certain differences. Methods focused on individual cells struggle to accurately estimate the SOC of all cells in an energy storage battery pack, as all cells within the same battery pack undergo charging and discharging collectively, and the overall information of the battery pack cannot be ignored. To address this issue, this paper proposes a cell memory and cluster feature fusion network (CMCF), which accurately estimates the SOC of multiple cells in a cluster by incorporating dual-perspective inputs from cluster and cell features, as well as cell memory. On one hand, the memory module can remember the typical features of different battery cells during operation, forming cell memory features; on the other hand, leveraging cluster expert knowledge to provide information about the overall operation of the battery pack. Finally, the fusion of cluster, cell, and memory features enables fine-grained SOC estimation of individual battery cells in the energy storage cluster. Experimental verification on a real-world energy storage dataset shows that the mean squared error of estimation decreases by 71.37% compared to methods that do not consider cluster features.

**Key words:** Electrochemical energy storage; battery state of charge; deep network; multi-battery estimation

### 0 引 言

储能电站是实现能源安全的重要一环, 也是实现“双碳”目标的重要路径<sup>[1]</sup>。其中电化学储能电

收稿日期: 2024-06-10

基金项目: 浙江省“尖兵”“领雁”研发攻关计划项目(2024C01163); 国家自然科学基金杰出青年基金(62125306)

作者简介: 郑振巍(2001-), 男, 浙江台州人, 工学学士, 研究领域为大数据挖掘; 赵春晖(1979-), 女, 山东莱州人, 博士, 教授, 研究领域为大数据分析及其在不同领域的应用(本文通信作者, Email: chhzha@zju.edu.cn)。

站受地理条件影响较小,建设周期短,成本也在发展中逐渐下降,是储能新增装机的主流,也是当前应用范围最广、发展潜力最大的电力储能技术<sup>[2]</sup>。

对于储能电站的安全稳定运行,对电池的荷电状态(State of charge, SOC)估计是必须的。SOC 是电池剩余可用电量占总容量的百分比,具体公式为:

$$SOC = \frac{Q_{remain}}{Q_{rated}} \times 100\% \quad (1)$$

其中  $Q_{remain}$  是电池当前剩余的电荷容量,  $Q_{rated}$  是电池当前标定的电荷容量<sup>[3]</sup>。准确估计 SOC 可以帮助电池安全充放电,如果未对电化学储能系统的 SOC 进行准确估计,可能会导致电池过充进而引发火灾、爆炸等事故,危及储能电站甚至电力工业过程的安全稳定运行<sup>[4]</sup>。

电池的 SOC 通常难以利用传感器直接测量得到,但在受控的实验室环境中,可通过开路电压(Open circuit voltage, OCV)和 SOC 之间的特定关系,即开路电压法进行计算。然而,开路电压的测量需要电池在每次电池充放电后静置一个多小时,因而无法在线应用。

在线估计 SOC 的方法通常可以分为库伦计数法、模型驱动的方法和数据驱动的方法。其中,最常用的办法是库伦计数法,使用测得的电流和时间的积分来获得 SOC<sup>[5]</sup>。但是作为一种开环估计方法,不准确的初始 SOC 和电流累积误差会使 SOC 估计的准确性不断降低<sup>[6]</sup>。其次是模型驱动的方法,这些方法利用电压模型来建立电压信号和 SOC 之间的联系。主要电压模型为电化学模型(Electrochemical models, EM)和等效电路模型(Equivalent circuit models, ECM)。电化学模型需要深入了解电池的内部化学和电气特性,并用偏微分方程<sup>[7]</sup>来描述其内部过程。其基本的等效电路模型包括 Rint 模型、一阶 RC 模型、二阶 RC 模型和 Thevenin 模型等<sup>[8]</sup>。基于模型的方法的 SOC 估计性能需要假设电池模型是准确建立的,并通过滤波算法提高估计精度,如扩展和无迹卡尔曼滤波<sup>[9]</sup>等。虽然基于模型的方法可以通过复杂的机理模型生成可靠的模型,但模型的建立复杂,参数难以准确获取且对参数的精度要求高,同时模型在不同工况下表现可能不稳定,且计算时间较长,限制了其在实时应用中的使用。

随着数据驱动与人工智能的方法在多领域中的发展<sup>[10]</sup>,众多学者开始研究数据驱动方法在 SOC

估计上的应用。数据驱动的方法无需建立复杂的电池模型,基于大量离线数据,建立并训练电池可测变量(电压、电流、表面温度)和 SOC 之间的直接映射关系模型。此外,深度学习模型依靠其强大的拟合能力收到了越来越多研究者的青睐<sup>[11]</sup>。常用于电池 SOC 估计的深度学习模型有层感知机网络(Multi-layer perception, MLP)<sup>[12]</sup>、长短期记忆(Long short term memory, LSTM)<sup>[13]</sup>网络、时域卷积网络(Temporal convolutional network, TCN)<sup>[14]</sup>等等。同时,也有研究者对这些网络进行组合开发了更强大的深度学习模型,如 Hu 等人<sup>[15]</sup>提出了一种 TCN 与 LSTM 相结合的神经网络来估计 SOC。

然而,上述方法主要应用于针对单个电池的 SOC 估计。出于对电压和功率的要求,电化学储能系统通常由多达数百个串联或并联的电池单体(Cell)组成。由于生产技术和公差的限制、材料缺陷等,电池之间在容量、动力学和老化特性<sup>[16]</sup>等方面可能存在微小差异,最终反映在 SOC 或内阻等差异上<sup>[17]</sup>。因此,估计电池组中每个单体电池的 SOC 是对过充防护很有必要的。虽然可以通过复制单体 SOC 估计器进行多单体估计,但是这种办法没有考虑不同单体之间的差异,同时忽视了整体电池组的整体运行特性与变化趋势。电池组中的所有单体可作为一个集群,在运行过程中会同时充放电,将整体电池组的全局数据信息输入到模型中,提供辅助信息,扩展输入视角,有利于每个单体 SOC 的估计。针对上述问题,本文提出了单体记忆与集群特征融合的网络(Cell memory and cluster feature fusion network, CMCF),将电池组里多个单体视为同一个集群,通过集群单体双视角输入与记忆典型单体特征,实现对 SOC 准确估计。一方面,引入记忆模块,可以记忆不同电池单体运行过程的典型特征形成单体记忆特征;另一方面,引入集群专家知识给整个模型提供整个电池组全局运行状况,增加输入信息。并且对集群、单体、记忆三个特征进行融合,最终可实现对储能集群下各个电池单体的细粒度 SOC 估计。本文的贡献点总结如下:

1)考虑了储能集群的整体运行效应,分为单体特征和集群特征两部分输入,扩展了模型输入的信息量,并通过类注意力机制进行特征融合,从而实现模型对电池组整体运行工况的关注,辅助 SOC 估计,增加了估计精度;

2)引入可训练的记忆机制,对关键的单体特征进行记忆,实现对电池运行的典型模式记忆以及单

体差异的记忆，进而满足对具有一定差异的不同电池的統一表征刻画，最终提高对同一电池组下每一个单体电池的 SOC 估计精度和细粒度。

本文剩余部分结构如下，第 2 节首先介绍了残差深度神经网络架构和记忆机制，第 3 节介绍了所提用于电池组多单体 SOC 估计的 CMCF 网络，第 4 节通过实验证明了所提方法的有效性，第 5 节进行了总结与讨论。

## 1 相关知识

本节将简要介绍残差神经网络和记忆机制的相关知识。

### 1.1 残差神经网络

残差神经网络(Residual network, ResNet)是由 He 等人于 2015 年提出的一种神经网络架构<sup>[18]</sup>，引入了残差学习的概念，通过添加跨层连接(skip connection)来解决深层神经网络训练过程中的梯度消失和梯度爆炸问题。这种设计使网络可以更容易地被训练，极大地提升了深度神经网络的性能和效率。

在 ResNet 中，每个基本块(basic block)包含了多个卷积层和批量归一化层，同时引入了残差连接。具体地，设输入为  $x$ ，经过基本块后的输出为  $F(x)$ ，则基本块的输出可以表示为：

$$y = F(x) + x \quad (2)$$

其中  $F(x)$  表示基本块内部的卷积和批量归一化操作， $x$  表示输入的特征。通过残差连接，网络可以学习到残差  $y - x$ ，从而更好地优化网络参数。

残差神经网络可以避免电池时序数据由于简单重复等特征带来的梯度消失等问题。

### 1.2 记忆机制

记忆机制是 Park 等人<sup>[19]</sup>为图像异常检测任务提出的一种模块，来记录训练样本的典型模式。记忆模块中有  $M$  个记忆体(item)，记作  $p_m \in \mathbb{R}^c$  ( $m=1,2,\dots,M$ )，即  $M$  个典型正常模式，输入为  $K$  个查询特征(query)，记作  $q_k \in \mathbb{R}^c$  ( $k=1,2,\dots,K$ )。记忆模块中包含读取(Read)和更新(Update)两个操作，Update 操作用于更新 item，不断更新学习典型正常模式，Read 操作则根据 query 和记忆的 item，生成带有典型模式的聚合特征。

Read 操作分为两步，第一步是计算特征和各个 item 的余弦相似性，并利用 softmax 计算，得权重  $w^{k,m}$ ：

$$w^{k,m} = \frac{\exp((p_m)^T q_k)}{\sum_{m'=1}^M \exp((p_{m'})^T q_k)} \quad (3)$$

第二步是根据权重  $w^{k,m}$  和 item 加权，获取聚合特征  $p^k$ 。

$$p^k = \sum_{m=1}^M w^{k,m} p_m \quad (4)$$

Update 操作则是分为三步，第一步同样先计算各个 item 和所有特征的余弦相似性，并利用 softmax 计算，得权重  $v^{k,m}$ ：

$$v^{k,m} = \frac{\exp((p_m)^T q_k)}{\sum_{k'=1}^K \exp((p_m)^T q_{k'})} \quad (5)$$

第二步根据第  $m$  个 item 相似度最大的 query 的集合  $U^m$  归一化，得  $v'^{k,m}$

$$v'^{k,m} = \frac{v^{k,m}}{\max_{k \in U^m} v^{k,m}} \quad (6)$$

第三步根据  $U^m$  和  $v'^{k,m}$  更新第  $m$  个 item：

$$p_m \leftarrow f(p_m + \sum_{k \in U^m} v'^{k,m} q_k) \quad (7)$$

其中函数  $f$  是 L2 范数。

记忆模块负责对电池组运行的多模式进行捕获。电池组的多模式特性指的是，电池组在运行中，每个电池单体存在一定差异，同时不同电池在充电过程中的运行模式存在一定差异。因此需要对不同模式进行细粒度刻画。因此，我们通过记忆模块将电池单体特征用记忆体进行保存记录，即通过记忆体捕获不同电池样本之间的差异与典型模式。在应用过程中将单体特征通过与不同记忆体进行匹配得到对应权重，加权求和后变换表征为记忆特征的形式，从而进行细粒度表征以及实现对多模式的刻画，最终能够帮助网络对不同单体的 SOC 进行准确估计。

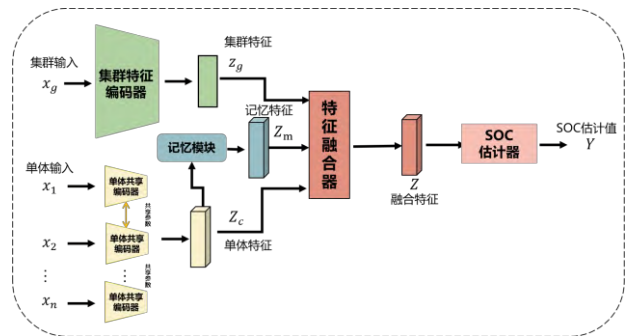


图 1 CMCF 总体结构示意图

Fig. 1 The overall structure



## 2 面向储能系统电池堆的充电状态估计方法

### 2.1 多单体 SOC 估计场景描述

传统数据驱动的单体 SOC 估计一般输入电池测点时序数据  $x_c \in \mathbb{R}^{J \times T}$ , 其中  $J$  表示测点变量数,  $T$  代表时序长度, 测点一般为电压、电流、表面温度等。输出为 SOC,  $y_c \in \mathbb{R}^1$ , 即一个电池单体数据估计一个 SOC 数值。对于集群 SOC 估计问题而言, 输入为电池组的多个单体的测点时序数据,  $X \in \mathbb{R}^{N \times J \times T}$ ,  $X = [x_1, x_2, \dots, x_N]$ , 其中  $N$  为电池单体的个数, 输出也为多个单体的 SOC,  $Y \in \mathbb{R}^N$ 。对于串联电池组而言同一时刻所有单体的电流为同一值, 而对于并联数据的电压为同一值。在该场景下需要利用同一电池组多单体的历史测点信息, 估计每个电池单体的当前 SOC。

### 2.2 整体网络架构

如图 1 所示, 整体网络模型由单体共享编码器、集群编码器、记忆模块、特征融合器以及 SOC 估计器五部分组成。

首先, 集群与单体双视角输入分别通过集群编码器与单体共享编码器得到集群特征与所有单体的整体单体特征, 单体特征通过记忆模块得到记忆特征, 将每个单体的集群特征、记忆特征、单体特征通过特征融合器得到最终的融合特征。最后通过 SOC 估计器, 得到估计的 SOC。本方法采用端到端的方式进行训练, 接下来会对本方法的各个部分进行详细阐述。

### 2.3 特征工程

考虑到电池集群为整个串联的电池组, 电池组内的单体的 SOC 与整体电池组的运行状况以及电池管理系统(Battery management system, BMS)对电池的平衡控制策略具有不可忽视的相关性<sup>[20]</sup>。为了同时考虑电池单体自身的运行情况和电池组整体的集群运行情况, 模型的输入分为集群和单体两个视角, 并分别构造成集群特征和单体特征。




图 2 残差 MLP 模块示意图

Fig. 2 The structure of residual MLP

对于单体的特征构造, 在同一批次中所有单体数据一起输入, 共  $N$  个单体输入。这些单体特征通过共享参数的单体编码器编码后得到对应的  $N$  个单体特征。考虑到需要实时计算多个单体的 SOC, 以及近年来的时序网络研究工作<sup>[21]</sup>表明 MLP 网络对于时序数据的分析具有良好效果。在本文中, 采用与 TiDE<sup>[21]</sup>的基础架构类似的残差 MLP 模块作为基本时序网络模块。如图 2 所示, 残差 MLP 模块与 resnet 的基本模块类似, 数据通过一层非线性层、一层线性层以及一层 Dropout 层后进行残差连接, 再做标准化。单体共享编码器  $E_c$  由  $N_c$  个残差 MLP 模块堆叠而成, 具体公式为:

$$E_c = \text{Dense}(N_c \times \text{resMLP}(\cdot)) \quad (8)$$

其中 Dense 是线性层, resMLP 是残差 MLP 模块。因此在输入模块前需要先将每个单体的二维时序数据  $x_i$  通过 flatten 操作展开成一维时序数据  $x_c^i \in \mathbb{R}^T$ :

$$x_c^i = \text{flatten}(x_i), i = 1, 2, \dots, N \quad (9)$$

其中 flatten( $\cdot$ ) 是展开操作。最终通过  $E_c$  得到整体单体特征  $Z_c \in \mathbb{R}^{N \times D}$ ,  $Z_c = [z_c^1, z_c^2, \dots, z_c^N]$ , 其中  $D$  是单体特征的维度, 单个单体特征计算公式如下:

$$z_c^i = E_c(x_c^i), i = 1, 2, \dots, N \quad (10)$$

而集群视角输入则是构造的集群专家知识,  $x_g \in \mathbb{R}^{G \times T}$ , 其中  $T$  代表时间维度窗口长度与单体输入相同,  $G$  代表集群专家知识的空间维度, 集群专家知识指的是基于电池组运行测量数据构造均值、方差、偏度等统计量, 从而反映出电池组集群运行情况和单体间的不一致性。具体计算公式如下:

$$x_g = [\mathcal{S}(f_1), \dots, \mathcal{S}(f_{J-1}), f_J] \quad (11)$$

其中,  $\mathcal{S}(\cdot)$  表示测点的专家知识构造计算, 由多个构造特征合并, 构造的特征计算公式在表 1 中列出;  $f_i (i = 1, \dots, J)$  代表第  $i$  个测点在所有单体上的时序数据,  $f_i \in \mathbb{R}^{N \times T}$ ,  $f_1$  到  $f_{J-1}$  是每个单体独立的测点数据, 而  $f_J$  是所有单体共享的测点, 如串联电池组的电流, 不进行构造。

表 1 集群专家知识构造特征表  
Tab. 1 Cluster hand-crafted features table

构造特征	计算公式
均值	$\mathcal{S}_{\text{mean}}(v) = \frac{1}{N} \sum_i v_i$

方差	$\mathcal{S}_{\text{var}}(v) = \frac{1}{N} \sum_i (v_i - \mathcal{S}_{\text{mean}})^2$
偏度	$\mathcal{S}_{\text{sk}}(v) = \frac{1}{N \cdot \mathcal{S}_{\text{var}}^3} \sum_i (v_i - \mathcal{S}_{\text{mean}})^3$
峰-峰值	$\mathcal{S}_{\text{pp}}(v) = \max(v) - \min(v)$
翘度	$\mathcal{S}_{\text{ku}}(v) = \frac{1}{N \cdot \mathcal{S}_{\text{var}}^4} \sum_i (v_i - \mathcal{S}_{\text{mean}})^4$

注： $v$  为输入测点数据， $v_i$  是  $v$  的第  $i$  个单体的数据

与单体特征一样，得到的集群特征展平后，通过集群编码器编码得到集群特征  $z_g$ ：

$$z_g = E_g(\text{flatten}(x_g)) \quad (12)$$

$$E_g = \text{Dense}(N_g \times \text{resMLP}(\cdot)) \quad (13)$$

其中，集群编码器  $E_g$  与单体编码器  $E_c$  类似，由  $N_g$  个残差 MLP 模块堆叠组成，需要注意的是同一集群下的不同单体在同一时刻的集群特征为同一个。

## 2.4 记忆模块

考虑到电池组内电池单体的不一致性，包括内阻、初始容量、最大容量等等的差异<sup>[22]</sup>，在估计 SOC 时需要考虑这些差异所带来的影响，因此采用记忆模块来解决这一问题。

在记忆模块中有  $M$  个电池记忆体作为 item，记作  $p_i \in \mathbb{R}^D (i=1, 2, \dots, M)$ ，即  $M$  个典型电池单体模式，训练开始前记忆体通过高斯分布随机初始化。将编码得到的全部单体特征拆分开输入到记忆模块中，即  $z_c^i \in \mathbb{R}^D (i=1, 2, \dots, N)$  作为 query，将 item 和 query 通过公式(3)与公式(4)Read 操作计算得到对应的记忆特征  $z_m^i \in \mathbb{R}^D (i=1, 2, \dots, N)$ ，同样整体记忆特征记为  $Z_m \in \mathbb{R}^{N \times D}$ ， $Z_m = [z_m^1, z_m^2, \dots, z_m^N]$ 。训练时，还需要通过公式(5)与公式(6)进行 Update 操作，更新记忆 item。

在记忆模块中为保证记忆特征的多样性和典型性，以确保能够以记录各个电池单体的差异性特征与充电典型特征被记录，采用特征紧密度损失  $\mathcal{L}_{\text{compact}}$  与特征分离损失  $\mathcal{L}_{\text{separate}}$  进行约束。其中  $\mathcal{L}_{\text{compact}}$  希望查询的特征 query 与其最接近的 item 之间的距离更近，也就是单体特征能够匹配上对应的典型特征以及固有差异特性，具体损失公式如下：

$$\mathcal{L}_{\text{compact}} = \sum_i \|z_c^i - p_p\|_2 \quad (14)$$

其中  $p$  为 query  $q_i$  最相似 item 的索引，定义为：

$$p = \arg \max_{i_m \in m} w^{i, i_m} \quad (15)$$

$\mathcal{L}_{\text{separate}}$  则是希望记忆的 item 之间具有足够的差异，即让记忆 item 能够表征不同充电阶段的典型模式以及电池单体之间的固有差异，具体损失公式如下：

$$\mathcal{L}_{\text{separate}} = \sum_i [\|z_c^i - p_p\|_2 - \|z_c^i - p_q\|_2 + \alpha]_+ \quad (16)$$

其中  $q$  为 query  $q_i$  第二相似 item 的索引，定义为：

$$q = \arg \max_{i_m \in m, i_m \neq p} w^{i, i_m} \quad (17)$$

## 2.5 特征融合

在得到  $z_g$ 、 $z_c$ 、 $z_m$  三个特征后，需要对每个单体进行特征融合操作，借鉴 self-attention 的结构<sup>[23]</sup>，提出了集群注意力(Cluster Attention)。如图 3 所示，以第  $i$  个单体为例，其中集群特征  $z_g$  通过线性映射  $W_Q$  获得  $Q$ ，记忆特征  $z_m^i$  通过线性映射  $W_K$  获得  $K_i$ ，单体特征通过  $z_c^i$  线性映射  $W_V$  获得  $V_i$ ， $Q, K_i, V_i \in \mathbb{R}^{d_k}$ ， $d_k$  是融合特征的维度。对于每一个单体的融合特征具体计算公式如下：

$$z_i = \text{softmax} \left( \frac{A_i}{\sqrt{d_k}} \right) V_i, i=1, 2, \dots, N \quad (18)$$

$$A_i = Q^T K_i \quad (19)$$

最终得到融合特征  $Z \in \mathbb{R}^{N \times d_k}$ ， $Z = [z_1, z_2, \dots, z_N]$ 。

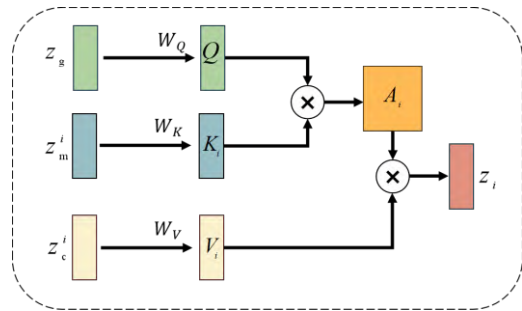


图 3 Cluster Attention 示意图  
Fig. 3 The structure of Cluster Attention

对于 SOC 的估计而言，单体信息应是最主要因素，因此作为自注意力中的 value，形成最后的特征主体。记忆特征作为典型特征找到相对固定的集群特征中重要的信息，形成注意力矩阵，更好得筛选出集群特征当中有用的信息，相比于过于依赖具体的单体特征更具有泛化性，防止单体特征在训练计算当中出现过拟合。

## 2.6 模型训练

融合特征  $Z$  最后通过 SOC 估计器得到

$Y \in \mathbb{R}^N, Y = [y_1, y_2, \dots, y_N]$ , 计算公式为:

$$Y = \text{Estimator}(Z) \quad (20)$$

其中, Estimator 是 SOC 估计器, 其结构为 MLP 网络。

对于 SOC 的估计采用均方误差(Mean squared error, MSE)损失  $\mathcal{L}_{\text{mse}}$ , 公式如下:

$$\mathcal{L}_{\text{mse}} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (21)$$

其中  $\hat{y}_i$  是第  $i$  个单体的 SOC 的估计值,  $y_i$  是对应 SOC 的标签值。

为了实现端到端的训练, MSE 损失需要和记忆模块的损失进行相加, 整体损失如下:

$$\mathcal{L} = \lambda_1 \mathcal{L}_{\text{mse}} + \lambda_2 \mathcal{L}_{\text{compact}} + \lambda_3 \mathcal{L}_{\text{separate}} \quad (22)$$

其中  $\lambda_1$ 、 $\lambda_2$ 、 $\lambda_3$  分别是三个损失的平衡系数。

### 3 案例分析

#### 3.1 实验数据集与评价标准

采用真实磷酸铁锂储能电池数据集, 使用该储能电池堆的一个电池簇数据进行实验验证。其结构由 224 个电池单体串联构成。每个电池单体均包含电压、温度两个测点以及共享的电流数据测点, 即  $J=3$ , 采集间隔为 1 分钟。采用该电池簇的五轮充电数据作为训练数据集, 一轮充电数据为测试数据集。为了提高网络的训练效率和鲁棒性, 需要对储能电池数据进行适当的归一化, 具体而言电压、温度、电流归一化到 0-1 区间, SOC 值除以 100 进行归一化。

实验评价标准采用全部单体的 MSE 值  $\varepsilon_{\text{mse}}$ 、全部单体的平均绝对百分比误差(Mean absolute percentage error)值  $\varepsilon_{\text{mape}}$ 、测试数据中的最大的平方误差值  $\varepsilon_{\text{max}}$ 、电池簇中最快充满的单体的平均 MSE 值  $\varepsilon_{\text{fast}}$  三个指标进行评价。其中前两个指标可以表示方法在电池整体的平均绝对和相对水平, 第三个指标代表方法的最差性能, 第四个指标表示方法在最快充满的单体上的性能水平, 相对于电池组里的其他单体, 该单体更容易发生发生过充问题, 需要重点关注。三个指标计算公式如下:

$$\varepsilon_{\text{mse}} = \frac{1}{t^* \cdot N} \sum_{i=1}^{t^* \cdot N} (y_i - \hat{y}_i)^2 \quad (23)$$

$$\varepsilon_{\text{mape}} = \frac{1}{t^* \cdot N} \sum_{i=1}^{t^* \cdot N} \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\% \quad (24)$$

$$\varepsilon_{\text{max}} = \max_{i=1}^{t^* \cdot N} (y_i - \hat{y}_i)^2 \quad (25)$$

$$\varepsilon_{\text{fast}} = \frac{1}{t^*} \sum_{i=1}^{t^*} (y_i^{\text{fast}} - \hat{y}_i^{\text{fast}})^2 \quad (26)$$

其中  $t^*$  是测试集的样本长度,  $y^{\text{fast}}$  表示电池簇中最容易充满的单体的 SOC。

表 2 CMCF 网络结构表  
Tab. 2 CMCF network structure table

模块名	网络层	网络结构/参数	输出形状
数据输入模块	单体输入层	展开层	[16,224,32*3]
	集群专家	专家知识层	[16,32,11]
	知识层	展开层	[16,32*11]
	残差 MLP 层 1	Dropout=0.1, 隐藏层大小 96	[16,224,96]
单体共享编码器	全连接层	映射节点 96*32	[16,224,32]
	残差 MLP 层 1	Dropout=0.1, 隐藏层大小 96	[16,96]
	残差 MLP 层 2	Dropout=0.1, 隐藏层大小 96	[16,96]
	全连接层	映射节点 96*32	[16,32]
记忆模块	记忆读取更新层	item 长度 32	[16,224,32]
	Cluster attention	映射节点 32*16	[16,224,16]
SOC 估计器	全连接层	映射节点 32*16	[16,224,16]
	激活函数	ReLU 函数	[16,224,16]
	全连接层	映射节点 32*1	[16,224,1]

#### 3.2 对比实验

为便于理解, 本方法网络结构如表 2 所示。其中集群特征空间维度  $G=11$ , 11 个集群特征空间分别代表电压和温度的均值、方差、偏度、峰-峰值和翘度以及整个串联电池组的电流。batch size 设置为 16, 时序长度为 32, 电池单体个数  $N=224$ , 记忆模块  $M=3$ 。采用 Adam 优化器, 学习率为  $2 \times 10^{-4}$ , 其参数设置为:  $\beta_1=0.9$ 、 $\beta_2=0.999$ 。其他训练超参数  $\lambda_1$ 、 $\lambda_2$ 、 $\lambda_3$  分别设置为 10、0.1、0.1。其中学习率和记忆体个数这两个超参数通过在训练集网格搜索交叉验证所得。选取支持向量回归(Support vector regression, SVR)<sup>[24]</sup>、多层感知机网络 MLP<sup>[12]</sup>、长短期记忆网络 LSTM<sup>[13]</sup>三种数据驱动方法进行对比, 对比方法的训练设置与本方法一致, 结果如表 2 所示。

从表 3 中可以看出对比方法相比于本方法具有较大差距, 最大原因在于对比方法均没有考虑集群效应, 即在训练过程中模型只关注各个单体本身测点数据对于 SOC 的拟合, 忽视了单体间的相关性以及集群信息, 这些信息可以弥补单体数据的单一性, 从而可以更好地帮助每一个单体的 SOC 的估



计。其中本方法相比其他三个方法每个指标均有一定的提升，其中  $\varepsilon_{mse}$  提升至少 71.37%， $\varepsilon_{mape}$  提升至少 48.35%， $\varepsilon_{max}$  提升至少 64.06%， $\varepsilon_{fast}$  提升至少 68.14%。

表 3 CMCF 方法与其他方法对比  
Tab. 3 Comparison between CMCF algorithm and other algorithm

指标	$\varepsilon_{mse}$	$\varepsilon_{mape}$	$\varepsilon_{max}$	$\varepsilon_{fast}$
方法				
SVR	$6.61 \times 10^{-3}$	13.34%	$8.27 \times 10^{-2}$	$9.30 \times 10^{-3}$
MLP	$1.10 \times 10^{-3}$	5.39%	$1.50 \times 10^{-2}$	$5.87 \times 10^{-4}$
LSTM	$5.31 \times 10^{-4}$	3.33%	$1.03 \times 10^{-2}$	$1.50 \times 10^{-3}$
CMCF	<b><math>1.52 \times 10^{-4}</math></b>	<b>1.72%</b>	<b><math>3.70 \times 10^{-3}</math></b>	<b><math>1.87 \times 10^{-4}</math></b>

图 4 展示了对比方法和本方法在测试充电数据上的估计效果。其中蓝色为估计值，橙色为真实值从图中可以看出，本方法和真实的 SOC 值最相近，其估计结果明显优于其余的估计方法。




图 4 对比实验结果图

Fig. 4 Comparison of Experimental Results

### 3.3 消融实验

为了进一步验证方法的有效性，设计消融实验，实验结果如表 4 所示，其中 w/o CF 代表没有集群特征，在特征融合部分用单体特征代替，w/o memory 代表没有记忆模块，在特征融合部分用单体特征代替。w/o Cluster attention 代表没有 Cluster attention 特征融合器，特征融合部分直接由三个特征拼接映射。w/o CF&memory 代表只使用单体特征进行 SOC 估计。

通过消融实验结果，可以看到本方法各个模块的有效性，特别是集群特征，这一特征的输入对于 SOC 估计起到关键性作用，不论只用单体特征进行估计，还是只去掉集群特征，误差增大都非常明显。只去掉集群特征，网络性能下滑严重，是因为网络

输入信息减少而复杂性较高导致难以训练的结果。此外，在有集群特征输入的基础上，通过增加记忆模块与 Goup attention 特征融合模块均可以进一步提高网络的性能，三个误差指标均有一定的提高。

表 4 消融实验对比结果  
Tab. 4 Comparison of ablation experiment

指标	$\varepsilon_{mse}$	$\varepsilon_{mape}$	$\varepsilon_{max}$	$\varepsilon_{fast}$
方法				
w/o CF	$2.99 \times 10^{-3}$	7.81%	$9.41 \times 10^{-2}$	$3.88 \times 10^{-3}$
w/o memory	$2.36 \times 10^{-4}$	2.16%	$4.86 \times 10^{-3}$	$2.97 \times 10^{-4}$
w/o Cluster attention	$3.36 \times 10^{-4}$	2.62%	$3.88 \times 10^{-3}$	$3.82 \times 10^{-4}$
w/o CF&memory	$5.94 \times 10^{-4}$	3.13%	$2.96 \times 10^2$	$1.38 \times 10^{-3}$
CMCF	<b><math>1.52 \times 10^{-4}</math></b>	<b>1.72%</b>	<b><math>3.70 \times 10^{-3}</math></b>	<b><math>1.87 \times 10^{-4}</math></b>

## 4 结 论

本文针对电化学储能电池堆下多单体 SOC 估计问题进行建模，提出集群 SOC 估计方法。通过集群单体双特征输入得到集群与单体双视角的特征，再通过引入记忆模块，对单体典型特征进行记忆得到记忆特征，最后通过集群注意力模块将三者进行融合，实现对电池堆下多单体的细粒度建模。并通过真实储能数据集进行验证，相比于不考虑集群效应的方法在整体均方误差上至少降低 71.37%，同时通过消融实验证明方法各个模块的有效性，为储能集群多单体 SOC 估计提供了新的思路。

## 参考文献(References)

- [1] 林伯强. “双碳”目标下储能产业发展新趋势[J]. 人民论坛, 2024(03): 78-83.  
LIN B Q. New trends in the development of energy storage industry under the "dual carbon" goal[J]. People's Tribune, 2024(03): 78-83.
- [2] 王一航, 陈旭, 沈萌, 等. 掩码表征迁移策略下的锂电池变工况健康状态预测[J/OL]. 控制理论与应用: 1-9[2024-06-07]. <http://kns.cnki.net/kcms/detail/44.1240.TP.20231114.1358.044.html>.  
WANG Y H, CHEN X, SHEN M, et al. A Masked Feature Transfer Strategy for Lithium Battery State of Health Prediction under Variable Working Conditions[J/OL]. Control Theory and Technology: 1-9[2024-06-07]. <http://kns.cnki.net/kcms/detail/44.1240.TP.20231114.1358.044.html>.
- [3] 沈浩然, 刘振兴, 邵丽源, 等. 基于改进无迹卡尔曼滤波的锂电池荷电状态估计[J]. 控制工程, 2023, 30(12): 2217-2225.  
SHEN H R, LIU Z X, SHAO L Y, et al. State of Charge Estimation of Lithium Battery Based on Improved Unscented Kalman filter[J]. Control Engineering of China, 2023, 30(12): 2217-2225.
- [4] 赵春晖, 宋鹏宇, 从结构推断到根因识别——工业过程故障根因诊断研究综述[J]. 控制与决策, 38(8): 2130-2157, 2023.  
ZHAO C H, SONG P Y. From structure inference to root cause identification: A survey on root cause diagnosis of industrial process faults[J]. Control and Decision, 2023, 38(8): 2130-2157.
- [5] ZHAO L, LIN M, CHEN Y. Least - squares based coulomb counting method and its application for state - of - charge (SOC) estimation



- in electric vehicles[J]. International Journal of Energy Research, 2016, 40(10): 1389-1399.
- [6] ZHENG Y, OUYANG M, HAN X, et al. Investigating the error sources of the online state of charge estimation methods for lithium-ion batteries in electric vehicles[J]. Journal of Power Sources, 2018, 377: 161-188.
- [7] HU X, YUAN H, ZOU C, et al. Co-estimation of state of charge and state of health for lithium-ion batteries based on fractional-order calculus[J]. IEEE Transactions on Vehicular Technology, 2018, 67(11): 10319-10329.
- [8] HU X, LI S, PENG H. A comparative study of equivalent circuit models for Li-ion batteries[J]. Journal of Power Sources, 2012, 198: 359-367.
- [9] 夏黎黎, 王顺利, 于春梅, 等. 基于AEKF算法的三元锂电池SOC估算方法研究[J]. 控制工程, 2021, 28(04): 730-735.
- XIA L L, WANG S L, YU C M, et al. Research on SOC Estimation Method of Ternary Lithium Battery Based on AEKF Algorithm[J]. Control Engineering of China, 2021, 28(04): 730-735.
- [10] 赵春晖, 胡赞昀, 郑嘉乐, 等. 数据驱动的燃煤发电装备运行工况监控——现状与展望. 自动化学报, 2022, 48(11): 2611-2633.
- ZHAO C H, HU Y Y, ZHENG J L, et al. Data-driven operating monitoring for coal-fired power generation equipment: The state of the art and challenge[J]. Acta Automatica Sinica, 2022, 48(11): 2611-2633.
- [11] 赵健程, 冯良骏, 岳嘉祺, 等. 从零样本学习理论模型到工业应用——动机、演变与挑战[J/OL]. 控制与决策: 1-25 [2024-06-08]. <https://doi.org/10.13195/j.kzyjc.2023.0924>.
- ZHAO J C, FENG L J, YUE J Q, et al. From zero-shot learning theoretical model to its industrial application: motivation, evolution and challenges. Control and Decision: 1-25 [2024-06-08]. <https://doi.org/10.13195/j.kzyjc.2023.0924>.
- [12] PARK M, SEO M, SONG Y, et al. Capacity estimation of Li-ion batteries using constant current charging voltage with multilayer perceptron[J]. IEEE Access, 2020, 8: 180762-180772.
- [13] CHEN J, ZHANG Y, WU J, et al. SOC estimation for lithium-ion battery using the LSTM-RNN with extended input and constrained output[J]. Energy, 2023, 262: 125375.
- [14] LIU Y, LI J, Zhang G, et al. State of charge estimation of lithium-ion batteries based on temporal convolutional network and transfer learning[J]. Ieee Access, 2021, 9: 34177-34187.
- [15] HU C, CHENG F, Ma L, et al. State of charge estimation for lithium-ion batteries based on TCN-LSTM neural networks[J]. Journal of the Electrochemical Society, 2022, 169(3): 030544.
- [16] 王一航, 冯良骏, 赵春晖. 面向锂电池少量循环的二维支持域直推式健康状态预测[J]. 控制理论与应用, 2024, 41(3): 474-483.
- WANG Y H, FENG L J, ZHAO C H. Lithium battery two-dimensional region of support transductive learning and state of health prediction oriented to few charge-discharge cycles[J]. Control Theory and Technology, 2024, 41(3): 474-483.
- [17] DUBARRY M, VUILLAUME N, LIAW B Y. Origins and accommodation of cell variations in Li - ion battery pack modeling[J]. International Journal of Energy Research, 2010, 34(2): 216-231.
- [18] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2016: 770 - 778.
- [19] PARK H, NOH J, HAM B. Learning Memory-guided Normality for Anomaly Detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 14372 - 14381.
- [20] NAGUIB M, KOLLMEYER P, EMADI A. Lithium-ion battery pack robust state of charge estimation, cell inconsistency, and balancing[J]. IEEE Access, 2021, 9: 50570-50582.
- [21] DAS A, KONG W, LEACH A, et al. Long-term forecasting with tide: time-series dense encoder[Z/OL]. arXiv:2304.08424, 2023. <http://arxiv.org/abs/2304.08424>.
- [22] ZHANG E, XU C, WANG S, et al. Effects of cell-to-cell variations on series-connected liquid metal battery pack capacity[J]. Journal of Energy Storage, 2023, 73: 109148.
- [23] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [24] TIAN H, LI A, LI X. SOC estimation of lithium-ion batteries for electric vehicles based on multimode ensemble SVR[J]. Journal of Power Electronics, 2021, 21(9): 1365-1373.